强化学习

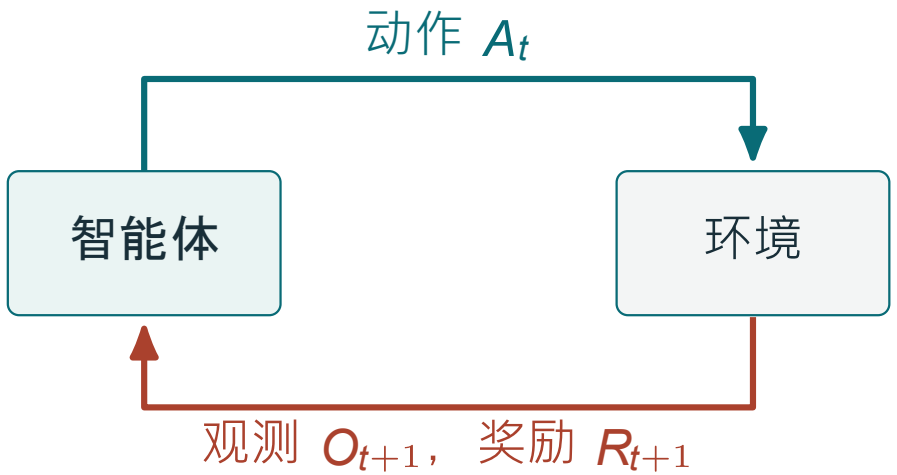
基于经验的预测与控制

RLChina Tutorial

温 颖

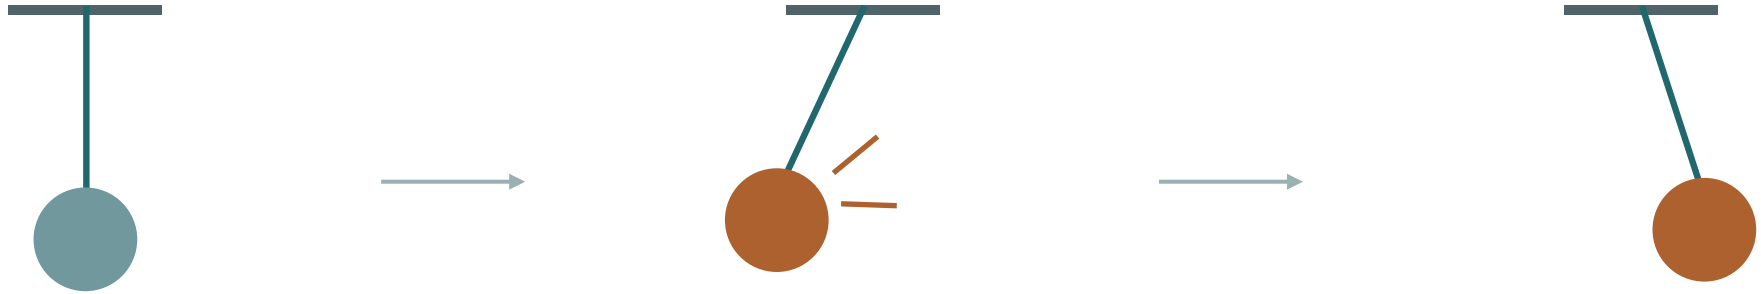
上海交通大学 / 上海创智学院

ying.wen@sjtu.edu.cn
yingwen.io



第 1 章　从交互中学习

一个婴儿伸手碰了碰悬着的玩具。玩具摇动，他听见了响声。



行动

伸手触碰

后果

玩具摇动、发声

再次行动

想让它再响，便伸手去碰。

行动提供了认识环境的机会。有了目标，对后果的预期才有助于选择下一步。

Sutton & Barto · Reinforcement Learning: An Introduction · §1.1

有目标的交互学习

强化学习研究智能体怎样利用交互经验，学会有利于长期目标的行动。

问题

规定智能体可获得的信息、可选动作与奖励，说明怎样评价一段行为。

方法

学习器可以从轨迹估计价值，直接调整策略，也可以学习模型并规划。

检验

在同一问题下，分析方法成立的条件，比较有限交互和计算预算下的表现。

目标说明什么结果值得追求。经验提供判断行动后果的依据。

Sutton & Barto · Reinforcement Learning: An Introduction · §1.1

课程目录：交互、价值与规划

1 从交互中学习　　**交互、策略与期望回报**

2 有限 MDP　**受控**转移、马尔可夫状态与回报准则

3 动态规划
给定模型，对可能后果求期望。

4 MC 与 TD 预测
给定轨迹，由样本估计价值。

5 动作价值与控制
用价值改善动作选择。

6 **多步回**报与资格迹
用后来的奖励更新早先的预测。

7 Dyna 规划
用学得的模型再做更新。

课程目录：函数逼近、深度方法与持续学习

8 函数逼近 访问加权的拟合误差与致命三元组

9 深度价值学习（DQN）
按动作价值比较，ε-贪心采样。

10 策略梯度与行动者—评论者
用轨迹估计期望回报的策略梯度。

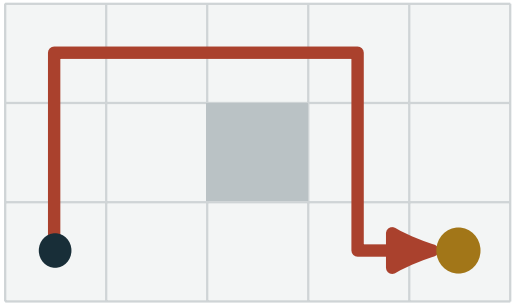
11 TRPO 与 PPO
用旧经验估计策略改进，调节更新步幅。

12 持续强化学习 一条经验流、有限的记忆与整个学习期间的收益

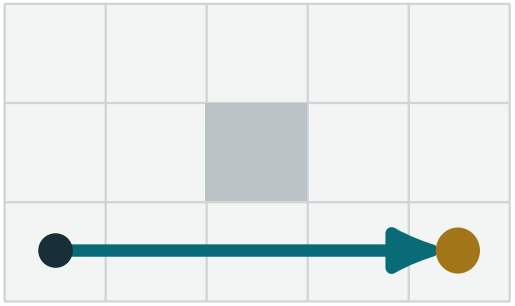
智能与目标

人和许多动物都能利用信息实现目标。身体决定哪些路能走，积累的经验则可能帮助它们找到一条更好的路。

初次行走



熟悉路线后



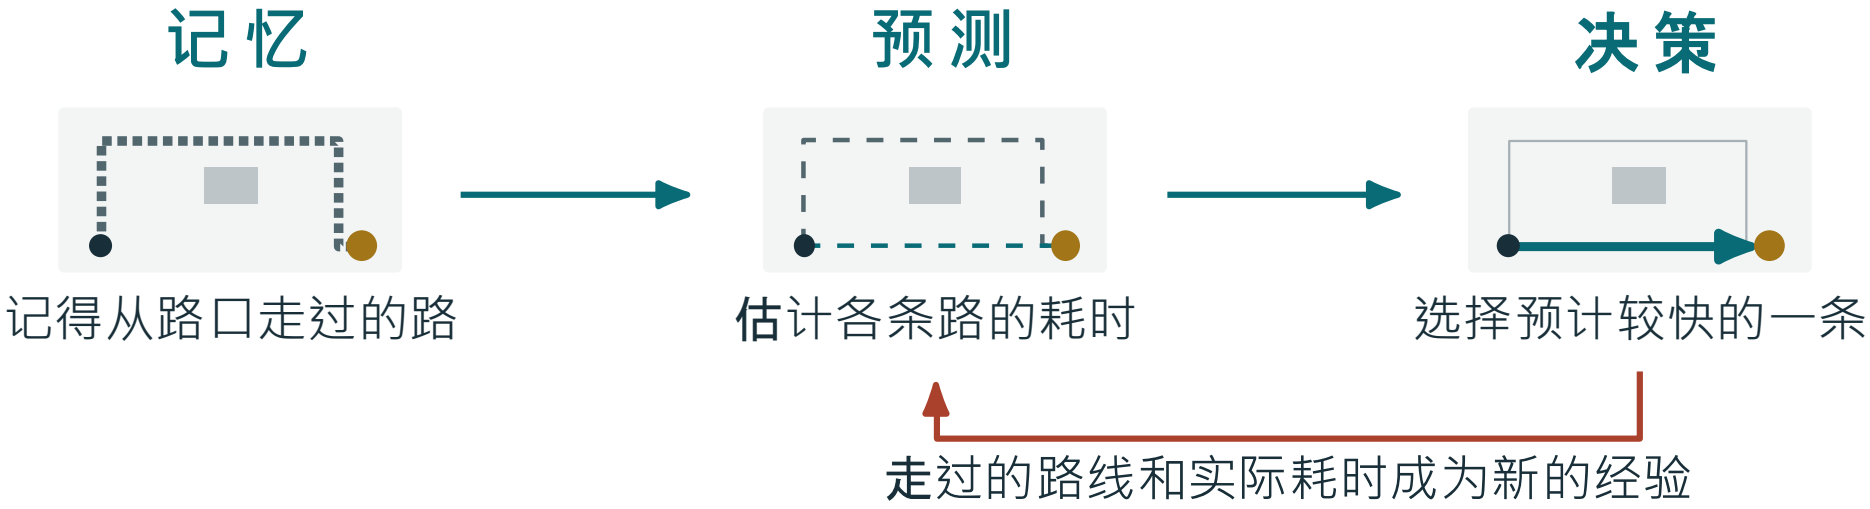
地形和食物位置相同。图中的动物记住路线后，第二次走得更短。

智能是在世界中实现目标的能力中的计算部分 这是 McCarthy 的定义。

Sutton，John McCarthy's Defnition of Intelligence（2020）。两条路径为教学示意。

智能、心智与学习

同一只动物在熟悉的路口能更快找到食物。**智能描述它利用信息**实现目标的能力。研究**心智**，则要解释这项能力由哪些过程产生，以及这些过程怎样共同支配行动。

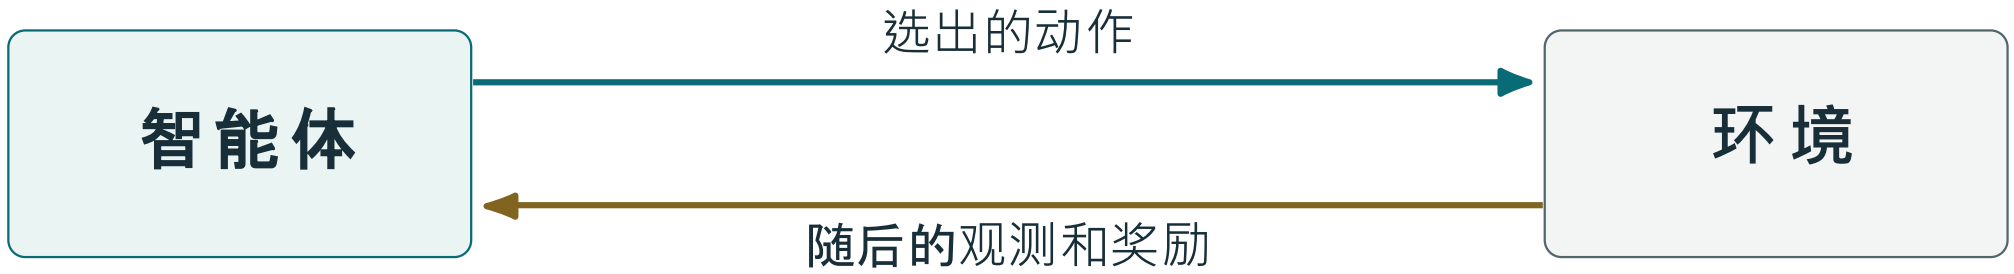


每次走到转角，动物都会得到新的观测。若这次绕路的经验改变了它**下次**对耗时的预期，或改变了它在**同一路口的**选择，就发生了学习。

McCarthy，What Is Artifcial Intelligence?；温颖，强化学习问题与大世界中的持续学习。图为一种可能的功能解释。

智能体与环境的交互接口

在一个决策问题中，选择动作的部分称为**智能体**。**同它交互的其余部分构成环境**。边界取决于智能体能**直接**选择什么；它也可能很熟悉边界以外的规律。

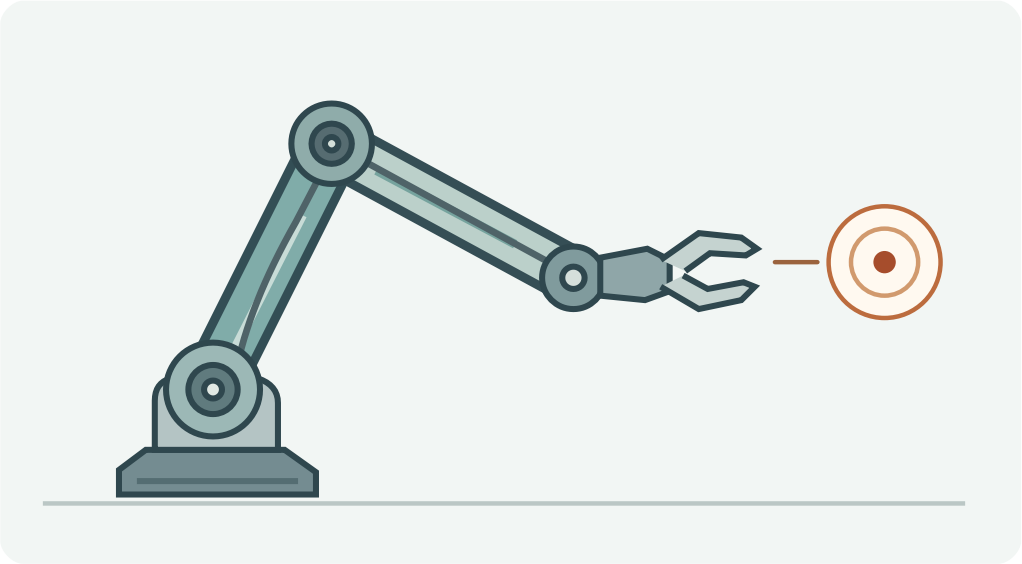


动作是交给环境执行的选择。**观测提供**结果的信息，可能只显示其中一部分。**奖励是数**值反馈，由任务规定怎样给出。智能体可以通过动作影响它们。

Sutton 与 Barto，《强化学习》，§3.1；Silver，Introduction to Reinforcement Learning。

同一只机械臂的两种动作接口

目标是让夹爪尽快进入橙色圆区。每走一个控制步得 -1，**首次**进入后结束。两次实验使用相同的机械臂、目标和计时方式。



实验甲　学习器指定下一控制步的参考位置，由已有**控制器**驱动关节。相机返回夹爪位置。

实验乙　参考位置由外部给出，学习器指定两个关节**的**驱动力矩。它还能读取关节传感器。

课堂讨论　**两**项实验各用什么动作、观测和奖励？哪项实验由学习器负责关节控制？夹爪的实际位置又由谁决定？

据 Sutton 与 Barto，§3.1、练习 3.3 改编。图为本课绘制。

奖励、回报与策略目标

智能体每走一步，环境都可以给出一个数值信号，称为**奖励**。评价一次选择，还要考虑这一步之后陆续**得到的**奖励。

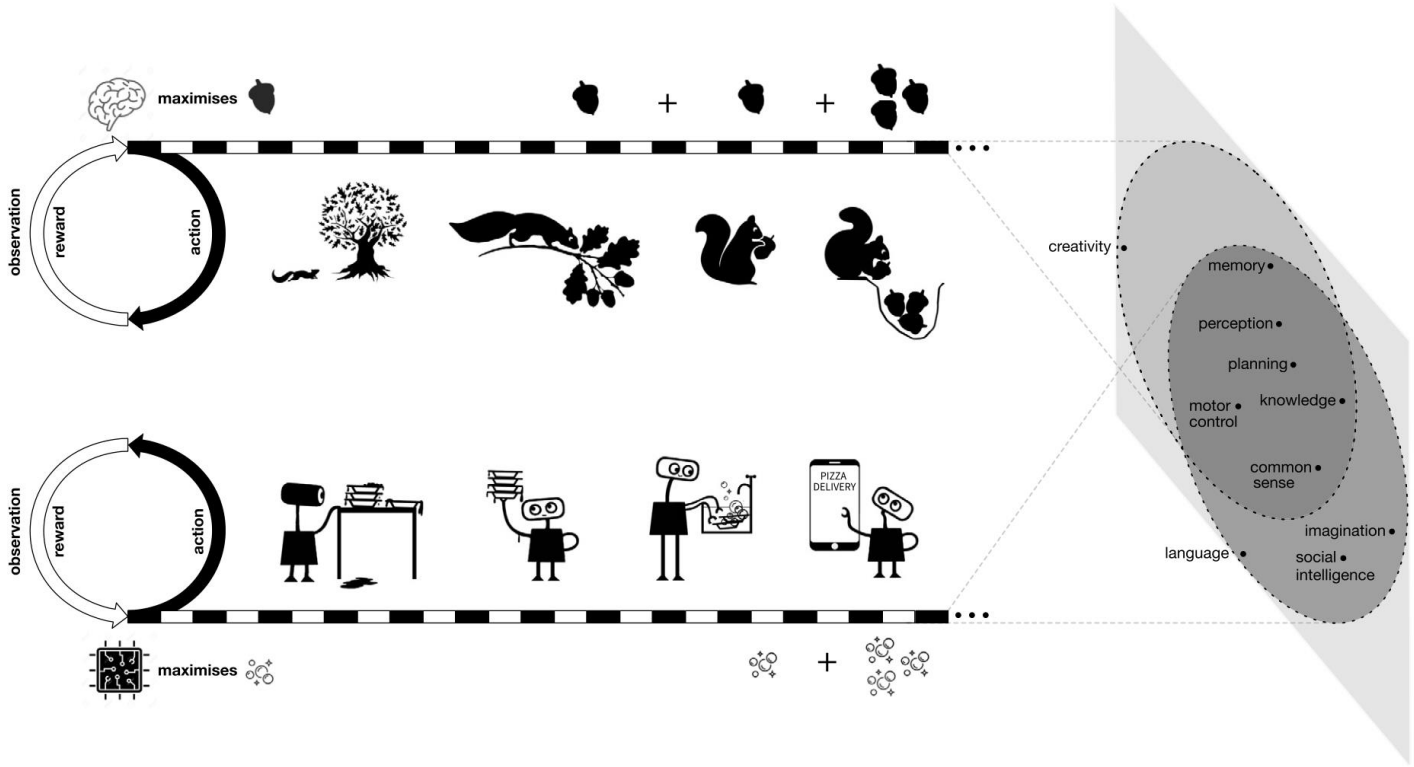


图中左路很快有收获，右路的收获较晚。**回报**按任务规定的时间范围和权重累积奖励。

给定起点，**策略的价值**是按该策略行动的期望回报。控制的目标是找到期望回报更高的策略。

Sutton 与 Barto，§§3.2–3.3。**冰面与路**线为本课的确定性两步任务。

奖励假设与智能能力的形成



奖励假设

一个目标可以表述为最大化某个标量奖励信号的期望累积值。设计者须说明用什么奖励表达这个目标。

Reward is Enough

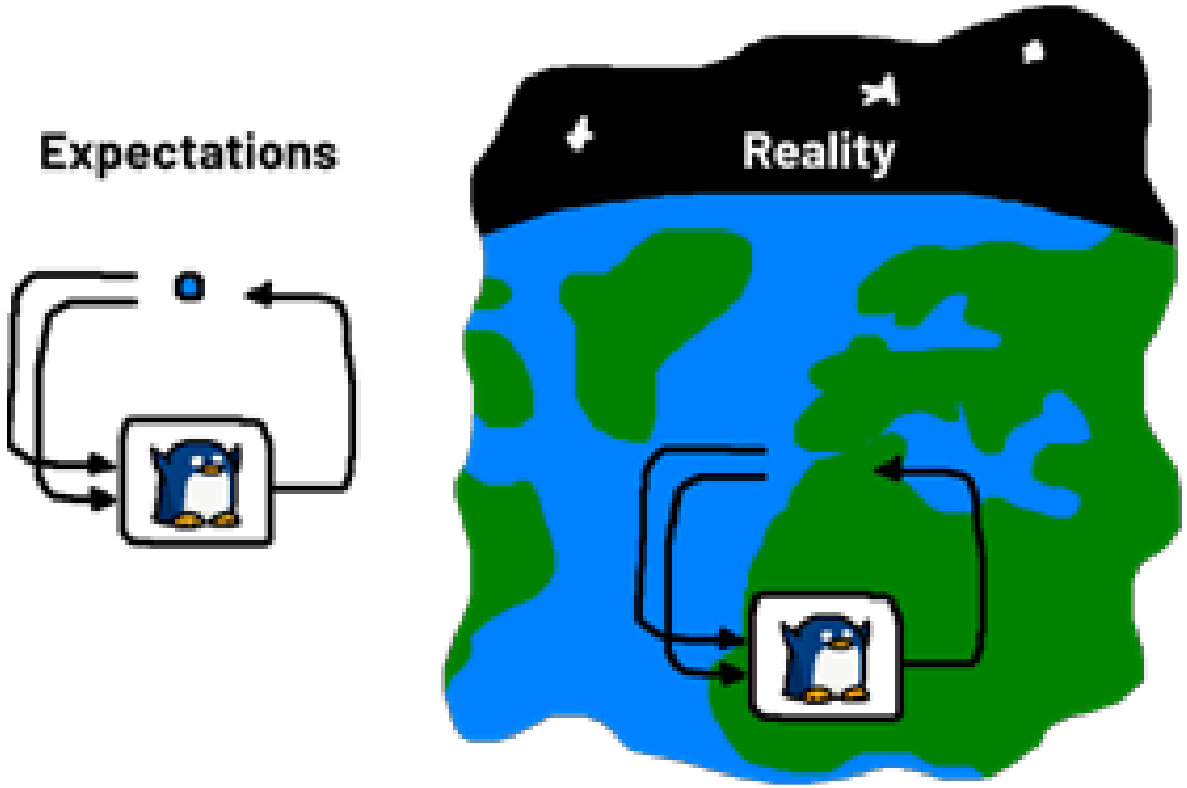
Silver 等提出，即使只有一个目标，在复杂环境中追求它也可能需要多种智能能力。

上排是储粮的松鼠，下排是清洁厨房的机器人。

松鼠今天藏起食物，过后还得找得到。图中的橡果代表所追求的食物收益。记住藏点、规划取食都可能**提高**长期收益，同一个目标就能解释两种能力的用处。

Sutton 与 Barto，§3.2。原图引自 Silver、Singh、Precup 与 Sutton，Reward is Enough（2021），图 1。© 2021 作者，CC BY-NC-ND 4.0。

大世界假设



两幅图中，企鹅一样大。

左边把企鹅放在一个小环境里。右边**仍是**这只企鹅，世界中同时发生的事**却**远多于它能看到、记住和处理的事。

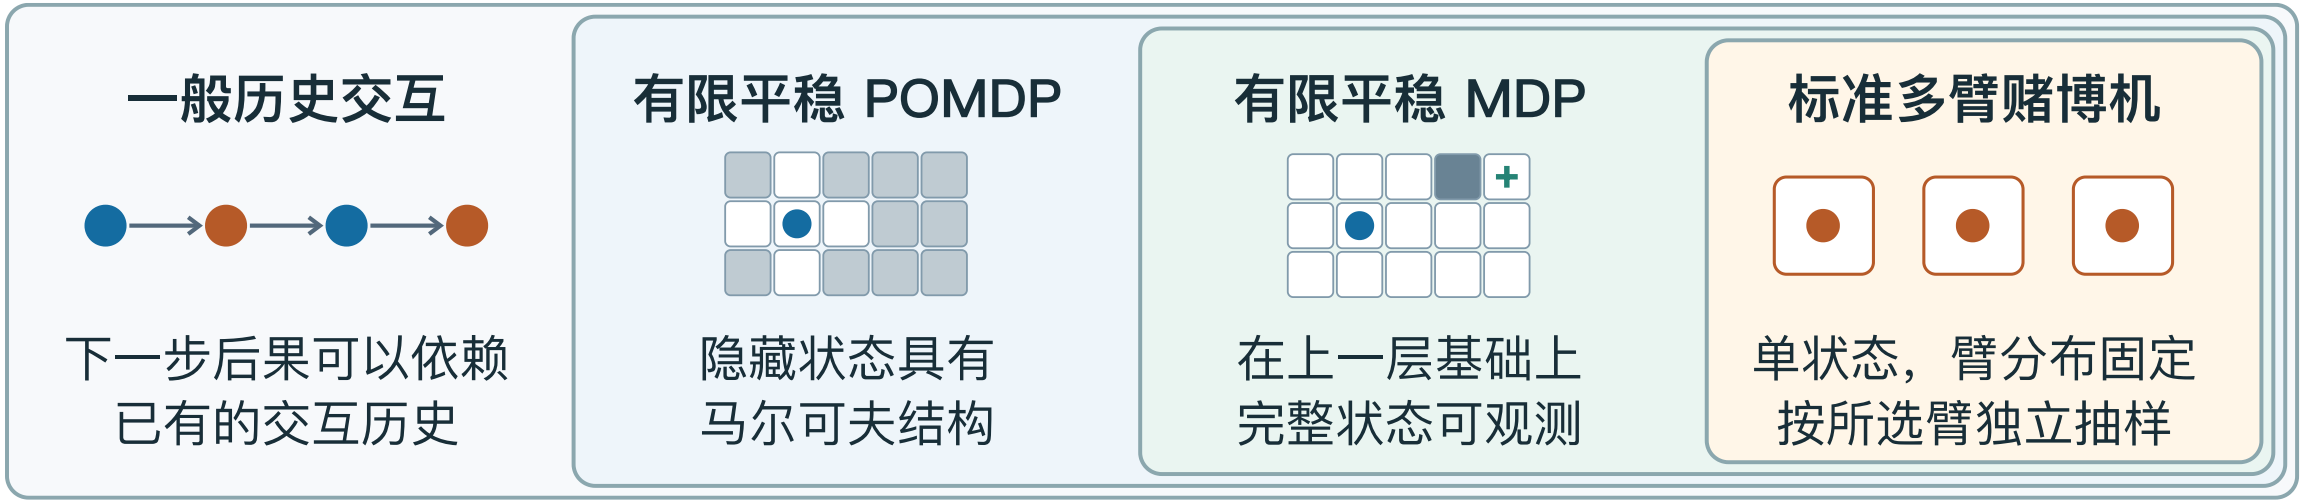
觅食时，它可能要留意哪里可以入水；**要返回原**处，还得记住来路。什么值**得**记，取决于接下来要做什么。

即使世界的规律固定，行动也会改变以后遇到的情形。有限的智能体需要从不断到来的经验中选择值得**学**习的内容。

原图：Kris De Asis，Design for Learning，见**温**颖，《强化学习问题与大世界中的持续学习》。Sutton，NSERC **研究**计划（2022），p.2。

环境模型的包含关系

在时刻 t，**智能体已取得**历史 H_t，**包含至今的**观测、动作和奖励。执行 A_t **后，它收到** O_{t+1}, R_{t+1}。图中**从左向右逐步**规定：历史里哪些信息足以预测这对反馈？



一般交互允许下一步的分布依赖 H_t 和 A_t。**MDP** 中，给定当前状态与动作，更早的历史不再改变下一状态与奖励的条件分布。

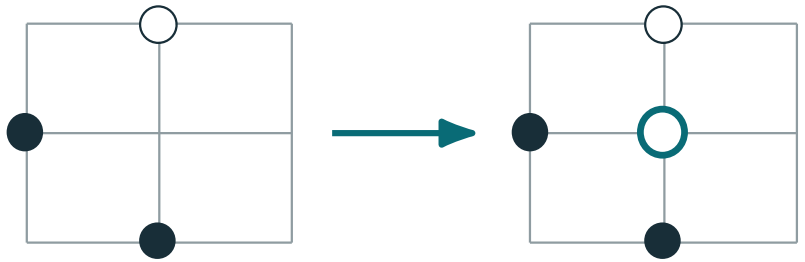
部分可观测时，眼前的景象可能对应不同位置；过去的行动与观测有助于分辨它们。即使状态完全可见，转移规律仍可以未知。

温颖，《强化学习问题与大世界中的持续学习》，“从历史到 Markov 状态”；**模型包含关系原**图。

预测与控制，学习与规划

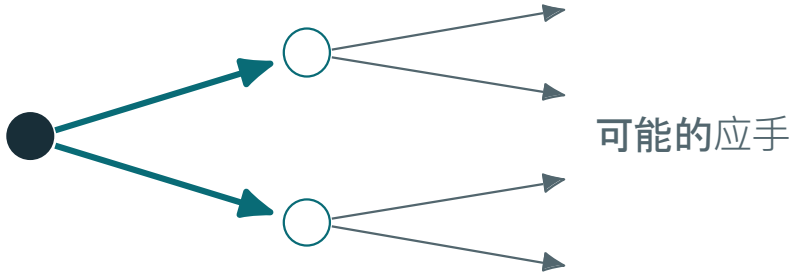
在棋局中，**预测**估计双方按给定策略继续对弈时的胜负前景。**控制**要选择落子策略，提高对给定对手的胜算。同一个局面可以提出这两类问题。

从对局中学习



一次落子推进正在进行的棋局。对弈者可用许多盘棋的局面与结局，学习判断形势或选择落子。

用模型规划



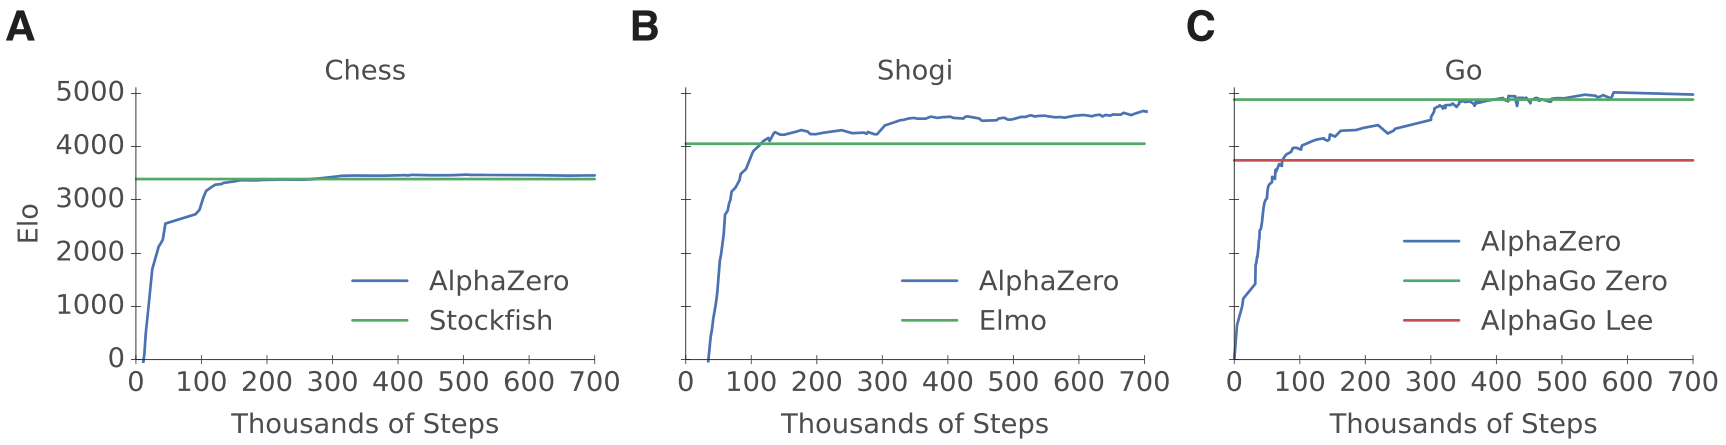
棋规给出每个合法落子的后继局面。对弈者可在**落子前推演几种**变化，比较它们的前景。

自我对弈为局面估值提供经验。搜索利用这些估值选择下一手。

Sutton 与 Barto，第 1、8 章；Silver 等，AlphaZero。棋盘为局部示意。

AlphaZero：用自对弈和搜索提高棋力

棋规给出了每步可以怎么走。面对难以穷尽的变化，棋手还需要判断哪些落子值得细看。

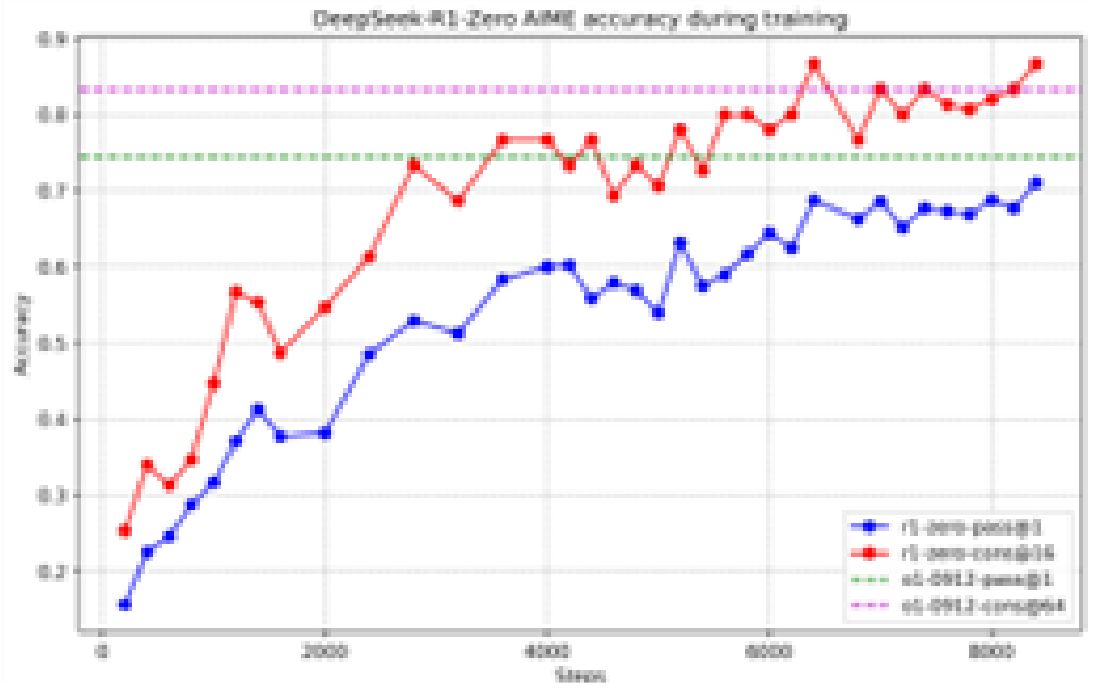


蓝线是 AlphaZero 在国际象棋、将棋和围棋中的棋力。它在每种棋上分别从头训练，通过自对弈逐渐超过了图中的强程序。

自我对弈训练网络预测走法和胜负。搜索参考这些预测，决定下一手。

Silver 等，A General Reinforcement Learning Algorithm that Masters Chess, Shogi, and Go through Self-play（2018），图 1。

DeepSeek-R1-Zero：用可核验的答案学习解题



随训练推进，单次回答数学竞赛题的正确率上升（蓝线）。

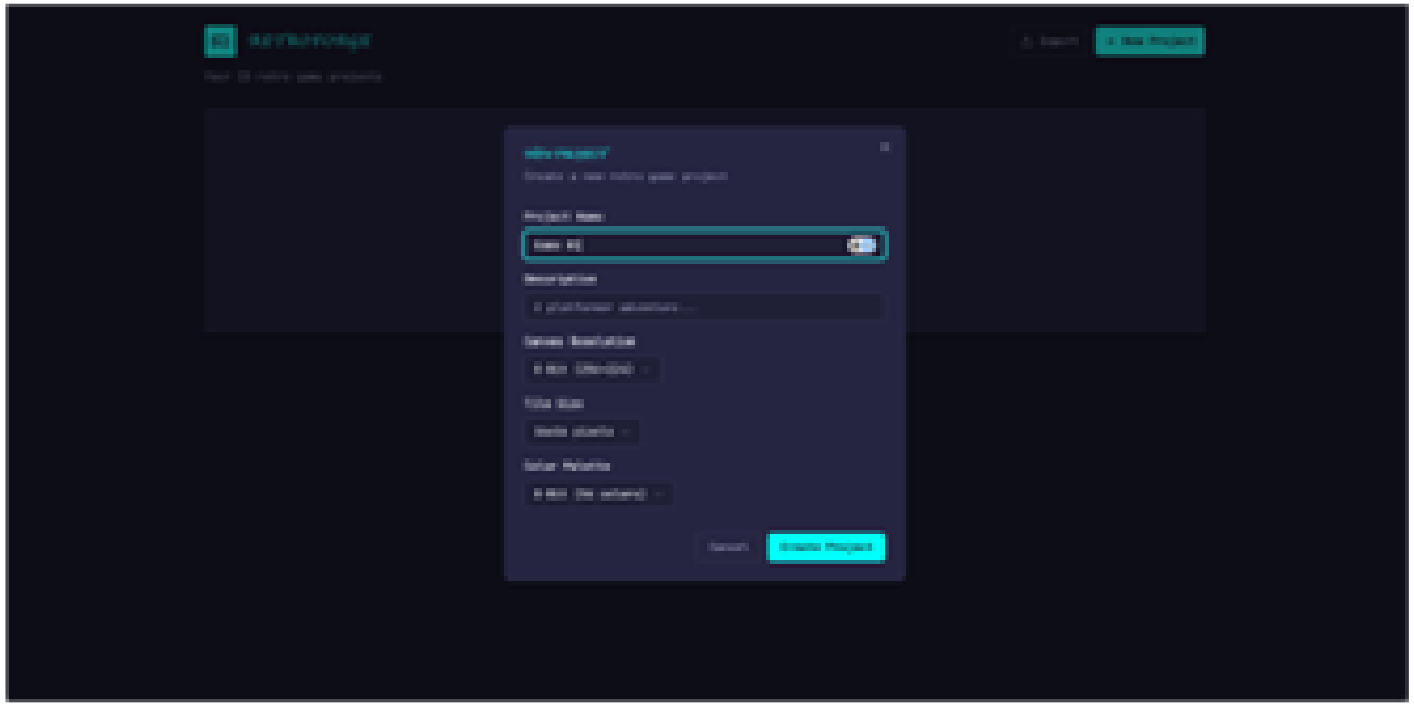
一道数学题可以有许多种解法。只要能核对最终答案，就有了评价整份回答的依据。

R1-Zero 从预训练模型出发，自己生成解答，用答案和格式检查得到的奖励调整模型。

训练可以用整份解答得到的反馈，无须教师逐步示范解法。

DeepSeek-AI，DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning （2025 年初稿），图 2。

Claude：在长程任务中使用反馈



Anthropic 的演示：Claude Opus 4.5 构建的游戏编辑器。

编辑器看上去已经成形，只有打开它、实际编辑一个场景，才能发现哪些功能可用。

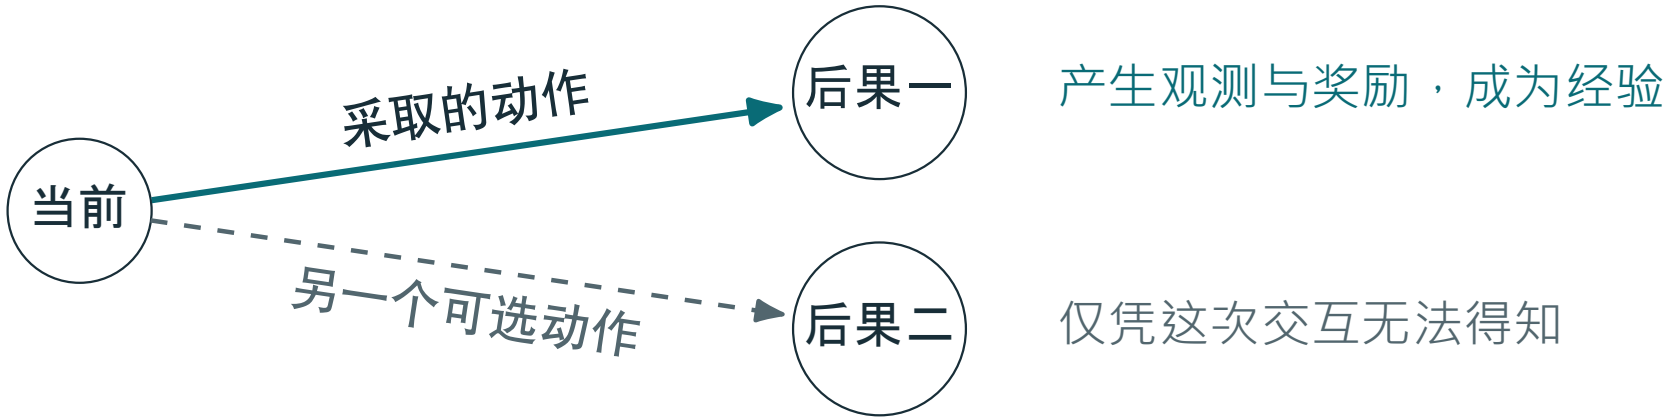
系统在浏览器中操作自己写的应用，根据测试结果修改代码。

修好当前项目说明反馈能指导下一步。这次经验是否改善了以后的工作，还要在新的项目中检验。

Anthropic，Harness Design for Long-running Apps（2026），游戏编辑器原图。

目标、经验与行动

交互接口规定决策者能观察什么、能选择什么。回报规定把哪些时刻的奖励计入表现。一次实际选择只产生一条可供学习的经验。



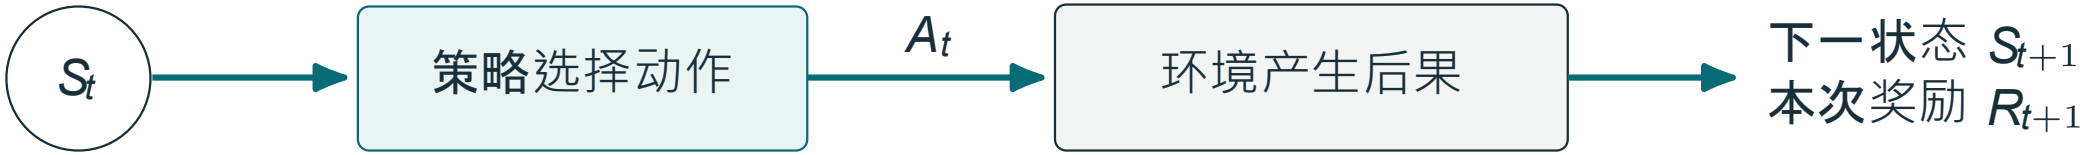
其他动作的后果，可以通过实际尝试或模型推演来估计。

在有限 MDP 中，一个可观测状态概括预测下一步所需的历史。这项假设使我们可以逐状态比较行动。

Sutton 与 Barto，§§1.1、3.1–3.2。

第 2 章　有限马尔可夫决策过程

马尔可夫决策过程 MDP　是序列决策的一种数学描述。智能体每次看到状态 S_t，选一个动作 A_t。当前状态与动作共同决定下一状态和奖励的条件分布。



记 H_t 为截至当前状态的交互历史。**马尔可夫性质**要求给定状态与动作后，一步后果的分布与更早的历史条件独立：

$$\Pr(S_{t+1} = s', R_{t+1} = r | H_t, A_t = a) = p(s', r | S_t, a).$$

本章状态与动作有限，状态可观测，环境核 p 固定。**能否查询 p 是另一个条件。**能查询真实分布时可对后果求和；只见实际转移时，可用样本估计同一期望。

预测给定策略的价值。　　**控制**求使期望回报最大的策略。

Sutton 与 Barto，第 2 版，§§3.1、3.5–3.6；Silver，第 2 讲；Machado，CMPUT 365，第 5 讲。

折扣MDP 的五元组

$$\mathcal{M} = (\ \underbrace{\mathcal{S}, \mathcal{A}}_{\text{状态与动作}}\ ,\quad \underbrace{P, R}_{\text{转移与期望奖励}}\ ,\quad \underbrace{\gamma}_{\text{回报的折扣因子}}\ ).$$

在非终止状态 $s \in \mathcal{S}$，智能体从 $\mathcal{A}(s)$ 选一个动作 a。环境随后给出下一状态 s' 和实际奖励 r。两者可以相关。离散情况下，用联合核表示

$$p(s', r|s, a) = \Pr(S_{t+1} = s', R_{t+1} = r|S_t = s, A_t = a).$$

$$P(s' \mid s, a) = \sum_r p(s', r \mid s, a), \qquad R(s, a) = \sum_{s', r} r\, p(s', r \mid s, a).$$

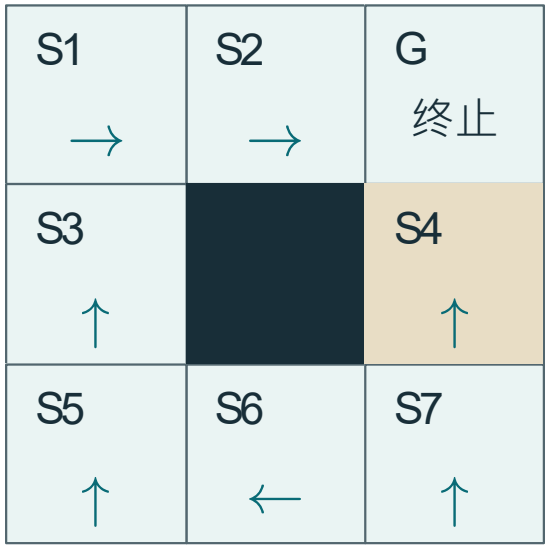
这里 $R(s, a)$ 是均值，R_{t+1} 是一次实际奖励。评价按当前状态行动的策略，只需 P 与这个均值。要模拟奖励与下一状态一起怎样出现，还需要它们的联合规律。

γ 规定未来奖励的权重。比较从指定起点出发的表现，另给初始分布 μ。本章取有界奖励、$0 \le \gamma < 1$，进入终点后的回报为零。

Silver，第 2 讲；Sutton 与 Barto，§§3.1–3.3。

泥地导航任务

从 S7 出发，前往 G



地图上 S4 是格名，S_t 是时刻 t 所在的格子。向上、下、左、右各走一格；撞墙或边界则留在原地。

$\mathrm{S7} \xrightarrow{\uparrow} \mathrm{S4}$ 确定发生。在泥地，每次动作有 .9 概率未能移动，.1 概率按普通规则执行。

只有进入 G 的一步奖励为 1；其余为 0。进入 G 后本回合结束，再开始时回到 S7。

图中箭头先给定一种行动规则，记为 π_0：在每格选择箭头方向。从 S7 出发，它会反复尝试向上。

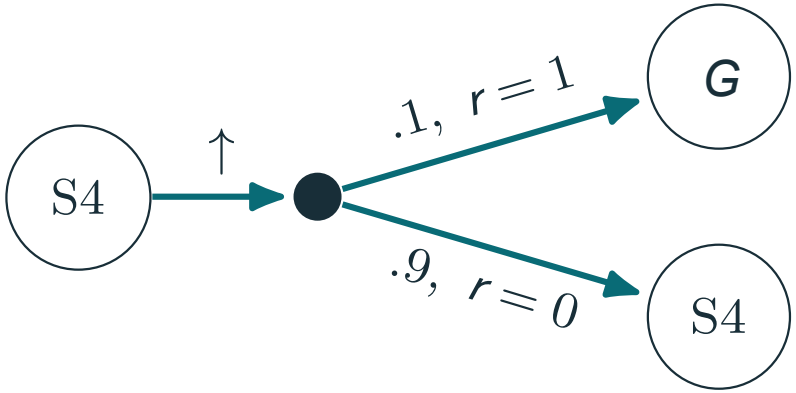
在 S7 向左或向上都得0，哪条路线好取决于何时到达终点。

Machado，CMPUT 365，第 5–6 讲。泥地任务据课程地图重绘。

状态转移与奖励的联合分布

一个环境后果同时包含**下一状态与本次奖励**，用联合核完整描述：

$$p(s', r|s, a) = \Pr(S_{t+1} = s', R_{t+1} = r|S_t = s, A_t = a).$$



s'	r	$p(s', r \mid \mathrm{S4}, \uparrow)$
G	1	.1
S4	0	.9

两条分支互斥且完备：$.1 + .9 = 1$。

$$\underbrace{P(s' \mid s, a) = \sum_r p(s', r \mid s, a),}_{\text{忽略奖励，得到状态分布}} \qquad \underbrace{R(s, a) = \sum_{s', r} r\, p(s', r \mid s, a)\,.}_{\text{把奖励按概率平均}}$$

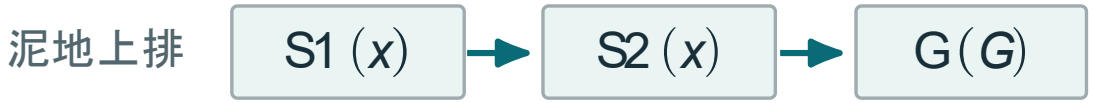
本课 $\mathcal{R} = \{0, 1\}$；对每个 (s, a) **都有** $\sum_{s', r} p(s', r \mid s, a) = 1$。给定马尔可夫策略，$P, R$ **足**够计算**它的期望折扣回**报，联合核还保留完整的后果分布。

Sutton 与 Barto §3.1；Machado，CMPUT 365，第 5–6 讲。

马尔可夫状态与最优动作

候选状态 $Z_t = g(H_t)$ **将两段可行历史** $h, \tilde{h}$ 归入同一状态。若它具有马尔可夫性质，固定任一可用动作 a，**下一状态与奖励的联合分布应当相同**：

$$\Pr(Z_{t+1} = z', R_{t+1} = r \mid h, a) = \Pr(Z_{t+1} = z', R_{t+1} = r \mid \tilde{h}, a) \qquad (\text{所有 } z', r).$$



括号内为观测。只有进入 G 才得 $+1$。

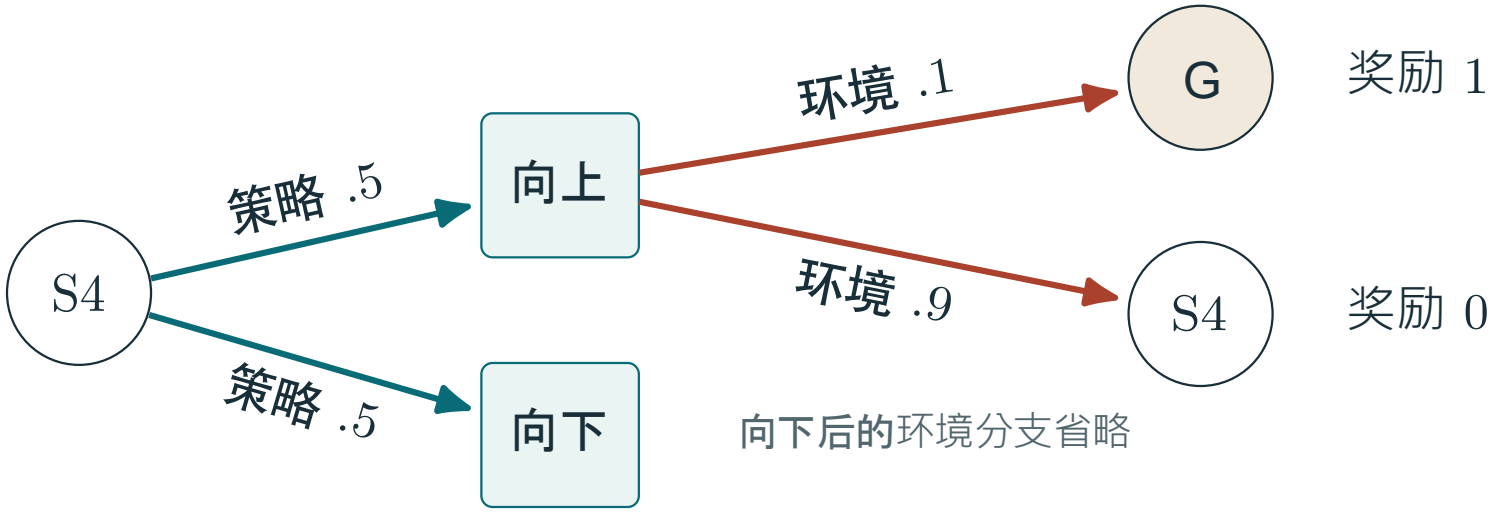
刚才在 S1	当前位置（观测）	此刻都向右	下一观测与奖励
向左撞墙	S1 (x)	→	$(x, 0)$ **概率** 1
向右一步	S2 (x)	→	$(G, 1)$ **概率** 1

两行需要不同的预测，却都应向右。取 $\gamma = .9$，**从 S1 连走两步向右得回报** $.9$，**从 S2 一步向右得** 1。**在这两格，其他首动作都会推迟到达。**

Sutton 与 Barto，初版 §3.5、第 2 版 §§3.1、3.5。Li、Walsh 与 Littman，2006，§3。 图据 Machado 的泥地任务。

策略与环境各决定一个条件分布

在状态 s，平稳马尔可夫策略 $\pi(a \mid s)$ 给每个可行动作分配概率，且 $\sum_{a \in \mathcal{A}(s)} \pi(a \mid s) = 1$。选定动作以后，下一状态和奖励由环境给出。



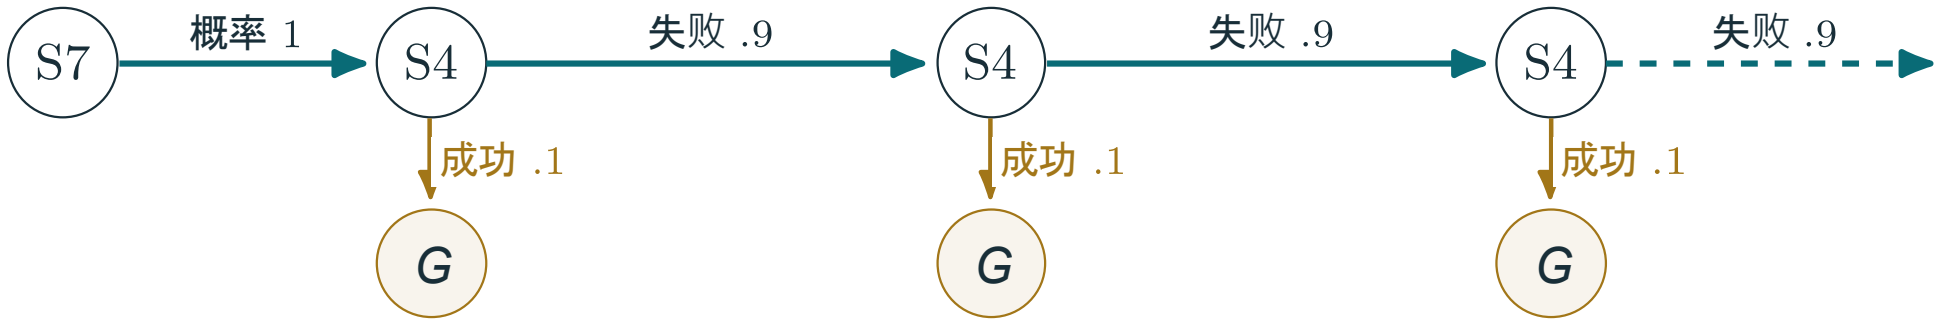
在图中的一次决策里，向上且抵达 G 的概率为 $.5 \times .1 = .05$。若把策略改为每次向上，这一概率变为 .1。改变策略能改变抵达 G 的机会，而给定向上后的成功概率仍为 .1。

Sutton 与 Barto，§§3.1、3.5。

固定策略下的轨迹分布

初始状态服从 μ。**每一步由策略**选择动作，由环境产生后继状态与奖励。具体轨迹 $\tau = (s_0, a_0, r_1, s_1, \ldots, a_{T-1}, r_T, s_T)$ **的概率**为

$$\Pr_{\pi}(\tau) = \mu(s_0) \prod_{t=0}^{T-1} \underbrace{\pi(a_t \mid s_t)}_{\text{策略}} \underbrace{p(s_{t+1}, r_{t+1} \mid s_t, a_t)}_{\text{环境}}.$$



$K = 0$： $P = .1$, $G_0 = .9$　　$K = 1$： $P = .09$, $G_0 = .81$　$K = 2$： $P = .081$, $G_0 = .729$

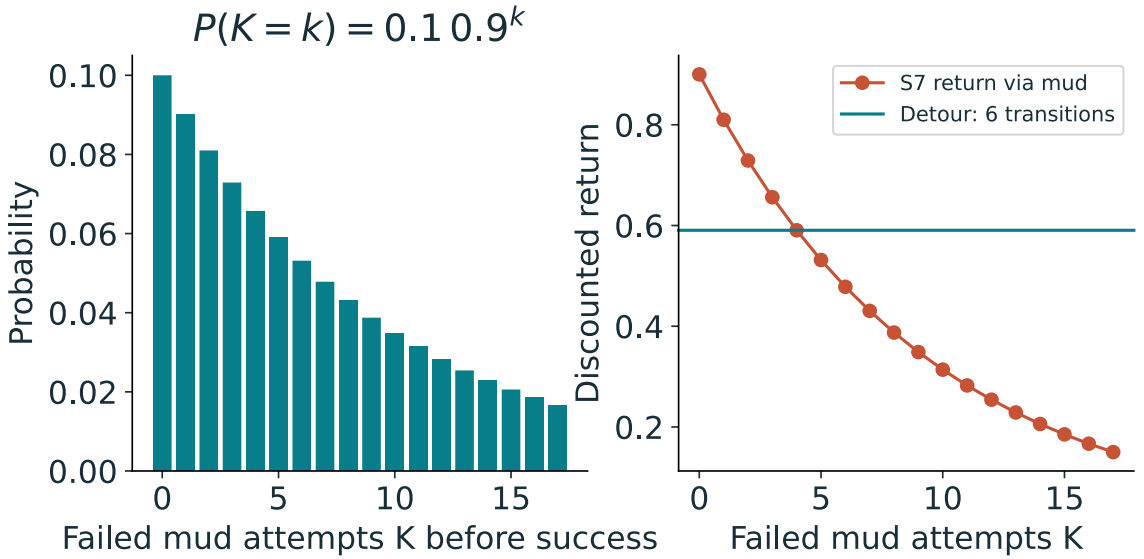
图中始终向上，仅进入终点时得 $+1$，$\gamma = .9$。**在泥地失败** k **次后脱困的概率是** $.9^k(.1)$；奖励推迟 k **步，回**报为 $.9^{k+1}$。**按概率加**权即得 $v_\pi(\mathrm{S7})$。

此策略在 S7 向左的概率为零。它采集的轨迹可以评价向上路线；若环境模型未知，仅凭这些记录无法确**定向左路**线的价值。

Sutton 与 Barto《强化学习》第 3 章；Silver，Markov Decision Processes。

状态价值函数

回报可积时，状态价值是**从该状态开始、一直按同一策略行动**的期望回报。



$$v_\pi(s) = \mathbb{E}_\pi[G_t \mid S_t = s], \qquad v_{\pi_0}(\mathrm{S7}) = \sum_{k=0}^{\infty} .1\,.9^k\,.9^{k+1} = \frac{.09}{1-.81} = .473684.$$

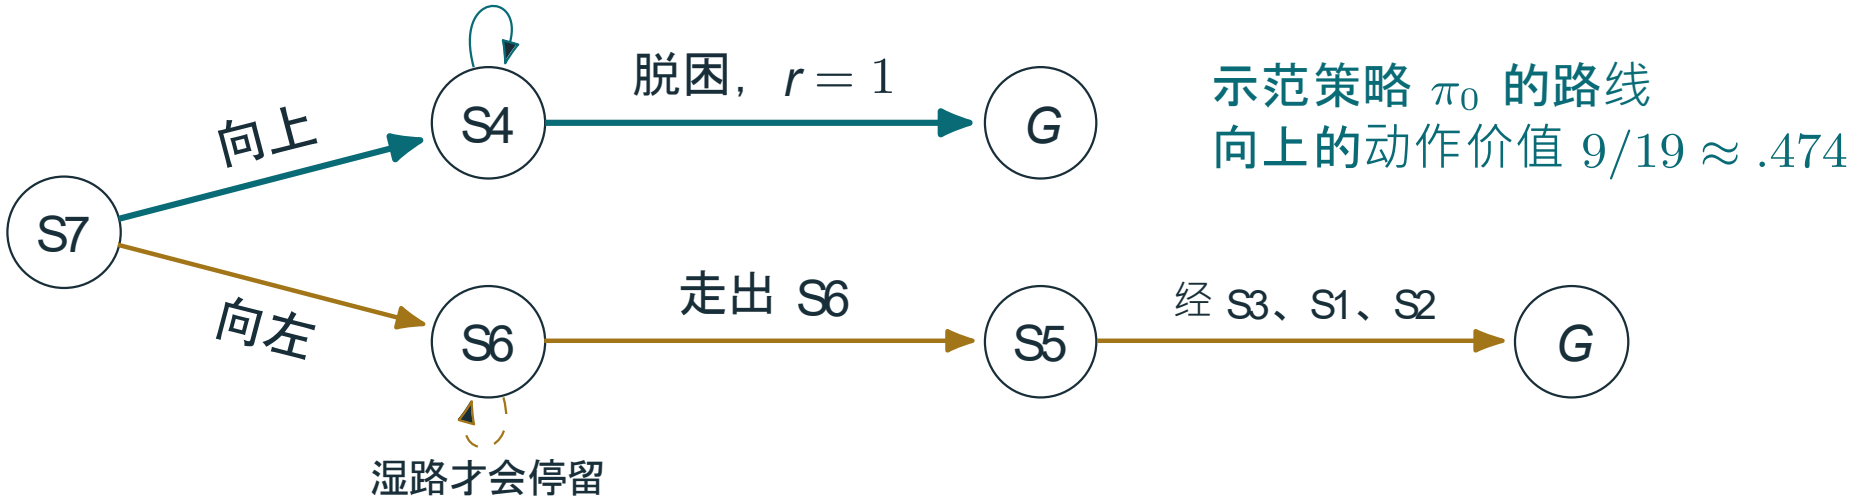
下标 π **决定以后怎**样行动；s **决定从哪里开始**；**期望同**时平均策略与环境的随机性。干路价值 $.59049$ 较高，单次走泥地仍可能更快。

Sutton 与 Barto：《强化学习》

状态价值与动作价值

$q_\pi(s,a)$ **是在** s **指定首**动作 a**、随后遵循** π **的期望回**报。若首动作也由 π 选择，

$$v_\pi(s) = \sum_a \pi(a|s)\, q_\pi(s,a).$$



示范策略 π_0 **的路**线
向上的动作价值 $9/19 \approx .474$

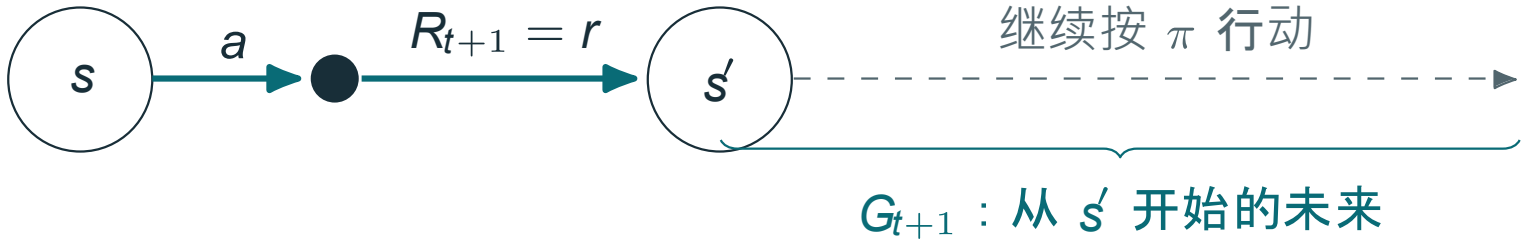
示范从 S7 向上，始终到不了 S6。S6 **干燥**时，起点向左的动作价值为 $.9^5 = .59049$。**若**仅把 S6 **向左改**为每次有 $.9$ **的概率留在原地，**这个价值降为 $.31078$。

两种环境给出相同的示范分布。干路宜选左，湿路宜选上。

Sutton 与 Barto，§§3.1、3.5；Silver，第 2 讲。原泥地任务与一条转移规律的对照。

回报递推与条件期望

在下一状态处切开轨迹，余下的仍是同一策略下的预测问题。



由 $G_t = R_{t+1} + \gamma G_{t+1}$，对下一后果 (s', r) 用全期望公式：

$$q_\pi(s,a) = \sum_{s',r} p(s', r \mid s, a)\left[r + \gamma \underbrace{\mathbb{E}_\pi[G_{t+1} \mid s, a, s', r]}_{v_\pi(s')}\right].$$

Markov 状态使过去的前缀不再改变后续分布；**平稳 Markov 策略**保证到达 s' 后仍用同一行动规则。因此，括号内的未来均值就是 $v_\pi(s')$。

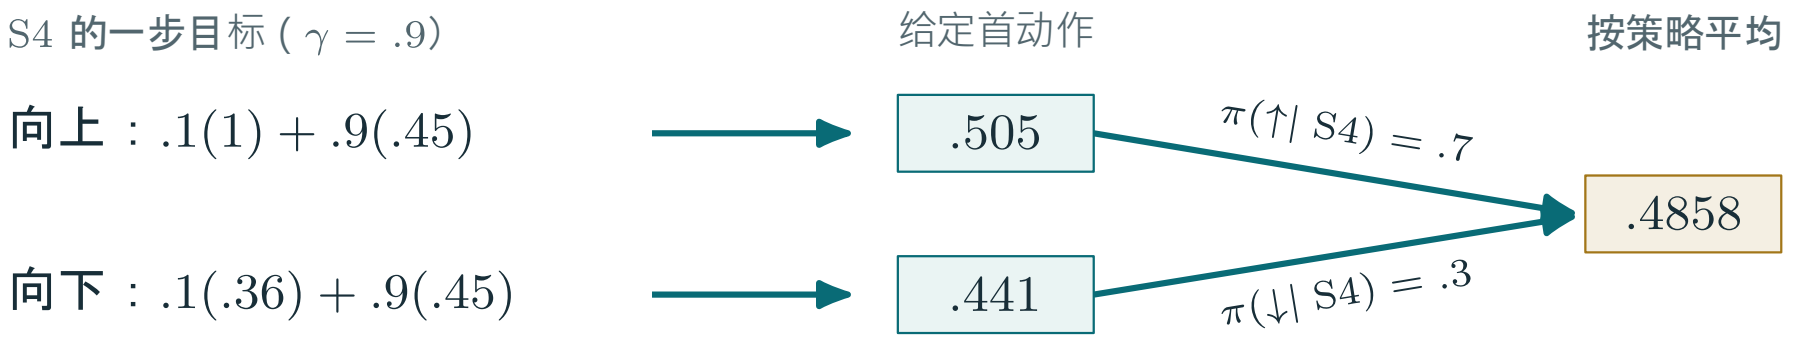
到达终点的一步仍有奖励 r。**此后的尾**值是 $v_\pi(G) = 0$。

Sutton 与 Barto §3.5，式 (3.14)；据 Silver 第 2 讲重绘。

Bellman 期望方程

在状态 s 按策略 π 行动。给定一张价值表 V，一步目标 $R_{t+1} + \gamma V(S_{t+1})$ 的均值有两层求和：

$$(T_\pi V)(s) = \sum_a \underbrace{\pi(a \mid s)}_{\text{动作概率}} \underbrace{\sum_{s',r} p(s', r \mid s, a)\,[r + \gamma V(s')]}_{\text{给定动作，对后继状态与奖励求平均}}.$$

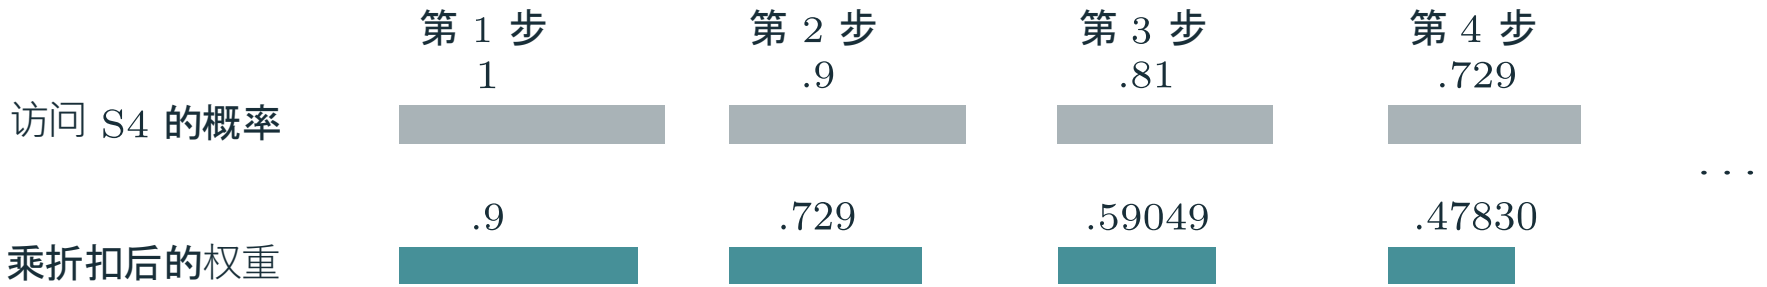


图中 $V(\mathrm{S4}) = .5$，$V(\mathrm{S7}) = .4$，$V(G) = 0$。S4 的一步目标均值是 .4858。若尾值取真实价值，延续同一策略的期望回报仍为 v_π，即 $v_\pi = T_\pi v_\pi$。

Sutton 与 Barto《强化学习》§3.5；Silver，Markov Decision Processes。

状态动作的访问次数与折扣占用度量

从 S7 出发始终向上，一步到泥地 S4。每次在泥地行动，以 .1 的概率到达终点并得 1，否则仍在泥地且奖励为 0。



每回合访问泥地的期望次数为 $1 + .9 + .9^2 + \cdots = 10$。若目标折扣为 .9，第 t 步的贡献还需乘 γ^t。从起点直到终止 T，定义

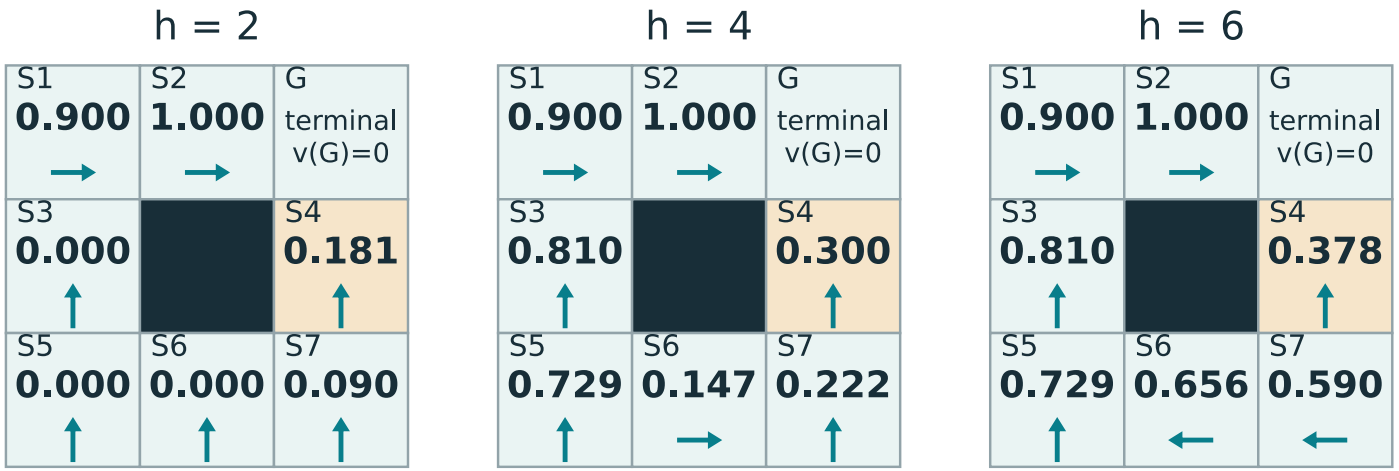
$$\eta^{\gamma}_{\mu,\pi}(s,a) = \sum_{t \geq 0} \gamma^t \Pr_{\mu,\pi}(S_t = s, A_t = a,\ t < T), \qquad \underbrace{J_\gamma(\pi)}_{\text{起点期望回报}} = \sum_{s,a} \eta^{\gamma}_{\mu,\pi}(s,a)\ \underbrace{R(s,a)}_{\text{一步奖励均值}}.$$

这里用未归一化的占用量。泥地的折扣权重为 $.9/(1-.81) = 90/19$。奖励只可能在泥地发出，故 $J_\gamma = (90/19) \times .1 = 9/19$，与 Bellman 方程给出的起点价值一致。

Sutton 与 Barto，§§3.5、9.2、13.2。泥地采用本章固定策略；条形长度表示每步的访问概率及其折扣权重。

有限期限改变了控制目标

本任务只计未来 h 步内的奖励。到达 G 或用完 h 步就终止。图中箭头为最优首动作。



还剩 2 步

向上进入泥地，再向上有 .1 **的概率到达** G，**期望回报为** $.9 \times .1 = .09$。**向左来不及得**奖。

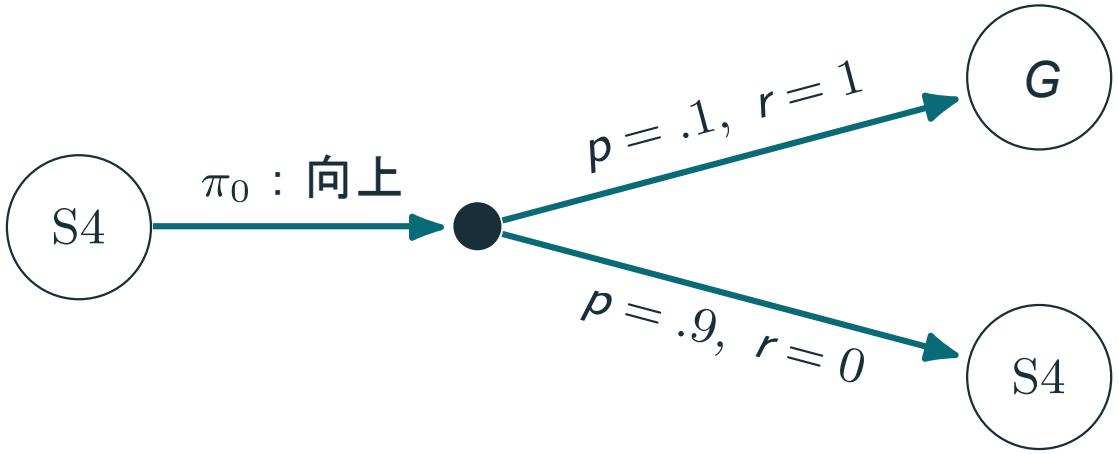
还剩 6 步

向左绕行，第六步确定得奖，回报为 $.9^5 = .59049$。**同一起点的最**优首动作由上变为左。

决策时需要知道位置及剩余步数 (s, h)。**走到** $(\mathrm{S4}, 0)$，**后**续价值为零。若只规定每两步保存一段记录，任务本身仍可继续，$\mathrm{S4}$ **仍有未来回**报。

Sutton 与 Barto，§§3.3–3.4；Pardo 等，Time Limits in Reinforcement Learning（2018）。图为本课泥地模型的有限期限最优解。

Bellman 方程与策略评价



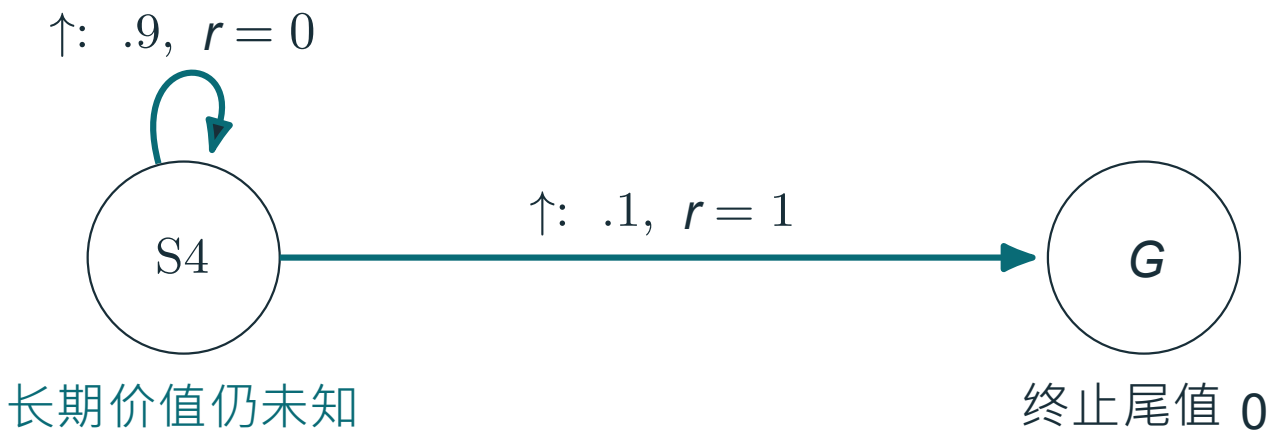
$$\underbrace{v_{\pi_0}(\mathrm{S4})}_{\text{从泥地出发的价值}} = .1\,(1 + .9 \times 0) + .9\,(0 + .9\,v_{\pi_0}(\mathrm{S4})) \implies \boxed{v_{\pi_0}(\mathrm{S4}) = .1/.19 \approx .526}.$$

成功离开就得到 1；**原地打滑便回到同一个**预测。**Bellman 方程按第一步的后果分解**长期回报。泥地只**剩一个未知**值。整张地图的未知值彼此相依，动态规划用已知模型求解这组方程。

Sutton 与 Barto §3.5。**泥地任**务的状态转移树。

第 3 章　动态规划

给定有限平稳 MDP 的转移和奖励模型、有界奖励以及 $0 \leq \gamma < 1$。**策略评估**计算 v_π。**最优控制**求 v_* 和相应策略。



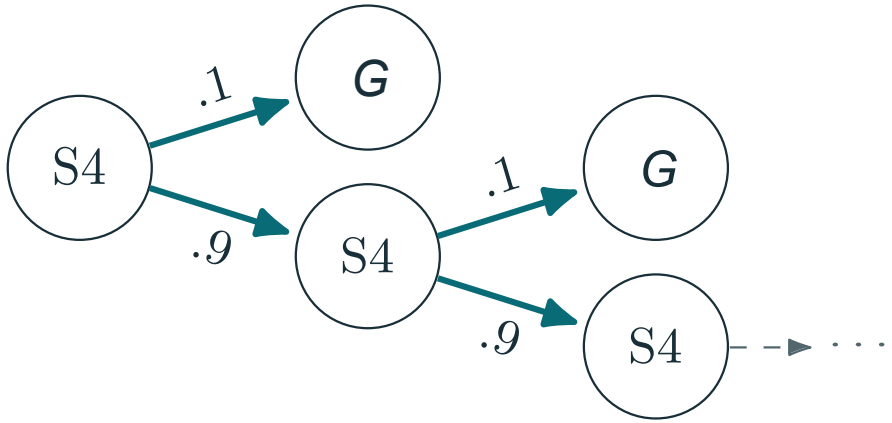
泥地中的自环使 $v_\pi(\mathrm{S4})$ **出**现在方程两边。策略评估反复按模型概率加权后继价值。求最优策略时，可以**交替**评估和改善策略，也可以在每次价值更新时直接取最优动作。

Sutton 与 Barto 第 4 章；Silver，第 3 讲。

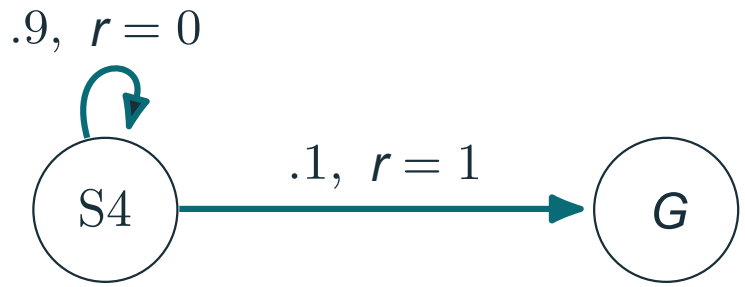
重叠子问题：同一状态的尾值可以复用

固定平稳策略 π_0。**每次回到** S4，继续向上的后果分布和未来行动规则都相同。

轨迹树：相同尾部反复出现



状态表：复用一个 S4 **尾**值



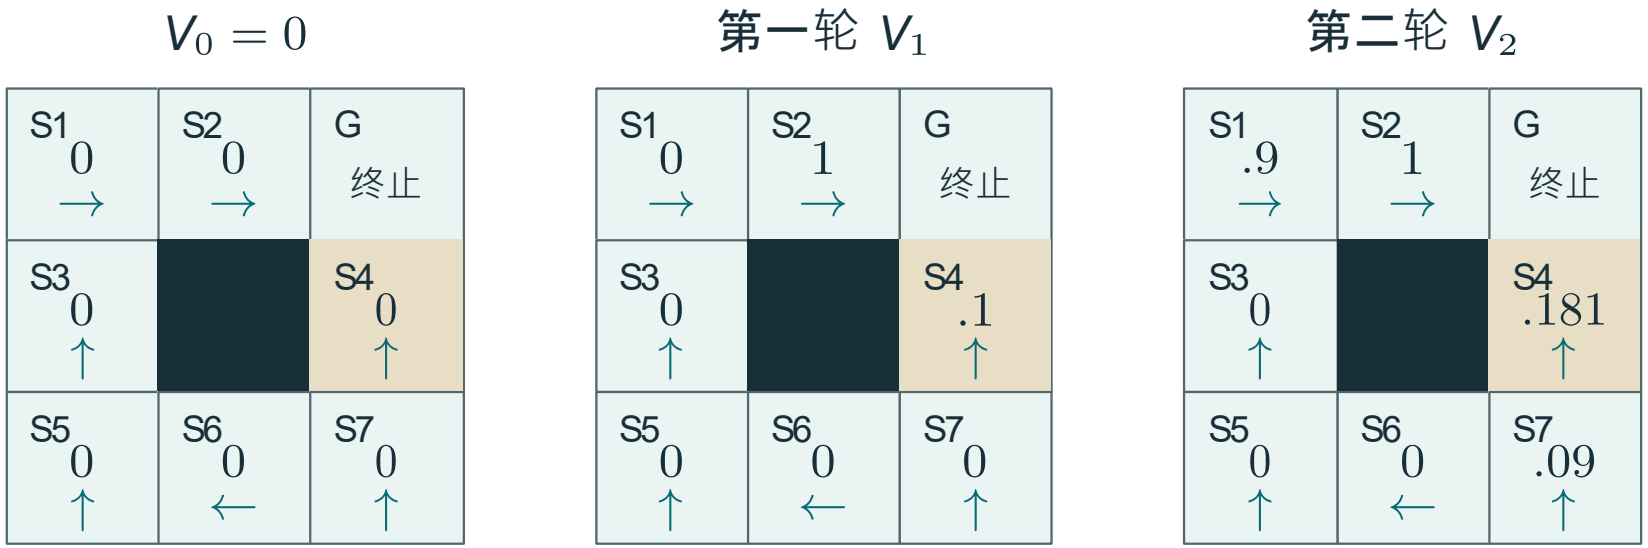
$$v_{\pi_0}(\mathrm{S4}) = .1[1 + .9(0)] + .9[0 + .9v_{\pi_0}(\mathrm{S4})].$$

马尔可夫状态与平稳策略使两段历史到达 S4 **后有同一个尾**值。泥地可以反复回到 S4，图中的无限条路**径因而只需一个未知数。**

据 Silver 第 3 讲的重叠子问题重绘；Sutton 与 Barto §4.1。

同步策略评价：前两轮的价值传播

从 $V_0 = 0$ 出发，第 k 轮等于**固定策略下前 k 次转移的折扣奖励期望**剩余尾值取 0。



$$V_1(\mathrm{S4}) = .1 + .81(0) = .1, \qquad V_1(\mathrm{S7}) = .9V_0(\mathrm{S4}) = 0,$$

$$V_2(\mathrm{S4}) = .1 + .81(.1) = .181, \qquad V_2(\mathrm{S7}) = .9V_1(\mathrm{S4}) = .09.$$

第一轮只计一步内的奖励，故 $V_1(\mathrm{S4}) = .1$、$V_1(\mathrm{S7}) = 0$。**第二**轮 S7 读到这 .1，**得到** $.9 \times .1 = .09$。**两幅**图的策略箭头完全相同。

据 Sutton 与 Barto 图 4.1 及 Silver 第 3 讲重绘。数值取自泥地任务。

同步迭代策略评价算法

输入：准确模型 p、固定策略 π、$0 \le \gamma < 1$，**所需最大**误差 $\varepsilon > 0$。

输出：一张价值表 $\widehat{V}$；**停止**时最大误差 $\max_s |\widehat{V}(s) - v_\pi(s)| \le \varepsilon$。

1. **取任意有限初**值 V_0，令 $V_0(G) \leftarrow 0$，$k \leftarrow 0$。
2. **重复**：
3. 置 $W(G) \leftarrow 0$。
4. 对每个非终止状态 s，计算 $\boxed{W(s) \leftarrow (T_\pi V_k)(s)}$。
5. $\Delta_k \leftarrow \max_{s \in \mathcal{S}} |W(s) - V_k(s)|$。
6. 若 $\dfrac{\gamma \Delta_k}{1-\gamma} \le \varepsilon$，**返回** W。
7. $V_{k+1} \leftarrow W$，$k \leftarrow k+1$，继续第 2 行。

第 4 行枚举模型给出的全部后果；所有尾值只读取 V_k。Δ_k **是相**邻整表的最大差，第 6 **行的**误差保证由贝尔曼算子的收缩性得到。

Sutton 与 Barto §4.1；Silver，第 3 讲。实现：course25_dp_evaluation.py。

策略改善定理

在有限折扣 MDP 中，奖励有界，$0 \le \gamma < 1$。π, π' 为平稳策略。在 s 改用 π' 一步、此后恢复 π，收益差为

$$\Delta(s) = \sum_a [\pi'(a \mid s) - \pi(a \mid s)]\, q_\pi(s, a) = (T_{\pi'} v_\pi)(s) - v_\pi(s).$$

若每个状态的 $\Delta(s) \ge 0$，则每个起点均有 $v_{\pi'}(s) \ge v_\pi(s)$。

	$t=0$	$t=1$		$t=n-1$	$t=n$	$t=n+1$	
U_n	π'	π'	$\cdots$	π'	π	π	$\cdots$
U_{n+1}	π'	π'	$\cdots$	π'	π'	π	$\cdots$

U_n 的前 n 步用 π'，此后用 π。两行到达 S_n 的分布相同。增加一步新策略，得到

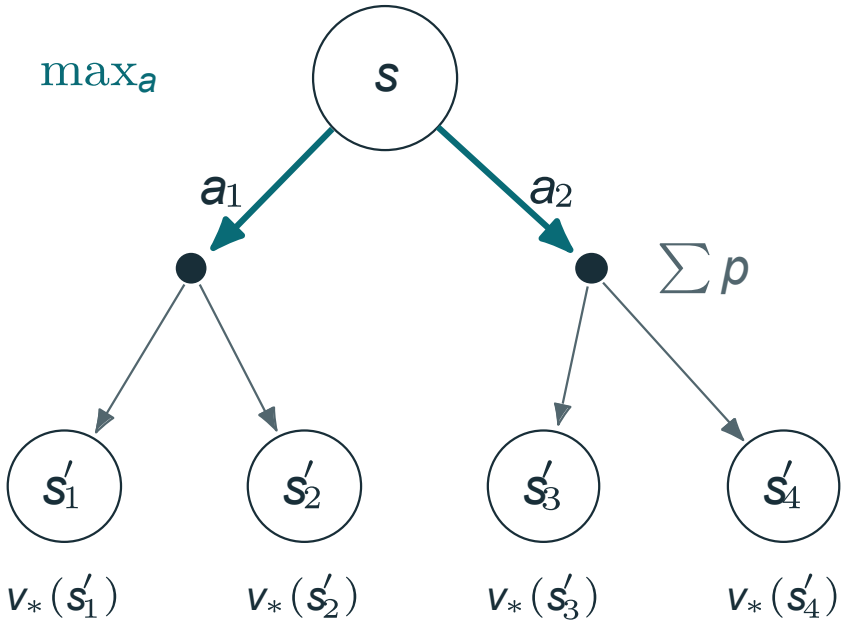
$$U_{n+1}(s) - U_n(s) = \gamma^n \mathbb{E}_{\pi'}[\Delta(S_n) \mid S_0 = s] \ge 0.$$

$U_0 = v_\pi$，折扣使有界的旧策略尾项趋于零，故 $U_n \to v_{\pi'}$。

Sutton 与 Barto《强化学习》§4.2；Silver，Planning by Dynamic Programming。

最优性原则与Bellman 最优方程

最优性原则：**在当前状**态选择动作后，后续决策仍应使到达状态的期望回报最大。Markov **状**态使这个后续问题只依赖到达状态。



对每个动作，先平均它可能带来的奖励与后继价值；再比较动作：

$$v_*(s) = \max_a \sum_{s',r} p(s', r|s, a)[r + \gamma v_*(s')].$$

用任意价值表 V 代替未知的 v_*，定义 **Bellman 最优算子**:

$$(T_*V)(s) \doteq \max_a \sum_{s',r} p(s', r \mid s, a)[r + \gamma V(s')].$$

若 π 对自身价值贪心，则 $v_\pi = T_\pi v_\pi = T_* v_\pi$。**因此**，评价与改善同时停止时，得到的是最优方程的一**个解。收**缩性保证解唯一。

Sutton 与 Barto，§§3.6、4.2；Silver，Principle of Optimality / Bellman Optimality Backup。**更新**树据原课程重绘。

策略迭代：精确评价与贪心改善

输入准确模型与 $0 \le \gamma < 1$；终止价值固定为 0。**以下先**给出**精确评价版本**。

1 **任取确定性策略** π。
2 **重复**：
3 　**求解** $V = T_\pi V$，**得到** $V = v_\pi$。　　固定策略评价
4 　对每个非终止状态 s：
5 　　计算所有动作的 $Q(s,a) = \sum_{s',r} p(s', r \mid s, a)[r + \gamma V(s')]$。
6 　　**取** $\pi'(s) \in \arg\max_a Q(s,a)$；**旧**动作若仍最大，则保留旧动作。
7 　**若** $\pi' = \pi$，**返回** (π, V)；**否**则令 $\pi \leftarrow \pi'$，继续第 3 **行**。

非稳定改善至少使一个状态严格变好；确定性策略有限，因此不会回到旧策略，最终得到 π_*, v_*。

$$\pi_0 \xrightarrow{\text{评价}} v_{\pi_0} \xrightarrow{\text{改善}} \pi_1 \xrightarrow{\text{评价}} v_{\pi_1} \xrightarrow{\text{改善}} \cdots$$

实际以数值容差停止评价时，V **只是近似**值。此时动作未变表示它对当前表贪心；最终误差还需用 **Bellman 残差判断**。

Sutton 与 Barto §4.3 和习题 4.4；Silver，第 3 讲。

价值迭代：每轮一次最优更新

策略迭代等待当前策略评价完成。价值迭代每轮直接比较动作，再更新一遍价值表：$V_{k+1} = T_* V_k$。**不必**为每轮维护一个已精确评价的策略。

1 输入准确模型、$0 \le \gamma < 1$、**要求的价值误差** $\varepsilon > 0$；**任取初表** V，**置** $V(G) = 0$。
2 **重复**：**先置** $W(G) \leftarrow 0$，**再**对每个非终止状态计算：
3 　$W(s) \leftarrow \max_a \sum_{s',r} p(s', r \mid s, a)[r + \gamma V(s')]$。　整轮读取旧表 V
4 　$\Delta \leftarrow \max_s |W(s) - V(s)|$，**然后** $V \leftarrow W$。
5 **直到** $\gamma\Delta/(1-\gamma) \le \varepsilon$。
6 **返回** V **和** $\pi(s) \in \arg\max_a \sum_{s',r} p(s', r \mid s, a)[r + \gamma V(s')]$。

$$\|V_k - v_*\|_\infty \le \gamma^k \|V_0 - v_*\|_\infty .$$

收缩性使误差反复缩小；第 5 行用上一轮改变量界定返回的新表的误差。最终策略另外从返回表向前看一步，选出贪心动作。

Sutton 与 Barto，§4.4；Silver，Value Iteration。本算法采用同步更新。

广义策略迭代：评价与改善的相互作用

评价使 V **接近当前策略的价**值；改善使策略对当前表贪心。策略一变，所要评价的行为也随之改变。



在有限折扣 MDP 中，两者共同稳定时，$V = v_\pi$ **且** $\pi \in \text{greedy}(V)$，**所以** $V = T_* V = v_*$。
对同一贪心策略做 $m \geq 1$ 轮评价，有

$$\pi_{k+1} = \text{greedy}(V_k), \qquad V_{k+1} = T^m_{\pi_{k+1}} V_k.$$

价值迭代	● ●	**一次**评价更新，立即重新贪心
部分策略迭代	● ● ● ●	**固定策略，做若干次**评价更新
策略迭代	● ● ● ● ● ●	**固定策略，求出它的价**值函数

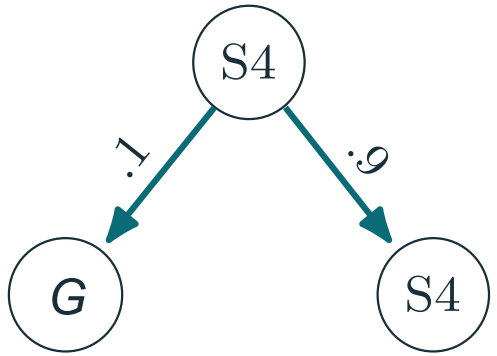
金色：选贪心策略　　**青色**：评价该策略　　（**点数**仅示意）

Sutton 与 Barto，§4.6；Silver，Modifed / Generalised Policy Iteration。图据原课程重绘。

模型期望与采样目标

在泥地 S4 始终向上。固定 $V(\mathrm{S4}) = .5$，$V(G) = 0$，$\gamma = .9$。

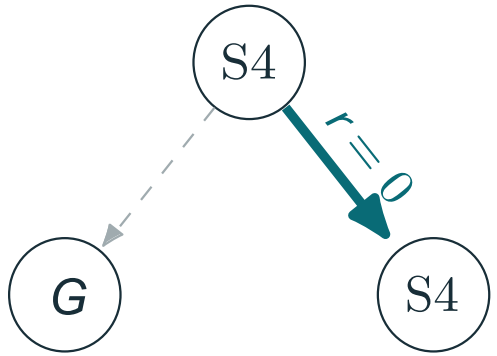
已知分布：列出所有后果



到站目标 1　　停留目标 $.9(.5) = .45$

$$\underbrace{.1(1) + .9(.45) = .505}_{\text{DP 对两个目标求期望}}$$

采到一个后果：留在泥地



到站目标 1　　停留目标 $.9(.5) = .45$

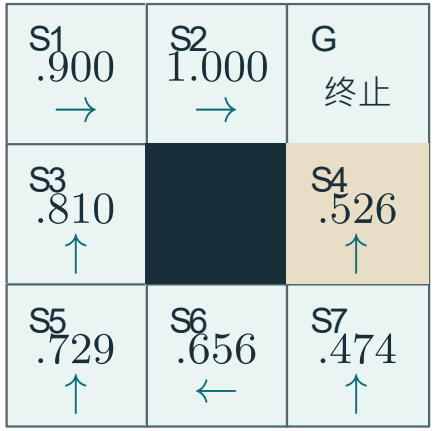
$$\underbrace{0 + .9(.5) = .45}_{\text{TD 使用实际分支}}.$$

$\mathbb{E}_\pi[R + \gamma V(S') \mid S = s, V] = (T_\pi V)(s)$. **若可指定格子和**动作调用模拟器，每次返回一个后果。真实交互须先走到该格。示范只提供走过的转移。

Sutton 与 Barto，**第一版 §9.5、§10.1**；**第二版 §8.1**。

策略改善改变了起点的动作

旧策略与价值



改善后的策略与价值



在旧策略下，起点向上的动作价值约为 $.474$，**向左**约为 $.590$。**把箭**头改向左后，重新评价新策略，得到**右**图。

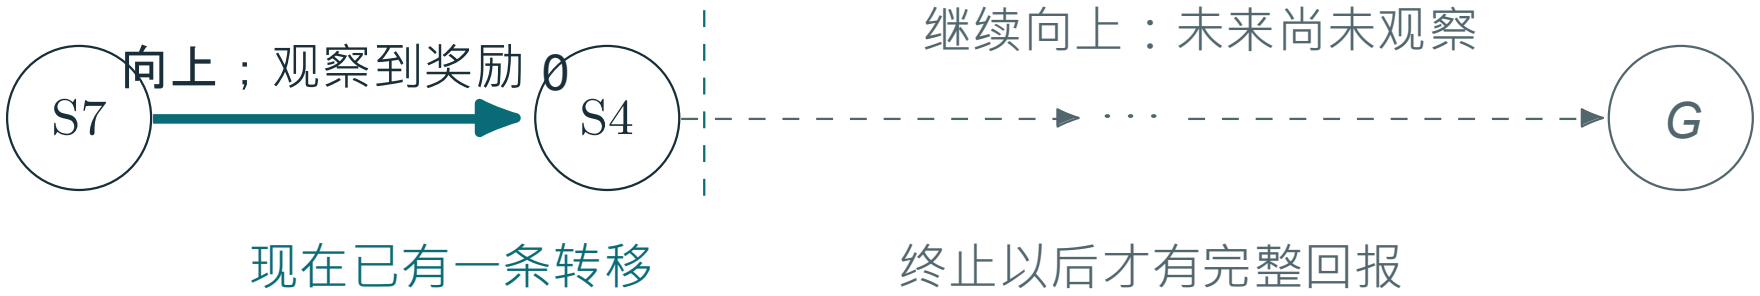
广义策略迭代 **先**评价当前策略，再按所得价值改善选择。下一轮评价改用新策略。

模型未知时，评价仍有相同的目标 v_π。**下一章固定策略，用**实际回报或一步转移估计它的价值。随后再**用**动作价值改善选择。

Sutton 与 Barto，**第一版** §4.6，Generalized Policy Iteration；**泥地价**值由给定模型计算。

第 4 章　Monte Carlo 与时序差分预测

固定泥地上始终向上的策略 π。**学**习器能读到沿途的状态和奖励，泥地成功率未知。目标是估计从每个**状**态出发、继续按 π **行**动的期望回报 $v_\pi(s)$。

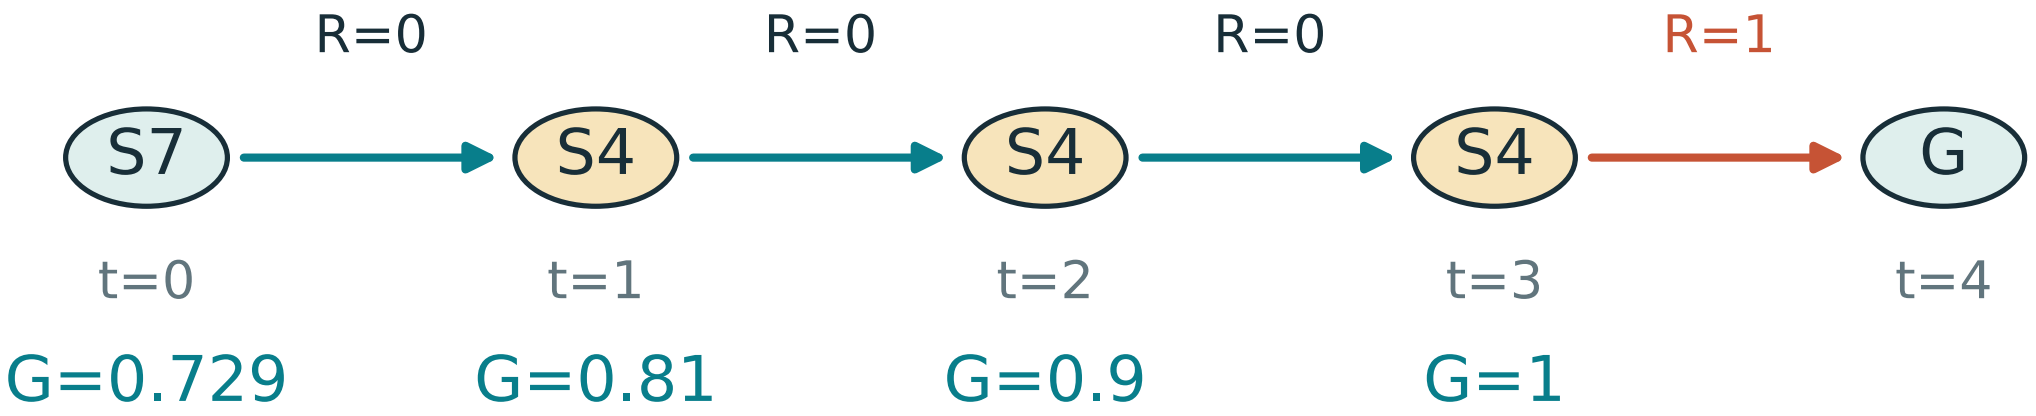


到终点得 1，**其余**奖励为 0，$\gamma = .9$。图中刚到 $\mathrm{S4}$。**此**时怎样给出发点 $\mathrm{S7}$ **构造学**习目标？

Monte Carlo 等到终点，用这趟完整回报更新。**一步 TD** 现在就能更新，用 $0 + .9V(\mathrm{S4})$ **估**计余下收益。

Sutton 与 Barto §5.1、§6.1；**同一泥地任**务。虚线为尚未观察的后续过程示意。

同一回合中的四次转移



沿这次行程，$S_1 = S_2 = S_3 = \mathrm{S4}$。下标表示时间，地图上的 S4 表示同一块泥地。

每次转移提供一个奖励；回合终止后，每次访问之后的完整回报均可计算。

Sutton 与 Barto，Reinforcement Learning: An Introduction；本课泥地算例。

首次访问Monte Carlo 预测算法

输入固定策略 π、折扣 γ 与回合数 B。初始化 $V(s)$ 任意，$N(s) = 0$；策略下回合终止，回报可积。

对每个回合$b = 1, \ldots, B$：
  从任务起始分布取 S_0，按 $A_t \sim \pi(\cdot|S_t)$ 交互，记录完整回合 $S_0, A_0, R_1, S_1, \ldots, A_{T-1}, R_T, S_T$；$S_T$ 为真正终止状态。
  令 $G \leftarrow 0$；对 $t = T-1, T-2, \ldots, 0$：
    $G \leftarrow R_{t+1} + \gamma G$，保存 $G_t \leftarrow G$。
  令已见集合 $\mathcal{S}_{\text{seen}} \leftarrow \varnothing$。
  对 $t = 0, 1, \ldots, T-1$：
    若 $S_t \notin \mathcal{S}_{\text{seen}}$：
      $N(S_t) \leftarrow N(S_t) + 1$。
      $V(S_t) \leftarrow V(S_t) + [G_t - V(S_t)]/N(S_t)$。
      $\mathcal{S}_{\text{seen}} \leftarrow \mathcal{S}_{\text{seen}} \cup \{S_t\}$。

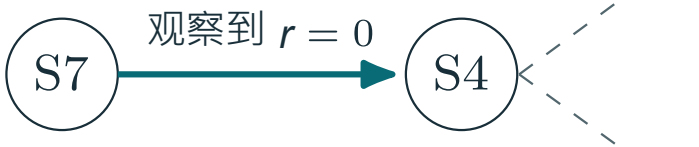
回报逆序计算，首次访问按实际时间步回合每状态只纳入最早访问；未访问状态保留初值。四步回合首次纳入时，$V(\mathrm{S7}) = .729$，$V(\mathrm{S4}) = .81$。

Sutton 与 Barto §5.1，First-visit MC prediction；实现：demos/sample14_mctd.py，mc_first_visit()。

一步 TD 的自举目标

固定平稳策略和马尔可夫状态。回报满足 $G_t = R_{t+1} + \gamma G_{t+1}$。给定后继状态，后续回报的条件均值为 $v_\pi(S_{t+1})$，因此

$$v_\pi(s) = \mathbb{E}_\pi[R_{t+1} + \gamma v_\pi(S_{t+1}) | S_t = s].$$



等到终点 完整回报可能为 $.9,\ .81,\ .729, \ldots$

等待时间取决于后来在泥地停留了几步。

现在更新 用表中 $V_t(\mathrm{S4}) = .5$ **代替未来回报**。

两种方法使用同一条已经观察到的转移。

TD(0) 用实际的 (R_{t+1}, S_{t+1}) 采样外层期望，用当前估计 V_t 近似真值：

$$Y_t = R_{t+1} + \gamma V_t(S_{t+1}) = .45, \qquad V_{t+1}(S_t) = V_t(S_t) + \alpha[Y_t - V_t(S_t)].$$

在这一步，最初的奖励总是 0，后继总是 S4。由于 $v_\pi(\mathrm{S4}) = 10/19$，表值 .5 偏低，目标 .45 也低于 $v_\pi(\mathrm{S7}) = 9/19$。

Sutton 与 Barto《强化学习》§6.1；Silver，Model-Free Prediction。终止时后继价值取零。

TD(0) 预测

输入固定策略 π、γ、步长 $\alpha > 0$ 与回合数 B。初始化非终止状态的 $V(s)$；终止值固定为 0。

```
对每个回合 b = 1, ..., B：
    从任务起始分布取非终止状态 S。
    重复，直到真正终止：
        按 A ~ π(·|S) 执行动作，收到奖励 R 与后继状态 S′。
        从更新前的同一张表读取 v ← V(S)。
        若 S′ 终止，令 u ← 0；否则令 u ← V(S′)。
        δ ← R + γu − v。
        V(S) ← v + αδ。
        S ← S′。
```

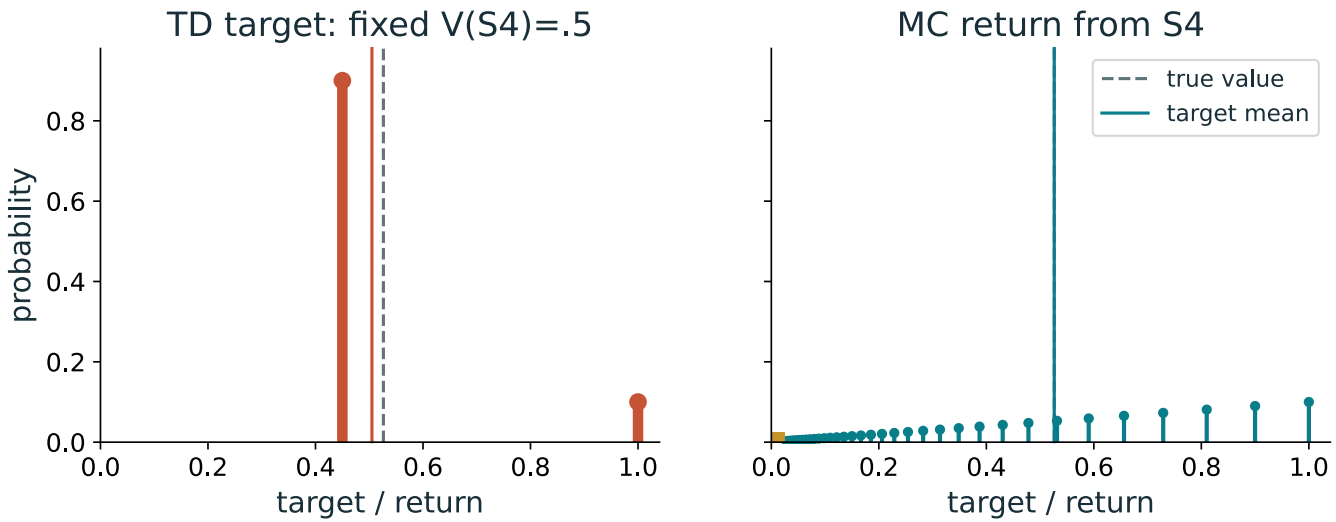
每条真实转移后立即写入自环时当前值和尾值都先读后写；真正终止只令尾值为 0，**最后**奖励仍进入目标。

若记录在回合中途截断，最后一个真实后继状态仍有尾值。

Sutton 与 Barto §6.1，Tabular TD(0)；实现：demos/sample14_mctd.py，td_step()。

MC 回报与TD 目标：均值和方差

在固定 $V(\mathrm{S4}) = .5$ 时，TD 目标方差较小，同时含有尾值估计带来的偏差。



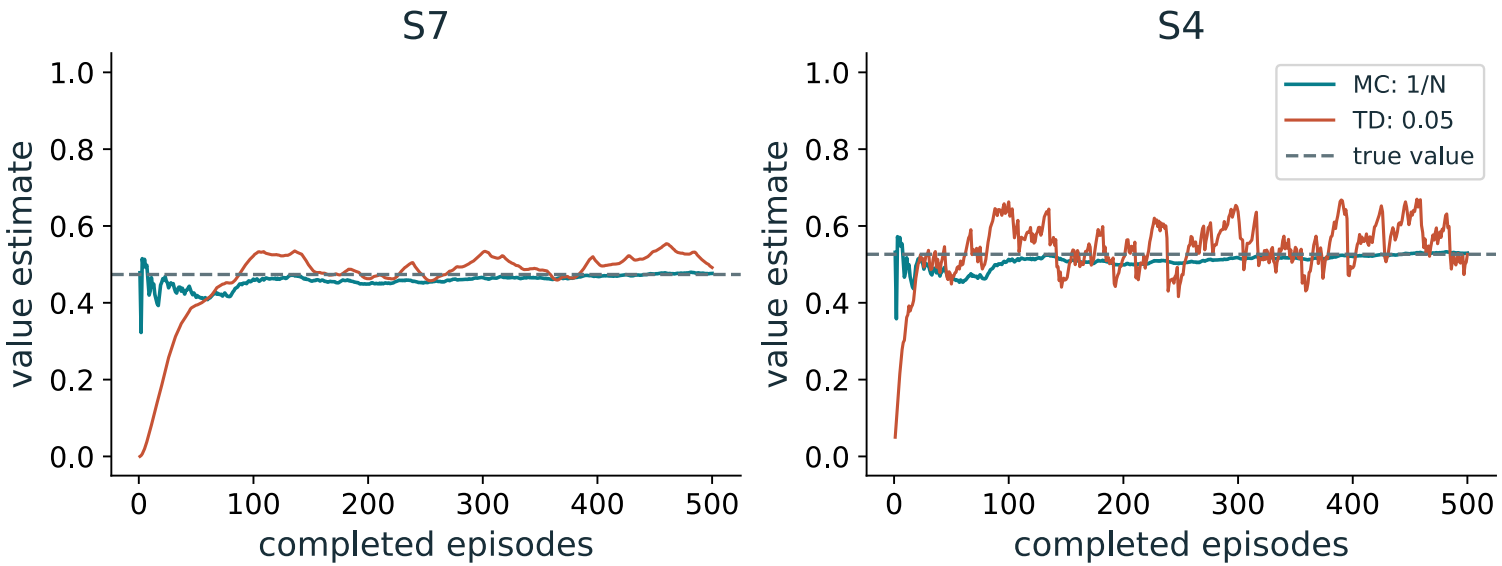
$\mathrm{S4}$，固定 $V(\mathrm{S4}) = .5$	目标均值	目标方差
TD：一次奖励与尾值	$.505$	$.027225$
MC：完整回报	$10/19 \approx .5263$	$\approx .091995$

随 $V(\mathrm{S4})$ 改变，TD 目标的均值和方差都会变。完整回报的分布由固定策略和环境决定。

Sutton 与 Barto，Reinforcement Learning: An Introduction；本课泥地算例。

Monte Carlo 与 TD 的学习曲线

样本平均逐渐平滑，固定步长 TD 持续波动。两者都在估计同一固定策略的价值。



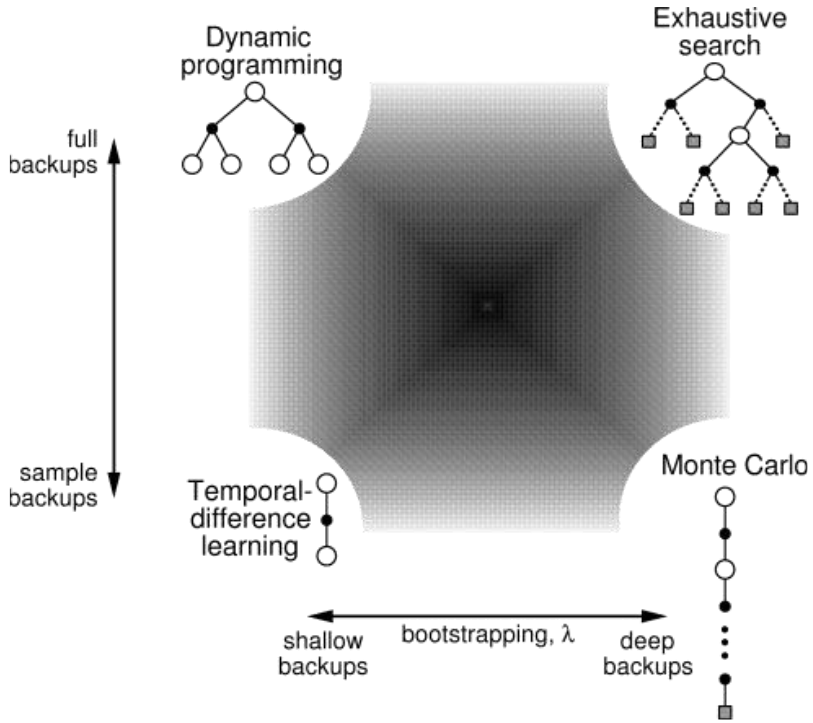
MC 的步长 $1/N(s)$ 随访问次数减小，新回报对均值的影响也减小；TD 使用固定 $\alpha = .05$，新转移持续修正预测，采样噪声也持续进入。

同批 500 回合、零初值、seed 7；每点取回合末。

Sutton 与 Barto：《强化学习》；本课固定策略预测实验

同一个状态价值，四种计算回报的方法

固定策略 π 和起始状态 s，要估计的始终是 $v_\pi(s) = \mathbb{E}_\pi[G_t \mid S_t = s]$。图中每棵树的根都是这次更新的起点。



左右看：在第几步使用已有估计

左列只展开一步，用后继价值补足以后的奖励。右列一直展开到终止，以后没有奖励，尾值为零。

上下看：一次计算包括哪些后果

下排沿一条采样轨迹计算。上排借助模型，按策略和环境的概率加权全部分支。

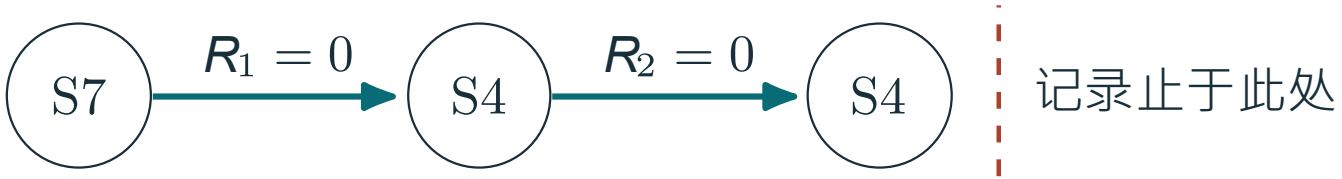
右上角逐条枚举到终点。它说明为什么已知模型时也值得自举：一步动态规划能重复利用后继状态已经算出的价值。

同一条轨迹可产生多种目标。一步 TD 在第一步自举，n 步 TD 推迟自举，回合式 MC 用完整回报。

Sutton 与 Barto，《强化学习》第一版，§10.1，图 10.1 原图。空心圆为状态，实心点为动作，方框为终止。

任务期限与采样截断的回报

智能体连续两次向上。第二步仍陷在泥地里。相同的两条转移，在两种任务约定下有不同的用途。



任务只计两步奖励

期限已满，$v_{\pi,0}(\mathrm{S4}) = 0$。**本次从** S7 **出**发的完**整回**报已经确定：

$$G_0 = R_1 + \gamma R_2 = 0.$$

若同一条轨迹下一步就抵达 *G*、**得**奖 1，**完整回**报是 $.9^2 = .81$。.405 则包含对余下回报的预测。即使采**集器随即重置**，这项预测仍取自重置前最后到达的 S4。

任务仍持续到抵达*G*

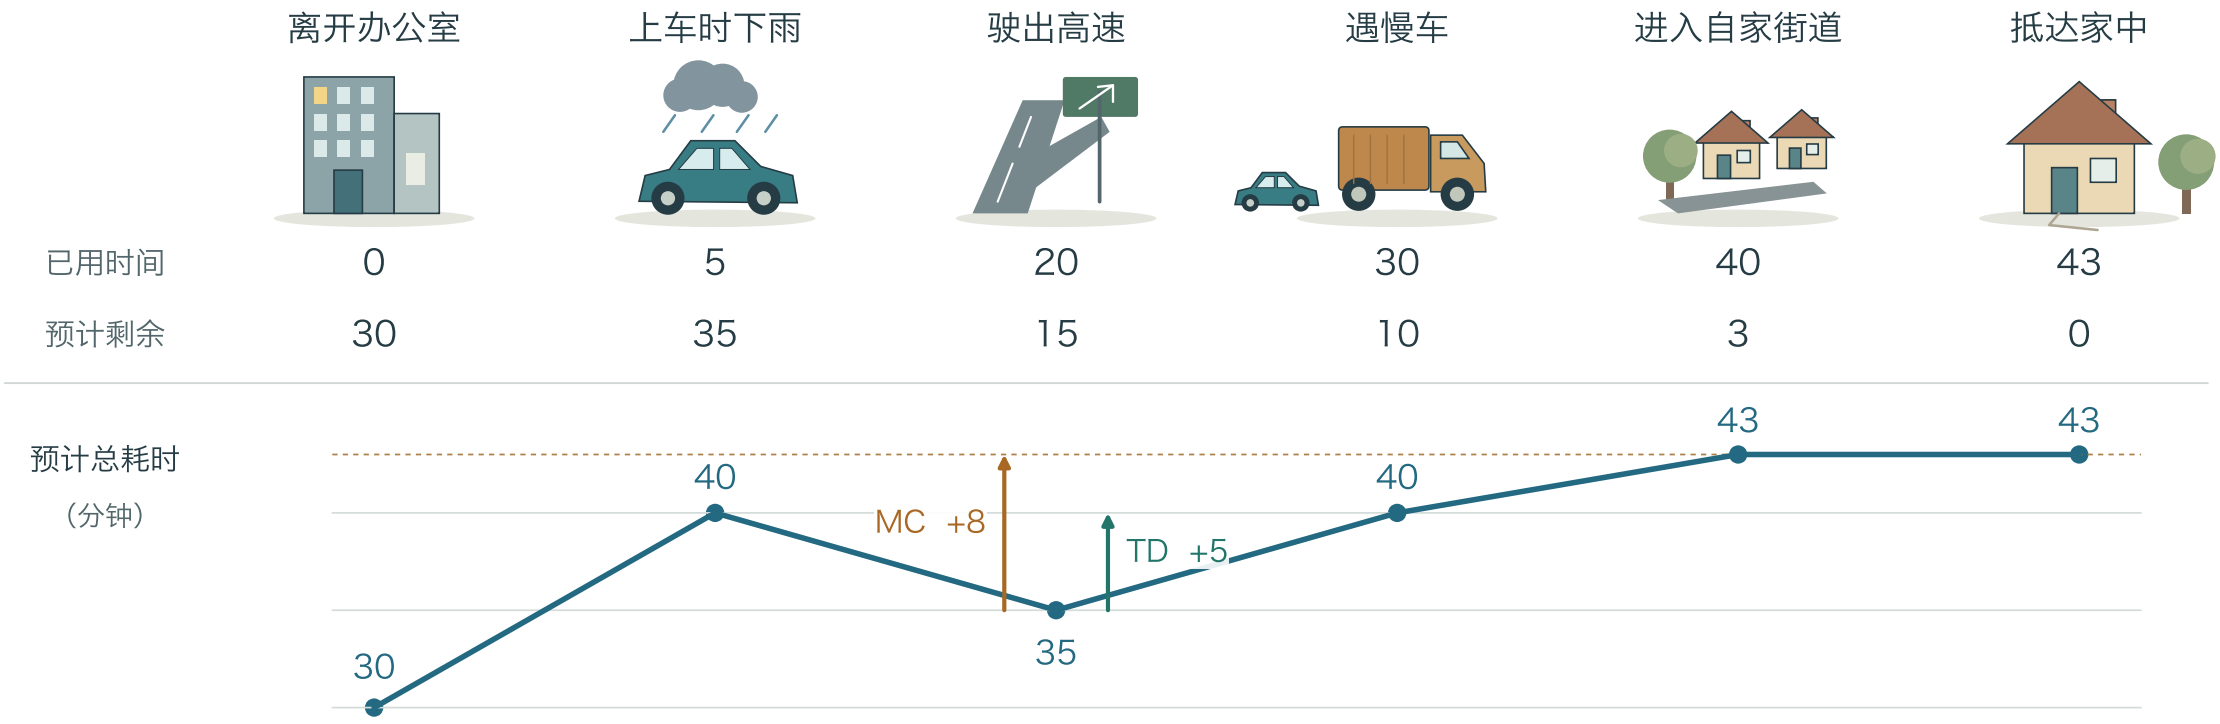
两步只是一段记录。用当时的估计 $V(\mathrm{S4}) = .5$，$\gamma = .9$，**两步目**标为

$$R_1 + \gamma R_2 + \gamma^2 V(\mathrm{S4}) = .405.$$

Sutton 与 Barto，§§3.3、6.1、7.1；Pardo 等（2018），部分回合末的自举。

开车回家：同一预测的两种更新目标

每段用时作为奖励，$\gamma = 1$。*V* **估**计剩余分钟数。图中折线是已用时间加 *V*。

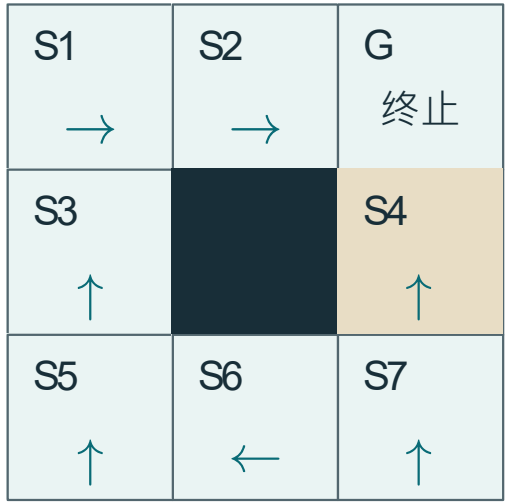


高速出口预计还需 **15 分**钟。10 **分**钟后遇慢车，预计还需 10 **分**钟，TD **目**标为 $10 + 10 = 20$（误差 $+5$）。**到家后**，MC **目**标为 $43 - 20 = 23$（误差 $+8$）。**若**还要选择路线，就需比较动作价值。

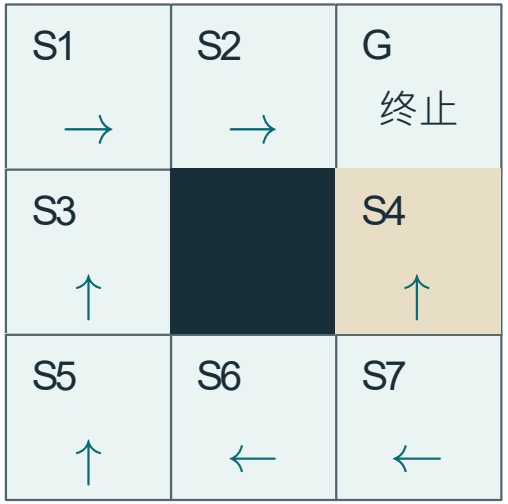
Sutton **与** Barto《强化学习》第二版，例 6.1、图 6.1，pp.122–123。**按原**书行程表重绘。

泥地成功率未知。智能体能选动作，随后看到实际奖励和下一格。现在要靠这些转移比较起点的两个动作，**改**进选路策略，提高从起点出发的期望折扣回报。

旧策略：经泥地



待比较的改善：绕行

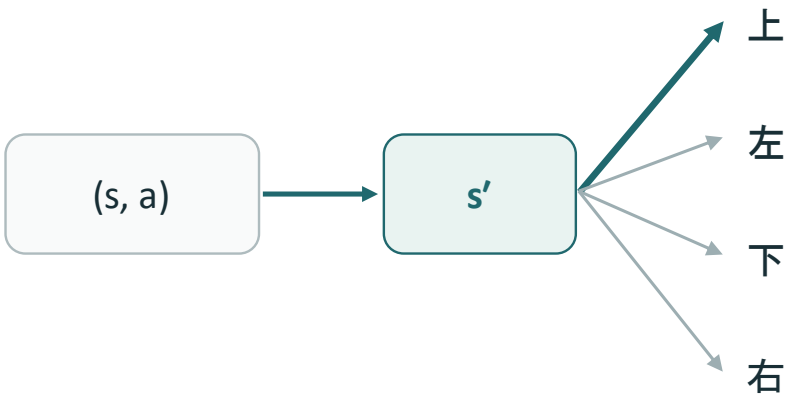


要学哪个后续策略的价值？**SARSA** 读下一格实际选中的动作，把探索也计入估值。**Q-learning** 读下一**格最大的**动作估值。两者都只能从行为策略实际走过的转移学习。

Sutton 与 Barto §6.4–6.6；**同一泥地控制任**务。Q **是**动作价值估计。

Sarsa：随实际后继动作自举

同策略控制要学习按当前行为策略继续行动的后果。



在后继状态按当前策略抽一个动作

观察转移

在 S7 向上，得到奖励 0，来到非终止状态 S4。

选择下一步

按当前行为策略在 S4 抽一次动作 A′。若抽到向上，读取 Q(S4, 上) = 0.5。

更新再执行

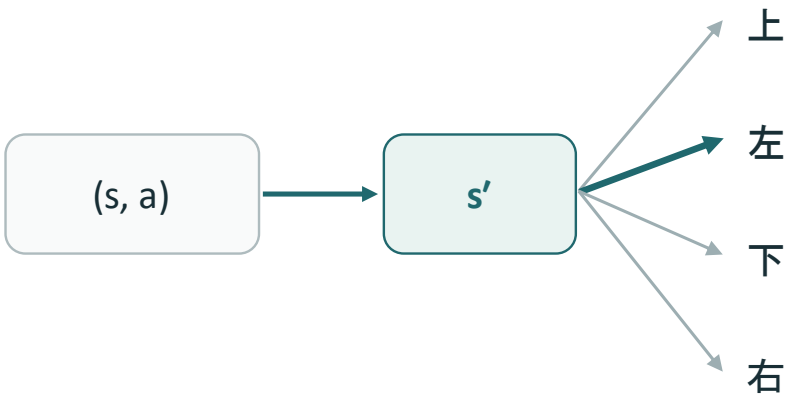
用目标修正 Q(S7, 上)，接着执行刚抽到的 A′；到终点时只用末次奖励。

$$Y = R + \gamma\, Q(S', A') = 0 + 0.9 \times 0.5 = 0.45$$

同一次抽样决定了自举目标，也决定了下一条真实转移。

Q-learning：以贪心后继为目标

同一个起点动作、同一次零奖励，改用当前估值最高的后继动作。



在后继状态比较四个动作的估值

条件已给定

观察 S7 向上到达 S4 的真实后果。在同一 MDP 中，给定状态动作后的环境规律相同。

查后继动作

S4 的四项估值中，向左最高，为 0.7。用它计算目标并更新起点的表项。

继续探索

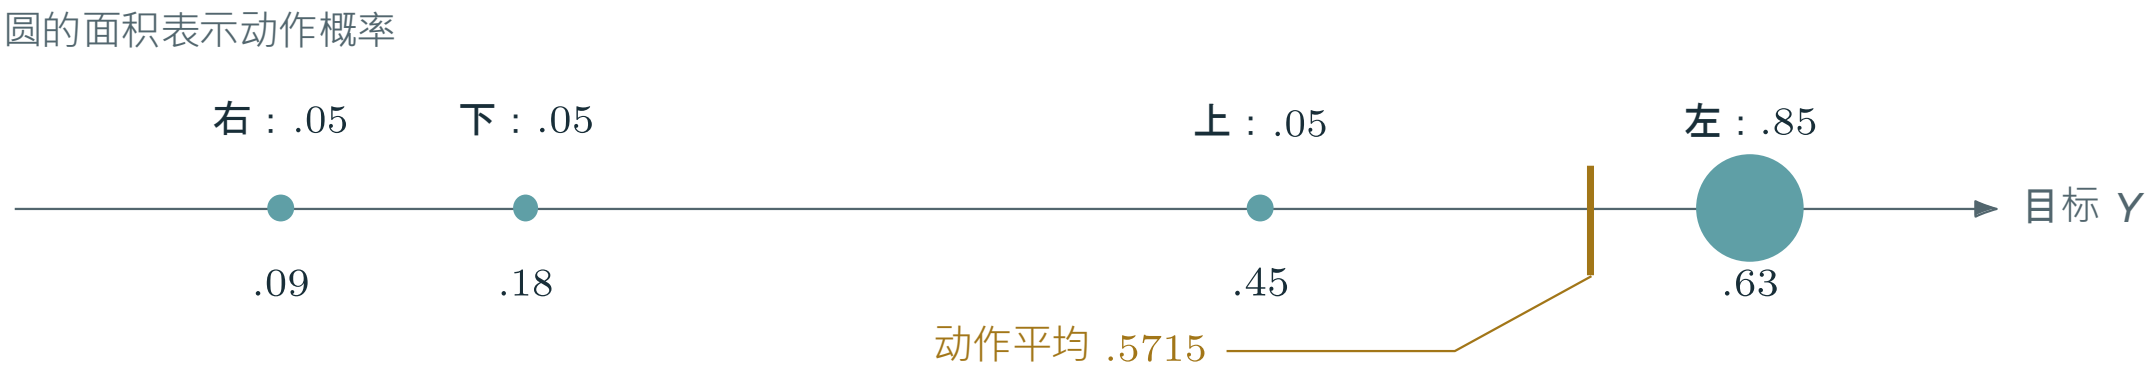
行为策略随后在 S4 选动作。若到达终点，尾值取零。

$$Y = R + \gamma \max_a Q(S', a) = 0 + 0.9 \times 0.7 = 0.63$$

目标已在下一次行动前算出，一步更新无需给下一动作乘概率比。

Expected SARSA 的动作平均

固定本次更新的 Q 和策略 π。已观察到 $\mathrm{S7} \to \mathrm{S4}$，奖励为 0。若下一动作按 π 采样，SARSA 的目标 $Y = 0 + .9\,Q(\mathrm{S4}, A')$ 有四种取值。



Expected SARSA 对这四个可能动作取期望：

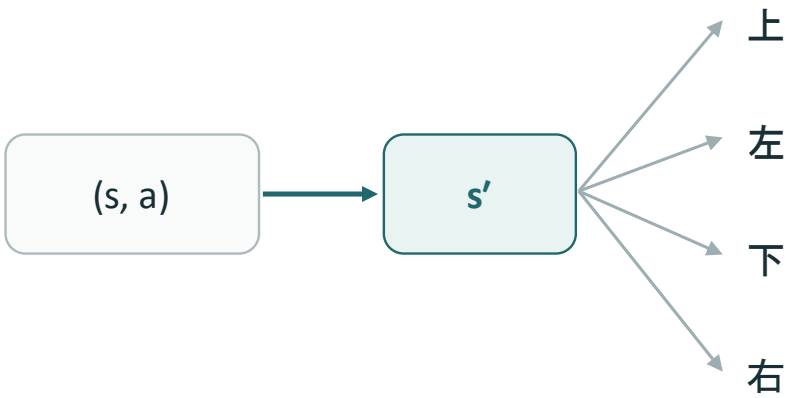
$$\underbrace{R_{t+1} + \gamma \sum_{c} \pi(c \mid S_{t+1}) Q(S_{t+1}, c)}_{\text{Expected SARSA 的更新目标}} = .05(.09 + .18 + .45) + .85(.63) = .5715.$$

给定本次奖励和后继状态动作平均消除了下一动作的抽样方差。奖励和后继状态仍由环境抽样；执行策略仍可继续探索。

Sutton 与 Barto《强化学习》§6.6。图中 π 是对四个动作作均匀探索的 .2-贪心策略。

一步离策略控制与轨迹评价

同一条经验记录，可以用来构造一步最优性目标，也可以用来评价给定策略。



取最大值，或沿实际选择的分支继续

一步 Q-learning

给定当前状态和动作，观察奖励和后继。在后继状态对可选动作取**最大**值。

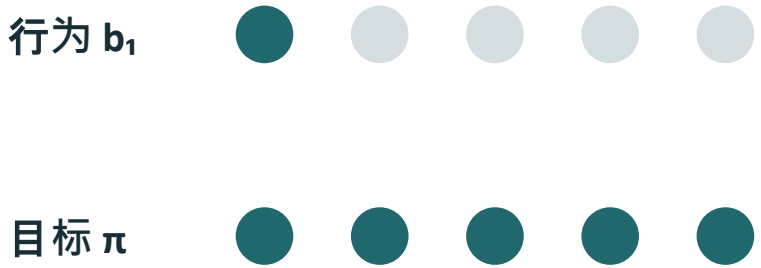
沿轨迹评价 π

采用后续实际奖励时，后续动作由行为策略 b 选择。它们在目标策略 π **下可能有不同的出**现频率。

一步最优性目标没有采样下一动作。使用一段行为轨迹评价另一策略时，动作分布才进入校正。

行为策略、目标策略与覆盖

目标策略 π 总在 S7 向左。离开起点后，两位驾驶员的走法都与目标相同。



每个实心点表示一次左行（比例示意）

行为 b_0 总向上

不论增加多少回合，记录里都没有左路的后果。

行为 b_1 也试左路

约五趟里有一趟向左。左路的后果有机会出现在真实记录中。

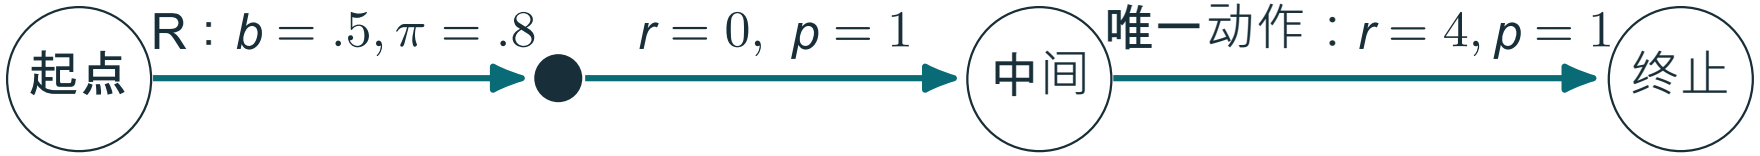
$$\pi(\text{左} \mid S7) = 1 \qquad b_0(\text{左} \mid S7) = 0 \qquad b_1(\text{左} \mid S7) = 0.2$$

想用行为数据评价目标策略，目标可能选择的动作必须有机会被行为选到。

轨迹的重要性采样比率

在同一环境中，轨迹概率比等于各步动作概率比的乘积。

$$\frac{\Pr_\pi(\tau \mid S_t = s)}{\Pr_b(\tau \mid S_t = s)} = \frac{\prod_{k=t}^{T-1} \pi(A_k|S_k)\, p(S_{k+1}, R_{k+1}|S_k, A_k)}{\prod_{k=t}^{T-1} b(A_k|S_k)\, p(S_{k+1}, R_{k+1}|S_k, A_k)} = \rho_{t:T-1}.$$



该路径 $\rho = (.8/.5)(1) = 1.6$，取 $\gamma = .9$，回报为 3.6

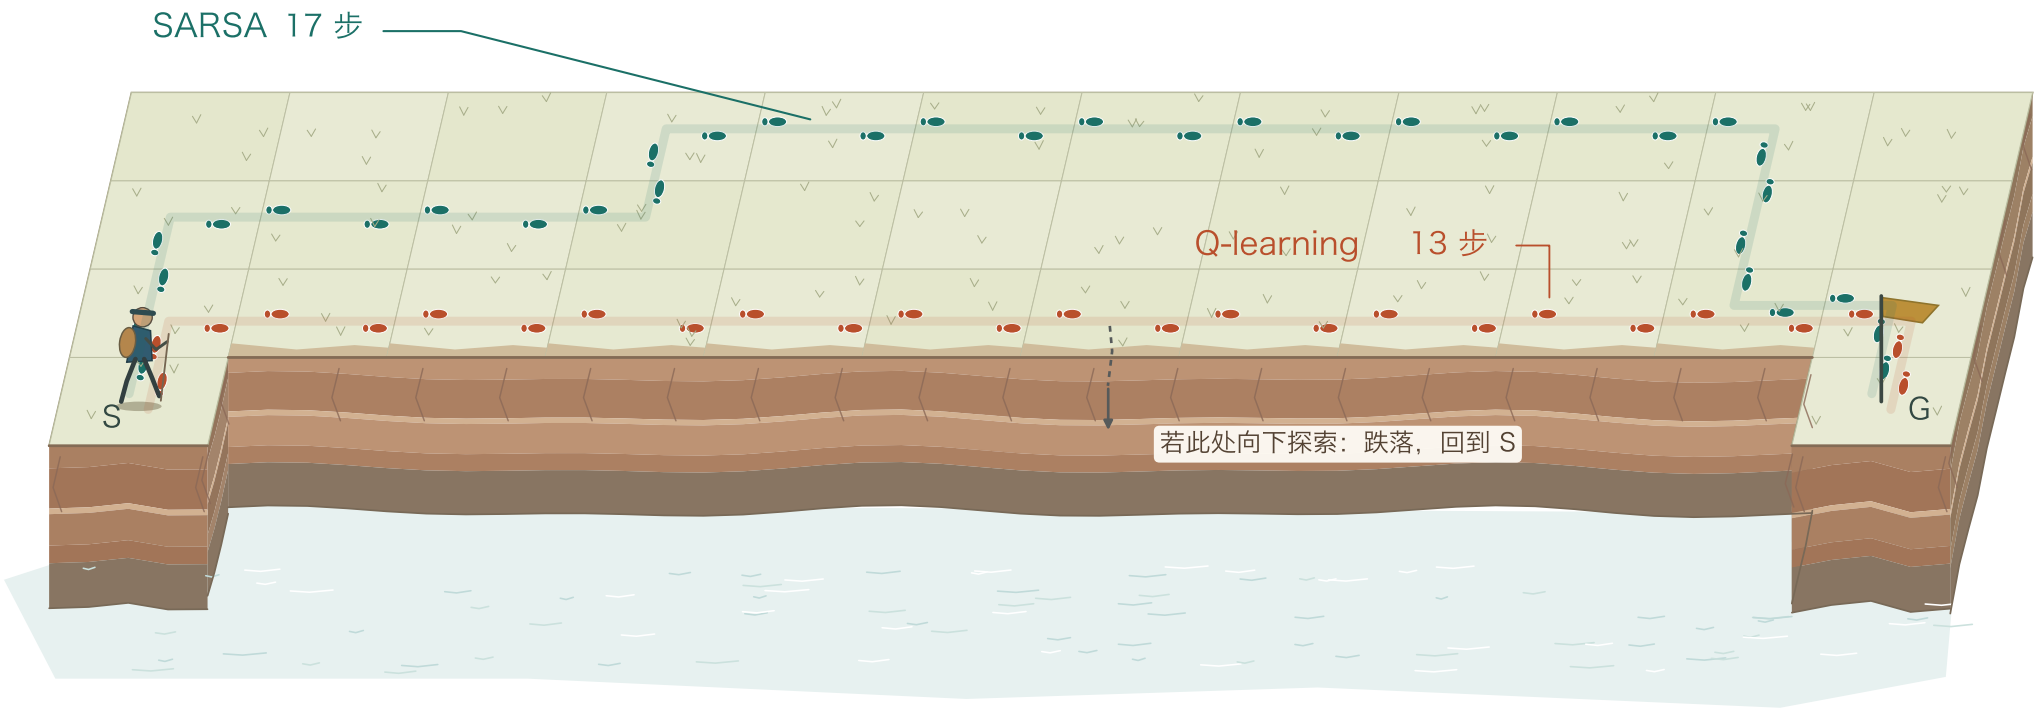
$$\boxed{\rho_{t:T-1} = \prod_{k=t}^{T-1} \frac{\pi(A_k|S_k)}{b(A_k|S_k)}}.$$

估计 $v_\pi(s)$ 时，首动作由策略抽取，比率从 t 起。估计 $q_\pi(s,a)$ 时，首动作已给定，比率从 $t+1$ 起。在目标策略可达的后续状态，行为策略须覆盖目标策略可能选的动作。

Sutton 与 Barto：《强化学习》§5.5，式 (5.3)–(5.4)

悬崖行走：两条学得的贪心路线

训练 500 回合后冻结 Q 表。足迹是贪心路线；虚线是一次可能的探索动作。

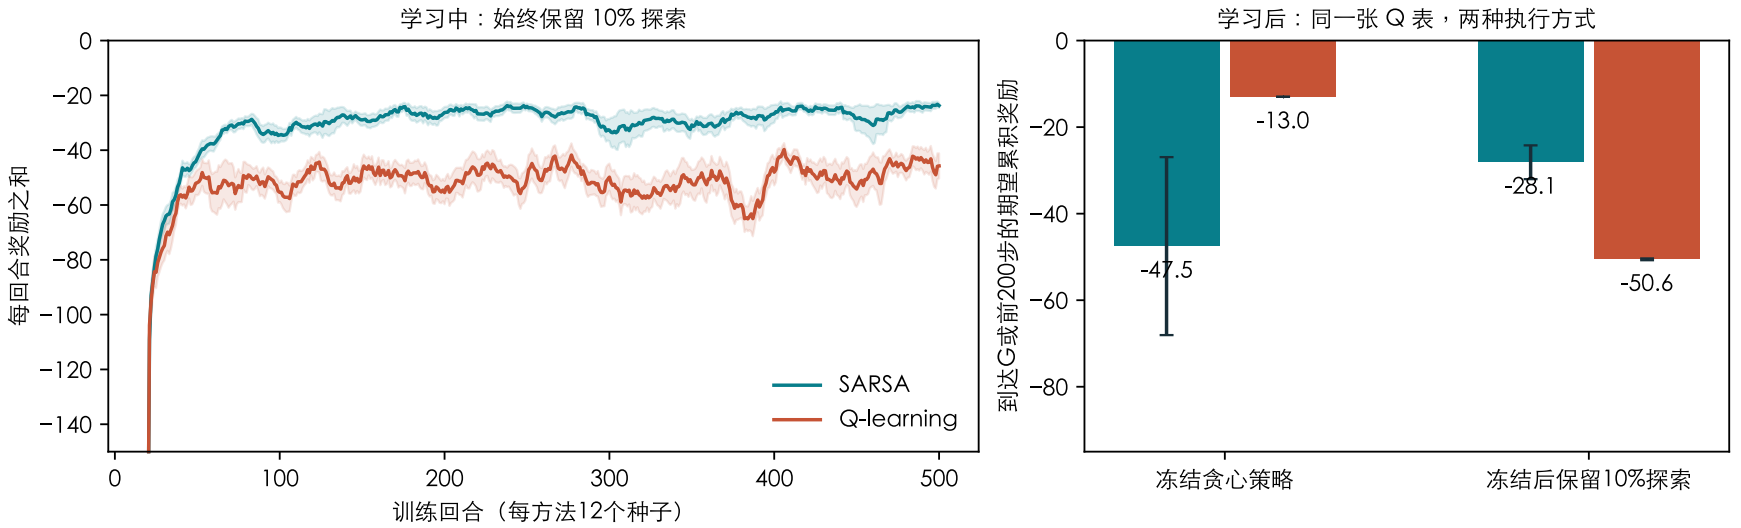


Q-learning 的路线经过 10 个临崖格，SARSA 的路线只经过 1 个。训练时 $\varepsilon = .1$，在这些格子即使贪心动作水平向前，仍有 $.1/4 = .025$ 的概率改向下走，跌落后得 -100 并返回起点。

任务见 Sutton 与 Barto《强化学习》例 6.6 及 Machado，CMPUT 365，第 19 页。路线为本课实验，种子 0，$\alpha = .5$，$\gamma = 1$。

悬崖行走：执行哪一种策略

临崖格的贪心动作若唯一且向右，取 $\varepsilon = .1$，行为向下的概率为 $.1/4 = .025$。实际执行的这一步，期望奖励为 $.975(-1) + .025(-100) = -3.475$；始终向右则为 -1。



学习时两种行为都探索。Sarsa 的目标包含继续探索的后果；Q-learning 以贪心行动作后续，实际落崖仍会收到 -100。

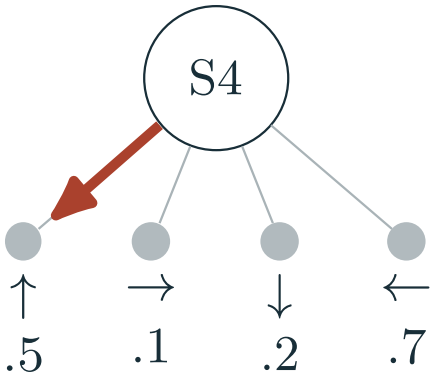
冻结后每张 Q-learning 表用两种方式执行，关掉探索时得 -13.0，保留时得 -50.6（到达 G 或前 200 步）。Sarsa 关掉探索后有 2 个种子循环，统计包含两者。

Sutton 与 Barto，例 6.6。本课 $\alpha = .5, \gamma = 1$，每法 12 个种子、各 500 回合。曲线取 20 回合滑动平均，误差为一个标准误。

同一条转移的三个控制目标

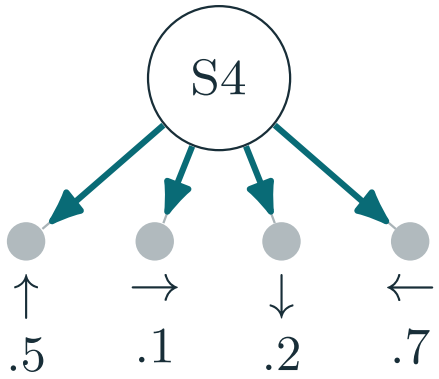
同一转移 $\mathrm{S7} \xrightarrow{\uparrow, 0} \mathrm{S4}$，$\gamma = .9$；给定 Q 表；　SARSA 与 Expected SARSA 的目标动作概率按上、右、下、左为 $.05, .05, .05, .85$。

SARSA



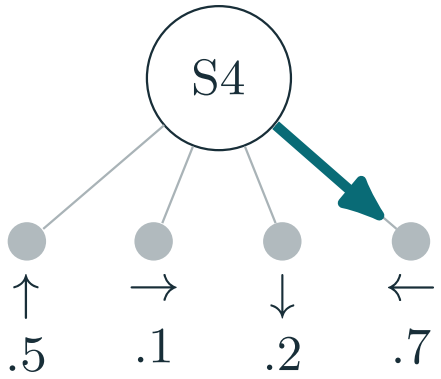
采得 ↑：$Y = .45$

Expected SARSA



对 π 平均：$Y = .5715$

Q-learning



取最大：$Y = .63$

三种算法都观察到同一个 $\mathrm{S4}$。区别在**后继动作的取法**：执行一次、按策略求平均、对估计值取最大。最大值可以直接查表，一步 Q-learning 因此无需给下一动作乘重要性比率。

行为仍要访问待学习的状态动作对。上述目标均只观察一步奖励。多步目标可将更远处实际取得的奖励纳入当前更新。

据 Sutton 与 Barto §§6.4–6.6、图 6.4 重绘。

第 6 章　多步方法与资格迹

固定向北走的策略 π，**只**观察一路经过的状态和奖励。要估计每个起点的期望回报 $v_\pi(s)$，**但**这趟直到第**四步才收到**奖励。



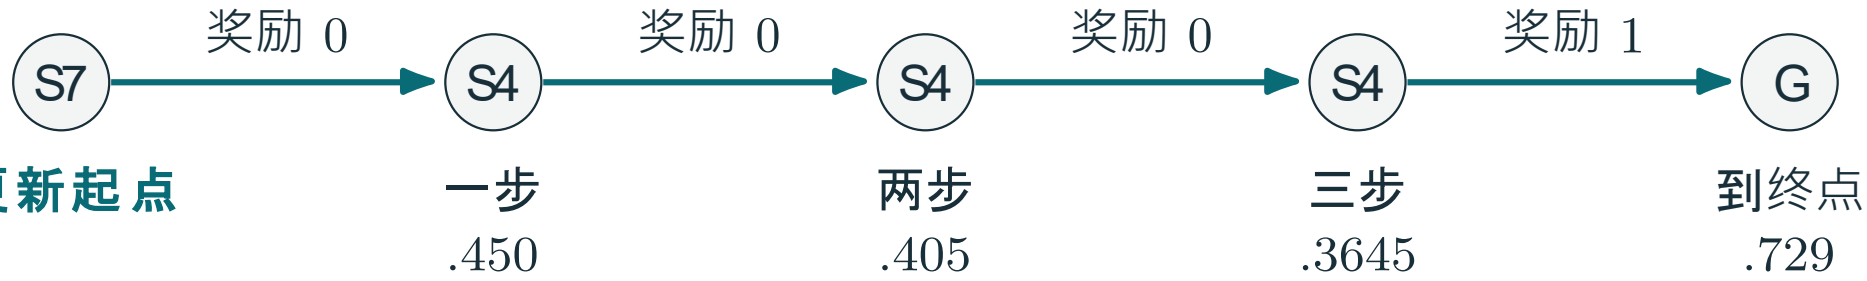
若初值全为零，第一步的 TD 目标是 $0 + \gamma V(\mathrm{S4}) = 0$。**四步后**，**同一次出**发的完整回报为 $\gamma^3 = .729$ $(\gamma = .9)$。

可以多等 n **步**，**用**这几步的真实奖励和末端的价值估计更新起点。也可以边走边留**资格迹**，让新到的误**差按衰减**权重更新先前访问过的状态。

Sutton 与 Barto《强化学习》第一版，§7.1。图中只画泥地地图的东侧一列；深色足迹标出本次位置。

n 步回报：实际奖励与尾部预测

固定策略、从 S7 出发的同一条记录和同一份价值表。只改变读到第几步：此前用实得奖励；若还未终**止，就从那一步的状**态接上预测。



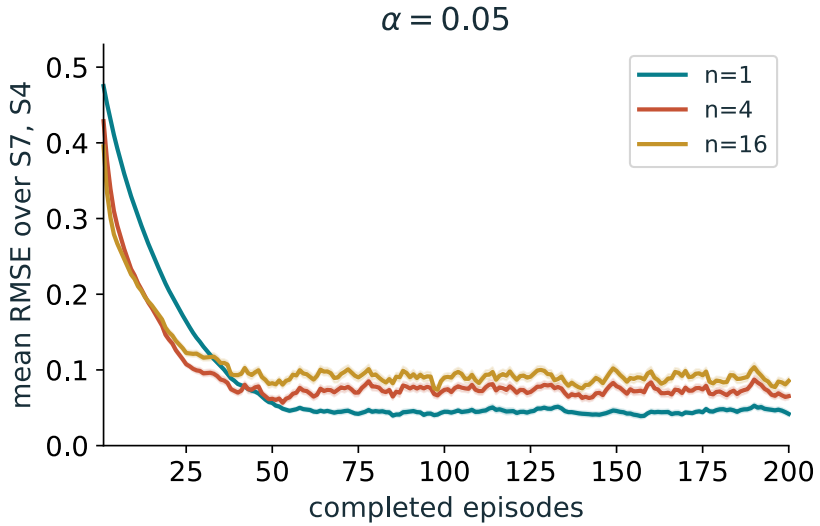
取 $\gamma = .9$、$V(\mathrm{S4}) = .5$。**两步目**标为 $0 + .9(0) + .9^2(.5) = .405$；**到**终点才停则得 $.9^3(1) = .729$，**无需尾**值。图中四个数都是 **S7 的目**标值。

***n* 步回报选一个深度 λ 回报混合这些深度。每向后延**长一步，剩余权重乘 λ；**抵达**终点时用完余下的权重。

Sutton 与 Barto，§7.1，图 7.1、式 (7.1)–(7.2)，§12.1。图为同一次泥地行程。

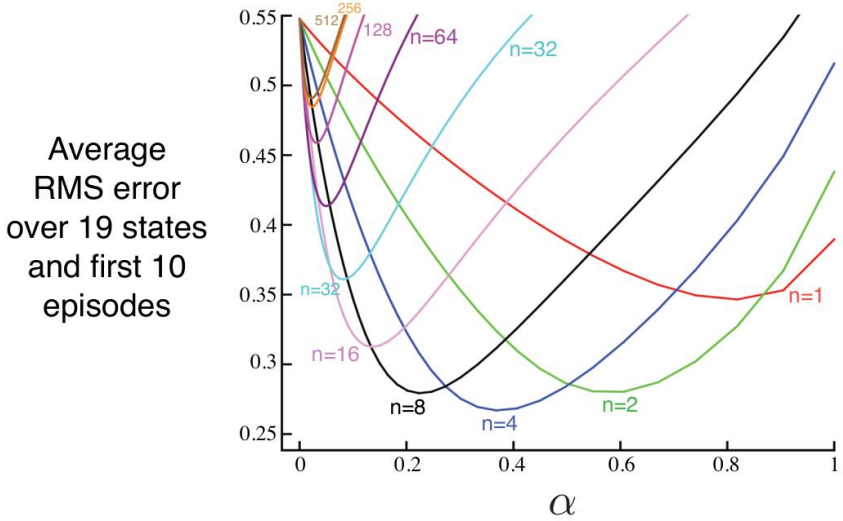
n 步 TD 的预测误差

固定步长，观察学习过程



本课泥地任务，$\alpha = .05$。第 10 回合，$n = 16$ 的误差低于一步 TD；到第 200 回合，次序相反。每条带表示 64 次运行的均值及一个标准误。

改变步长，比较早期误差



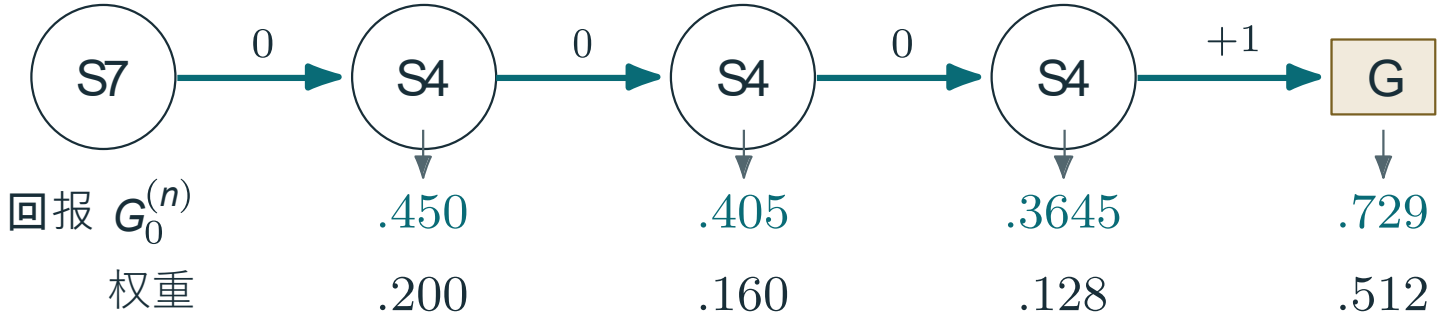
原书的 19 状态随机游走，两端奖励分别为 $-1, +1$。每条曲线固定 n，横轴为 α。在前 10 回合中，最低误差出现在中等的 n。

多看一步，会用一次新后果替换原来的尾值。如果尾值在可能的后继状态上相差很大，而后来的奖励几乎一样，目标方差甚至会下降。图中衡量的是多次更新后的预测误差它还取决于步长与数据量。

左：本课泥地实验，course15_traces.py。右：Sutton 与 Barto（2018），图 7.2，p.145。右图先对 19 个状态算 RMSE，再在前 10 回合和 100 次运行上取平均。

λ-回报：混合不同长度的目标

从 S7 进入泥格 S4，两次陷在原地，再到终点 G。前三步奖励为零，到 G 得 1。每到一次 S4，都能读它的预测来补足未来。**λ-回报把在不同步数自举的目标与完整回报加权平均。**



取 $\gamma = .9$，$\lambda = .8$，固定 $V(\text{S4}) = .5$。走一步，分出 .2 的权重给 $G_0^{(1)} = .9(.5)$；余下 .8 继续。到终点时，剩余 $.8^3 = .512$ 全部给实际回报 $.9^3(1)$，没有后继预测。

$$G_t^\lambda = (1-\lambda)\sum_{n=1}^{L-1}\lambda^{n-1}G_t^{(n)} + \underbrace{\lambda^{L-1}G_t}_{\text{距终点}L=T-t\text{ 步}} .$$

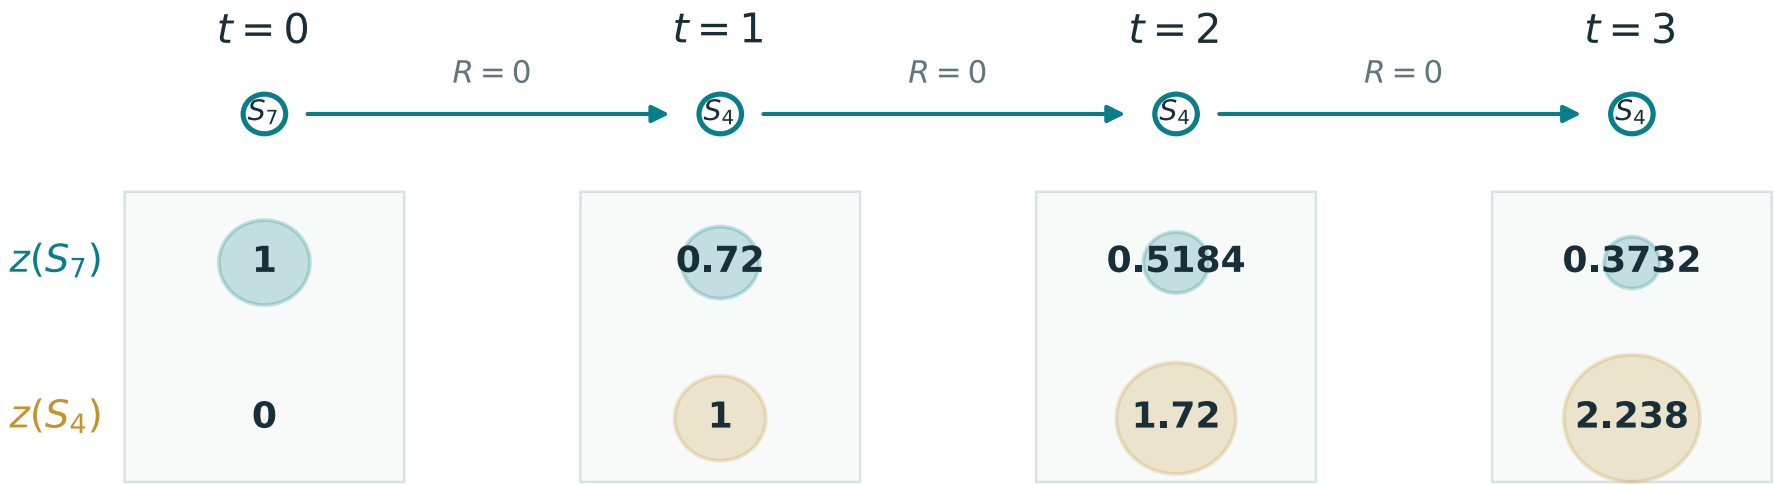
图中两行逐项相乘并相加得 $G_0^\lambda = .574704$。$\lambda = 0$ 给出一步 TD 目标；$\lambda = 1$ 给出整趟实得回报。

Sutton 与 Barto，§12.1，图 12.1–12.2；泥地行程程序，参数 --mix。

资格迹：衰减过去的权重，累加当前访问

资格迹 $z_t(s)$ **是状**态 s 历次访问在第 t **步的**总权重。把最近一次访问单独列出，

$$z_t(s) = \sum_{k=0}^{t} (\gamma\lambda)^{t-k} \mathbf{1}\{S_k = s\} = \underbrace{\gamma\lambda z_{t-1}(s)}_{\text{已有权重均衰减一次}} + \underbrace{\mathbf{1}\{S_t = s\}}_{\text{当前访问加 1}}, \qquad z_{-1}(s) = 0.$$



圆面积表示权重，$\gamma\lambda = .72$。**到** $t = 3$，S7 **的一次**访问只剩 $.72^3$；S4 连续出现三次，$z_3(\text{S4}) = .72^2 + .72 + 1 = 2.2384$。

Sutton 与 Barto §12.2。圆面积取自 course21_trace_visuals.py。

TD(λ)：一次误差如何更新过去的预测

当前转移产生一个 TD 误差。资格迹记录哪些状态刚访问过，以及每个状态应分得多大的更新。



同一 TD 误差 × 各状态的资格迹

读旧价值

用真正收到的奖励和后继的旧预测计算本步误差 δ。

记访问

所有迹乘 γλ 衰减，当前出发状态的迹加 1。**重复**访问会累积。

更新价值

每个状态按自己的迹乘同一误差。没有资格的状态在这一步保持原值。

$$\Delta V(s) = \alpha\, \delta_t\, e_t(s)$$

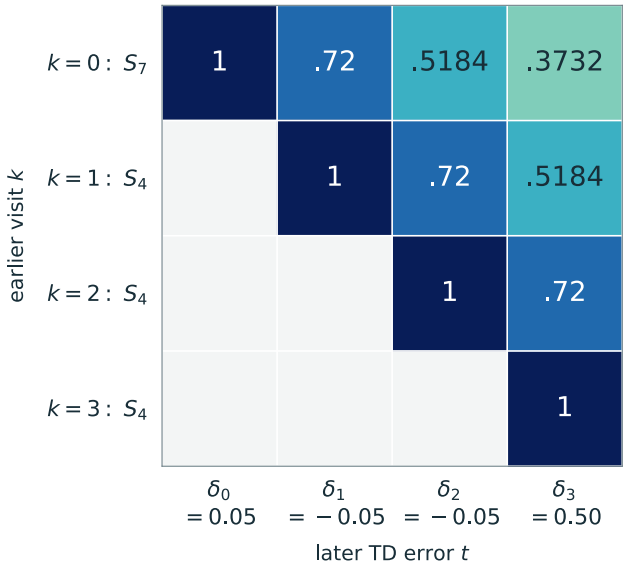
远处的奖励来到时，仍有资格的早期状态可以在同一步得到修正。

Sutton & Barto · §12.2

实验代码

多步目标与资格迹

一步 TD 很快得到学习目标，但远处的奖励须靠后续访问逐步传回。等待完整回报可以直接用到这个奖励，**更新却要等到回合**结束。



行对应先前的访问，列对应后来出现的 TD 误差。

向前看。从一次访问出发，*n* **步回**报指定用几步实际奖励。λ**-回**报给不同长度的目标分配权重。

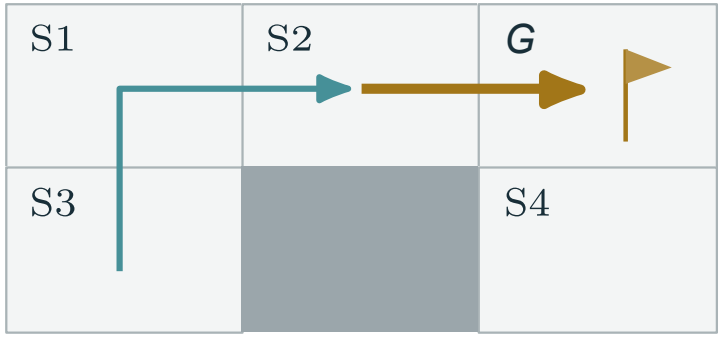
向后看。一个新的 TD 误差到达时，资格迹决定先前各**次**访问应得到多少更新。固定价值估计时，两种求和顺**序分配的是同一**组误差。

资格迹沿当前轨迹分配误差。规划可以查询过去走过的状态和动作，用模型预测更新价值。

Sutton 与 Barto，第 2 版 §§12.1–12.5；van Seijen 与 Sutton（2014）。

第 7 章　模型学习与规划

环境没有给出转移与奖励模型，真实行动次数有限。要找到起点期望折扣回报更高的路线，一条新经验**既可直接更新 Q，也可用来学**习动作的后果。



已存入模型的两段路
刚观察到的转移，奖励 $+1$

图中两段零奖励的路已经走过。现在从 S2 **向右首次到达** G，**得到**奖励 1。**直接做一步** Q-learning，**改**变的是 $Q(\mathrm{S2}, \rightarrow)$。

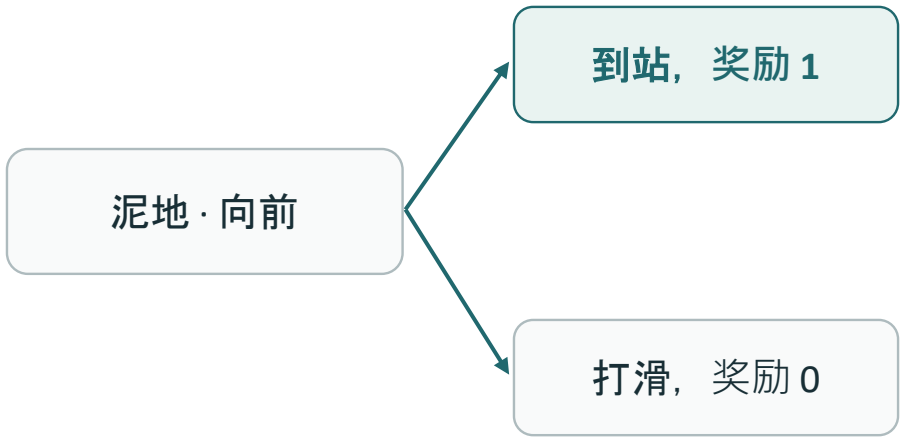
做一次规划时，可从先前走过的 S1 **向右**查询模型。若模**型**给出后继 S2，**便能用更新后的 Q 修正** S1 **的**动作估值，**无**须重走这条边。

每次实际行动后，**选哪些已见状态和动作、花几次计算查询模型**是规划的设计选择。已有模型能传播终点奖励；发现模型漏掉的新后果还需要真实经验。

Sutton 与 Barto《强化学习》第一版，§9.2，Dyna-Q。**泥地地**图北侧两行；终止后继的价值取零。

模型预测后果，价值评价后果

前面用一步真实转移更新动作价值。若同一个状态动作的后果可由模型生成，仍可使用相同的价值更新。



同一动作的两种可能后果

预测环境

由状态和动作预测奖励及后继。随机环境中需要能表示后果分布，或能按它采样。

预测回报

给定后继价值，将当步奖励与折扣尾值合并。模型相同，策略改变时价值仍可能改变。

一步目标 = 当步奖励 + 折扣 × 后继价值

动态规划直接查询给定模型；Dyna 从真实转移学习模型，再查询学得的模型。

从真实行动估计转移概率

在可反复从 $\mathrm{S4}$ 开始的试验中，每次向上一次。记 n 为真实尝试次数，m 为抵达 G 的次数。已有数据给出的成功概率估计为 $\hat{p} = m/n$。



前 10 次得到 $\hat{p} = 2/10$。把同一批记录读十遍，估计仍是 $2/10$。再执行六次动作并观察到六次失败，估计才变成 $2/16$。

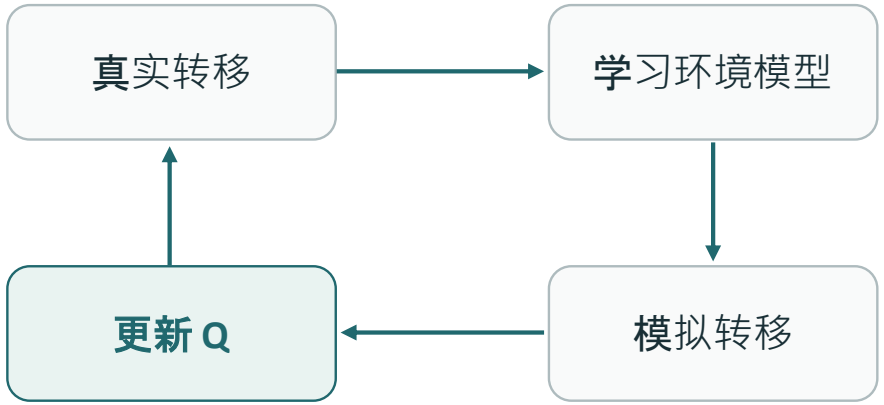
$$\hat{p}(s', r \mid s, a) = \frac{C(s, a, s', r)}{C(s, a)} \quad \text{（只对已试过的状态动作对有定义）。}$$

真实试验修正模型概率。在两次行动之间，规划按已有模型模拟后果。

Sutton 与 Barto，§§8.1–8.2。本课泥地原始记录，随机种子 2，图取时间顺序的前 16 次。

Dyna-Q：真实经验、模型学习与规划

第 11 次在泥地向上又打滑。一次真实交互供两处学习，随后可做 B 次规划。



真实转移也直接更新 Q

直接学价值

用真实奖励与后继更新 Q(S4, 上)。

修正环境模型

把这次失败记入真实频数。模型成功率从 2/10 变为 2/11。

利用模型规划

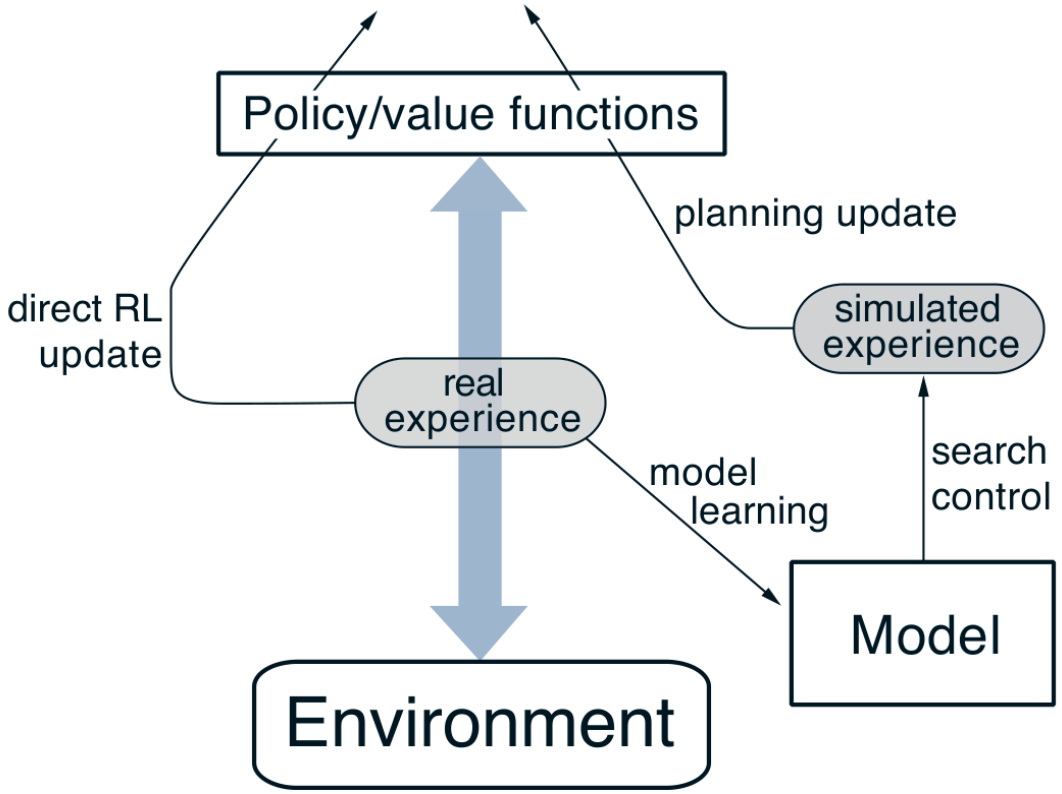
抽一个已试过的状态动作，从模型采一个后果，再用同一条 Q 更新式；可重复 B 次。

$$Q(s,a) \leftarrow Q(s,a) + \alpha[r + \gamma \max_{a'} Q(s',a') - Q(s,a)]$$

规划增加价值计算的次数；这轮结束后，真实泥地试验仍只有 11 次。

实验代码

Dyna 架构



Sutton 与 Barto：《强化学习》

真实转移一方面更新动作价值，另一方面修正后果模型。模型随后提供模拟转移，继续更新同一张 Q 表。

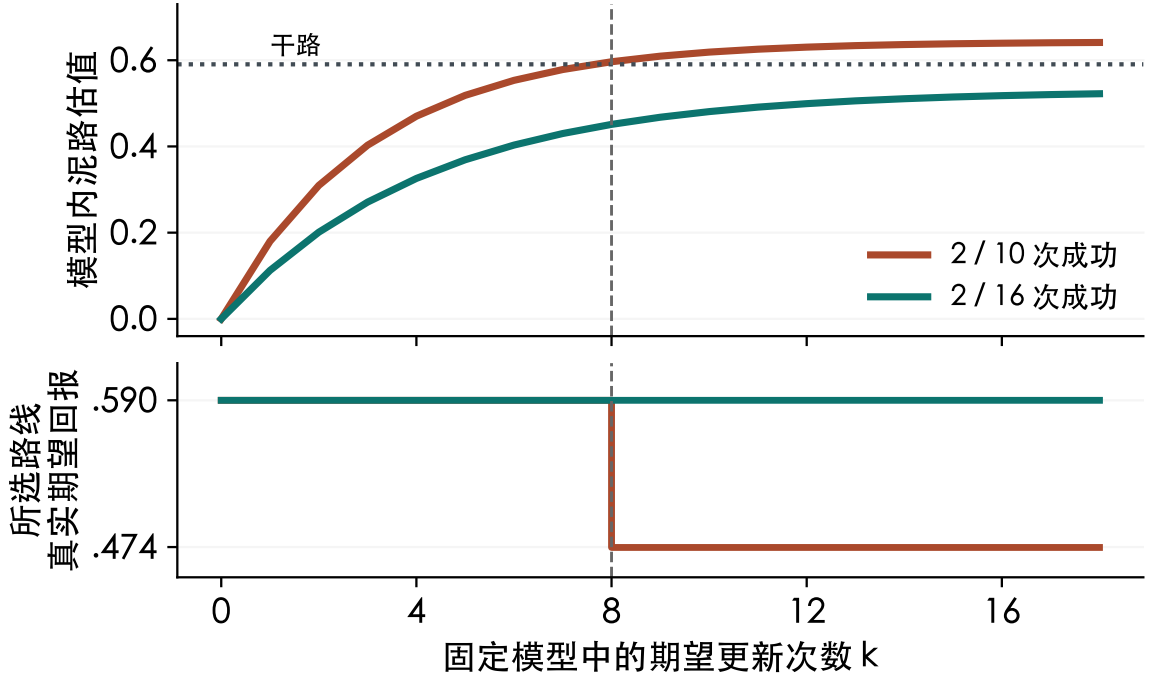
搜索控制指定从哪个 (s, a) 开始模拟。设记录中有两种状态动作对，分别出现 10 次和 1 次。

抽取规则	第一种	第二种
均匀抽已见的对	$1/2$	$1/2$
均匀抽经验记录	$10/11$	$1/11$

本课 Dyna 用第一种，后面 DQN 的均匀回放用第二种。同一批经验，额外计算花在了不同地方。

规划次数与路线选择

从 S7 出发，干路六步到 G，回报 $.9^5 = .59049$。泥路先走一步进入 S4，然后反复尝试向上。除泥地成功率 p 外，其余规律已知。



每次从 S4 开始试验。前十次成功两次，模型估计 $\hat{p} = .2$。固定它，从 $v_0 = 0$ 计算：

$$v_{k+1} = \hat{p} + (1 - \hat{p})\,.9 v_k.$$

从 S7 选泥路的估值为 $.9v_k$。第七次算得 $.5784$，第八次升到 $.5964$，超过干路。

规划改选泥路 实际 $p = .1$，泥路期望回报只有 $.4737$。再读六次真实试验，六次都未通过；模型改为 $2/16$，同样算八次仍选干路。

上图是模型内的估值，下图是把当时选定的路线放回原环境的期望回报。两条曲线使用同一批试验的两个前缀。

Sutton 与 Barto，§8.1、8.3、8.5。泥地模型、规划与路线评价程序 。

预测同一价值：展开深度、后果分支与样本效率

固定策略 π，估计 $v_\pi(s) = \mathbb{E}_\pi[G_t \mid S_t = s]$。**构造一个更新目标**，要决定**沿时间走多远** 以及**每一步怎样取得后果**。

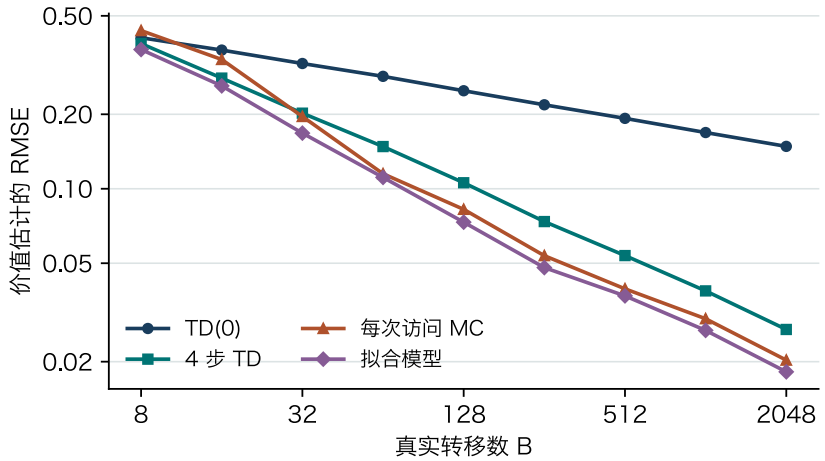
同一条 Bellman 递推的不同展开

	抽取一条路径	按模型对分支求和
一步	TD(0)	$T_\pi V$
n 步	n 步 TD	$T_\pi^n V$
直到终止	回合 MC	完整期望回报

$T_\pi V$ **是一步**奖励加折扣尾值的期望。左列可用**真实轨迹也可用模型模拟**。**模型**拟合有误时，两列都会受影响。

冻结 V，**用真**实转移展开 n **步**，**目**标的期望误差为 $\gamma^n P_\pi^n (V - v_\pi)$。**等到**终止就消去了尾值误差，却需等待**随机回**报。

同样多的真实转移，最后估得多准？



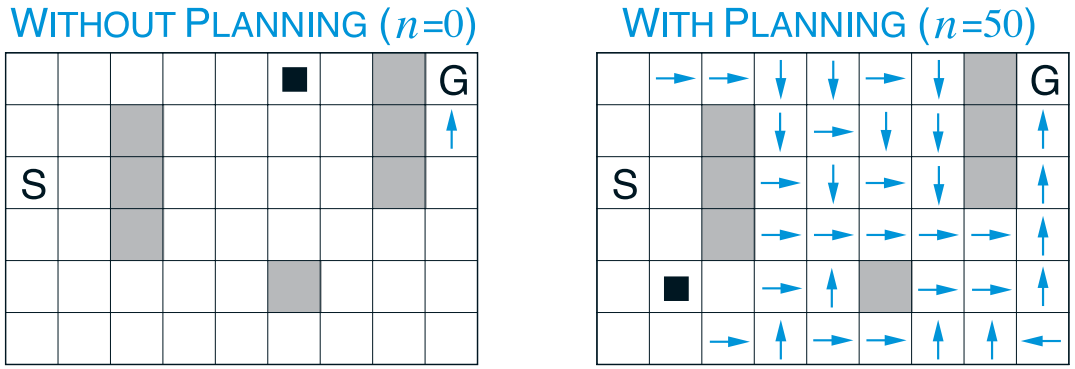
S4 **每步以** .1 **概率得** 1 **并**终止，否则得 0 **并留在** S4。$\gamma = .9$，**真**值 $10/19$。**四种方法共享** 256 组轨迹。

TD **与** MC **均取增量均**值步长。拟合模型用成败频率解价值方程。8 **步**时 MC 误差高于一步 TD；128 **步**时次序相反。

Sutton 与 Barto，第一版 §10.1、第二版 §§7.1、8.5。**配**对实验与原始估计；**逐分支**计算。

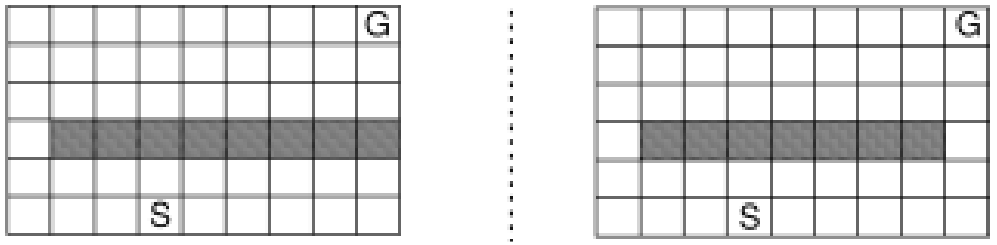
规划可以传播已知后果

确定性迷宫中的奖励传播



第二回合中途，黑格是智能体的位置。每个真实步再**用模型做 50 次价**值更新后（右），许多尚未重访的位置**已有偏好**动作。左图只用真实转移。

环境中的新捷径



第 3000 步后，墙的右端打开

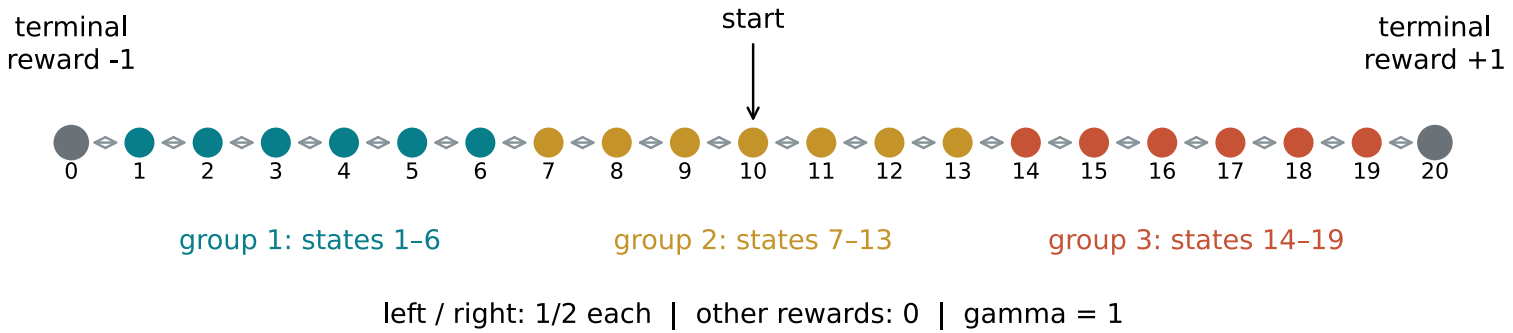
起点、终点和奖励规则相同，右端的转移已改变。只规划旧模型，那里依旧是墙；智能体须**重新**尝试该动作，才会观察到捷径。

真实经验更新模型，规划用模型更新价值表格将每个状态动作对单独存储。状态很多时，还需要用共**享参数把一次**经验推广到其他状态。

左：Sutton 与 Barto 第二版图 8.3（第一版图 9.6为同一实验）。右：第一版图 9.8上方两幅任务图。

第 8 章　函数逼近

仍然预测固定策略的期望回报 $v_\pi(s) = \mathbb{E}_\pi[G_t \mid S_t = s]$。一张表能为每格单独存一个值。若只能存三个数，更新其中一个数，就会同时改变多格的预测。



表示决定能区分哪些状态

每步等概率向左或右，到两端分别得 -1 或 $+1$。同色格共用一个参数，故第 14 格和第 19 格只能给出同一个估计；真值却是 $.4$ 和 $.9$。

状态权重与学习目标

用 $d(s)$ 给各格的预测误差加权，准则为 $\sum_s d(s)[v_\pi(s) - \hat{v}(s, w)]^2$。MC 拟合实得回报；TD 用后继估计自举，两者可在同一组数据上得到不同的解。

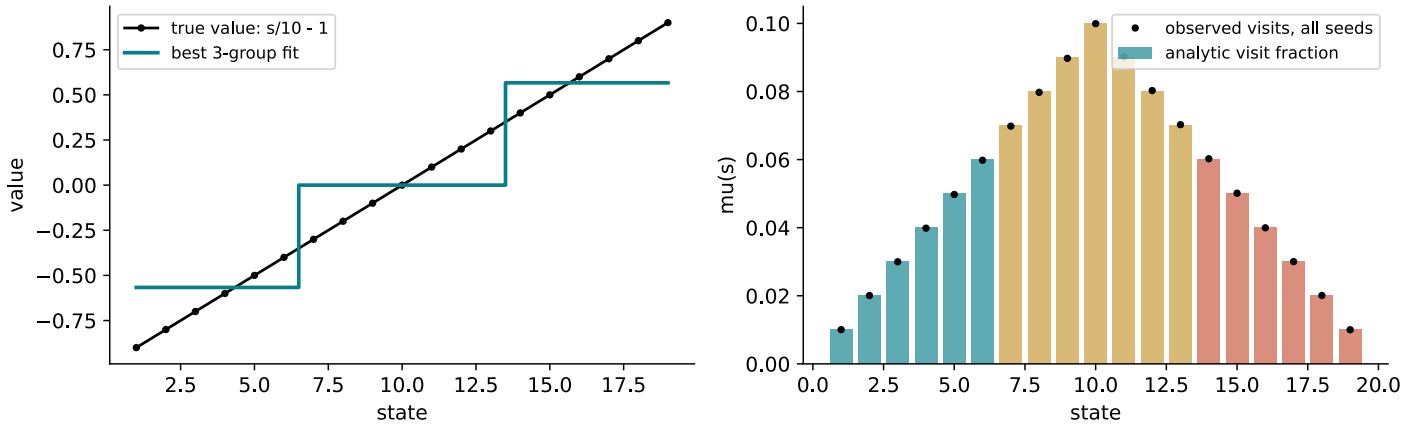
Sutton 与 Barto，Reinforcement Learning: An Introduction，§§9.1–9.4。本课 19 状态随机游走，course15_approximation.py。

随机游走的真实价值与访问分布

沿用本章的对称随机游走。令 $p_R(s)$ 为从 s 先到右端的概率：

$$p_R(s) = \tfrac{1}{2}[p_R(s-1) + p_R(s+1)], \qquad p_R(0) = 0,\ p_R(20) = 1.$$

相邻差分相等，故 $p_R(s) = s/20$；退出收益给出 $v_\pi(s) = 2p_R(s) - 1 = s/10 - 1$。



令 $\eta(s)$ 为每回合访问状态 s 的平均次数。每次访问来自起点或相邻格：

$$\eta(s) = \mathbf{1}\{s = 10\} + \tfrac{1}{2}\eta(s-1) + \tfrac{1}{2}\eta(s+1), \quad \eta(0) = \eta(20) = 0.$$

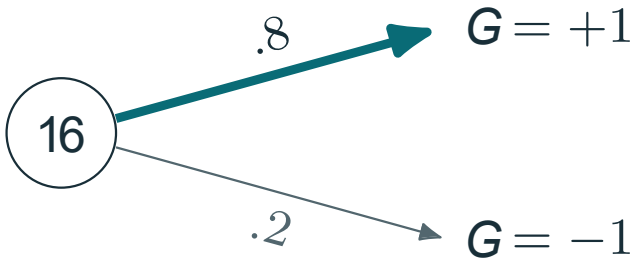
解得 $\eta(s) = \min(s, 20-s)$、$\sum_s \eta(s) = 100$；归一化访问比例为 $\mu(s) = \eta(s)/100$。中间格被访问得更频繁。

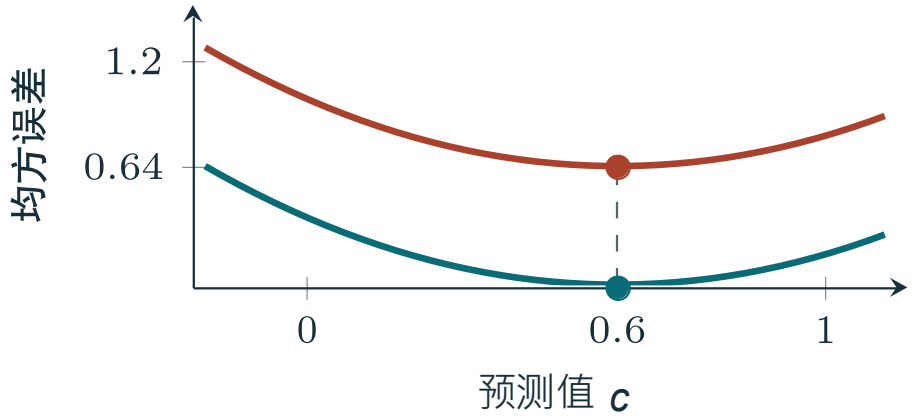
Sutton 与 Barto §9.2；本课 19 状态任务解析解与实际访问计数。

梯度 MC：以回报为标签的价值预测

设策略 π 固定，回合以概率 1 终止，回报有有限二阶矩。每次访问状态 s，都可以用随后的回报 G 作标签。给定 s，它的均值是 $v_\pi(s)$。

在随机游走的第 16 格，最终从右端退出的概率是 .8。两种回报相差 2，真实价值只有一个。





$$v_\pi(16) = .6, \quad \mathrm{Var}(G \mid 16) = .64。$$

给定 s，$\mathbb{E}[(G-c)^2 \mid s] = (v_\pi(s)-c)^2 + \mathrm{Var}(G \mid s)$。展开平方时，交叉项因 $\mathbb{E}[G - v_\pi(s) \mid s] = 0$ 消失。方差与预测无关，故两条曲线在同一处取最小值。按 μ 加权即得总体回归目标。

$$\boxed{w \leftarrow w + \alpha[\, G_t - \hat{v}(S_t, w)\,]\nabla_w \hat{v}(S_t, w)}$$

Sutton 与 Barto，第 9 章；Silver，Lecture 6。图据本章随机游走的两种终止结果绘制。

半梯度TD 与共享参数

同一策略下，MC 等到回合结束才取得回报。TD 在 $S_t = 6$ 走到 $S_{t+1} = 7$ 时，就用后继预测给第 6 格构造一个目标。此步奖励为零，$\gamma = 1$。



$$U_t = R_{t+1} + \gamma \hat{v}(S_{t+1}, w_t), \qquad w_{t+1} = w_t + \alpha \underbrace{[U_t - \hat{v}(S_t, w_t)]}_{\text{TD 误差}} \underbrace{\nabla_w \hat{v}(S_t, w_t)}_{\text{只对当前预测求导}}.$$

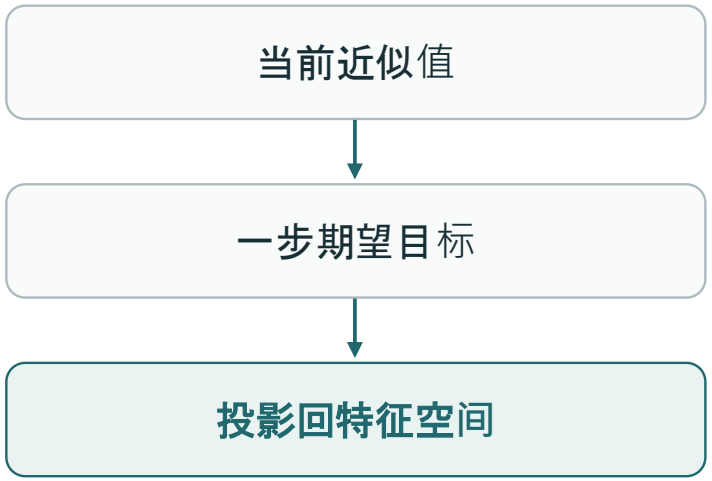
取 $\alpha = .1$。目标为 .20，当前预测为 $-.40$，第一组的六个预测一起提高 $.1(.20 + .40) = .06$。第 7 格使用另一个参数，预测仍为 .20。

这称为**半梯度**。后继预测也依赖参数，但本次求导把 U_t 的数值固定。若两格共用同一参数，更新当前预测也会改变下次读到的后继预测。

Sutton 与 Barto，§§9.2–9.4、11.5；状态聚合程序。

线性 TD 的解：投影贝尔曼固定点

固定策略、固定线性特征，问平均 TD 更新在哪个预测上停下来。



平均更新

状态按访问分布 μ 加权。TD 误差乘以当前特征，平均修正为零时参数达到平衡。

投影固定点

Tπ 给出一步期望目标，Πμ 把它投影回特征空间。投影后的目标须与当前预测一致。

收敛条件

有限折扣任务中，同策略遍历采样、特征满列秩、奖励有界，递减步长总和发散而平方和有限。

$$\hat{v}_{\mathrm{TD}} = \Pi_{\mu} T_{\pi} \hat{v}_{\mathrm{TD}}$$

MC 直接投影真值。TD 的目标含有自身的后继预测。

同一组状态上的回报投影与 TD 固定点

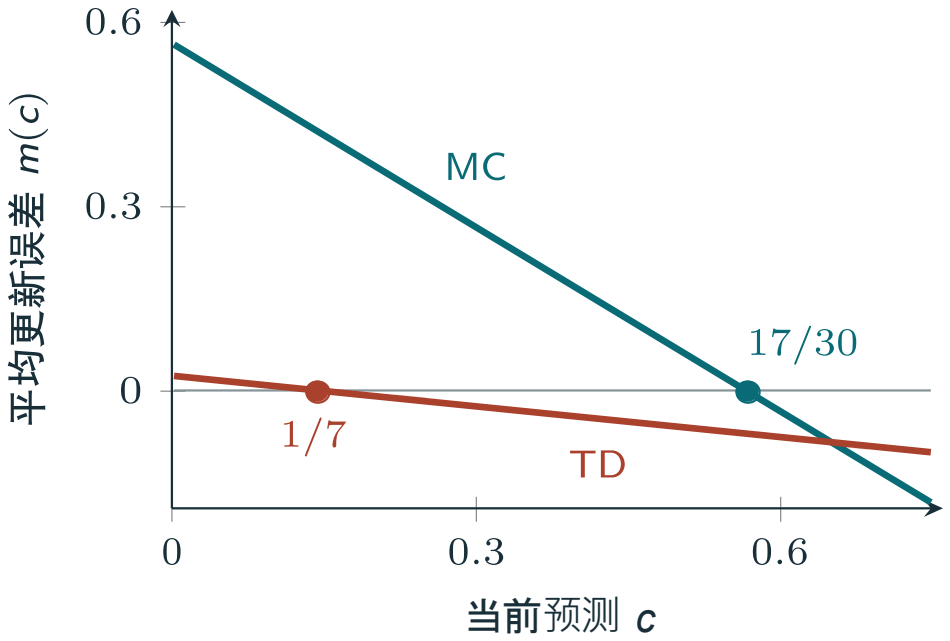
在 19 格随机游走中，右组（14–19 格）共用预测值 c。按访问比例在组内抽一格，考察一次更新的平均误差。取 $\gamma = 1$，利用对称性令中间组的预测为 0。

MC 用实际回报。六格真值依次为 $.4, .5, \ldots, .9$，访问次数之比为 $6:5:4:3:2:1$。加权平均为 $17/30$。

$$m_{\mathrm{MC}}(c) = \mathbb{E}[G - c \mid \text{右组}] = 17/30 - c.$$

TD 用一步目标。离开右组的两条边是 $14 \to 13$ 和 $19 \to 20$，组内概率分别为 $6/42$ 和 $1/42$。其余 $35/42$ 的转移仍以 c 为目标。

$$m_{\mathrm{TD}}(c) = \frac{35c + 6\cdot 0 + 1}{42} - c = \frac{1 - 7c}{42}.$$

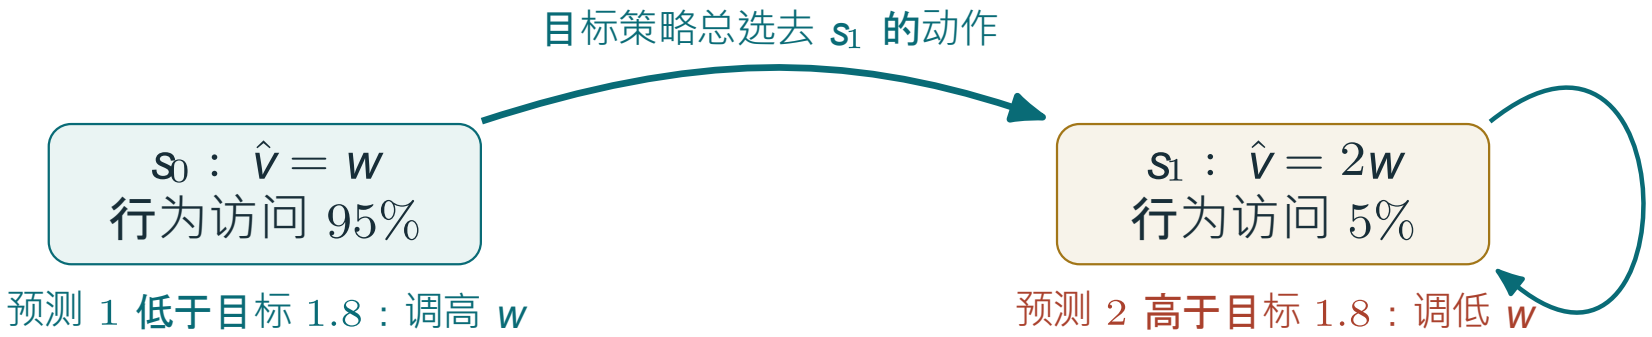


记 Π_μ 为取各组的加权均值，$T_\pi f$ 为用 f 计算的一步期望目标。MC 拟合完整回报，解为 $f = \Pi_\mu v_\pi$。TD 拟合自己的后继预测，解满足 $f = \Pi_\mu T_\pi f$。图中两条曲线的零点就是右组的两个解。

Sutton 与 Barto，第 9、11 章；图据本章 19 状态随机游走的精确访问频率绘制。

致命三元组 Deadly Triad

要预测目标策略 π 的价值，经验却由行为策略 b 产生（离策略学习）。若多个状态共用参数（函数逼近），又用后继价值估计构造目标（自举），三者并用称为**致命三元组**。此时半梯度 TD 可能发散，即使真值可以精确表示。



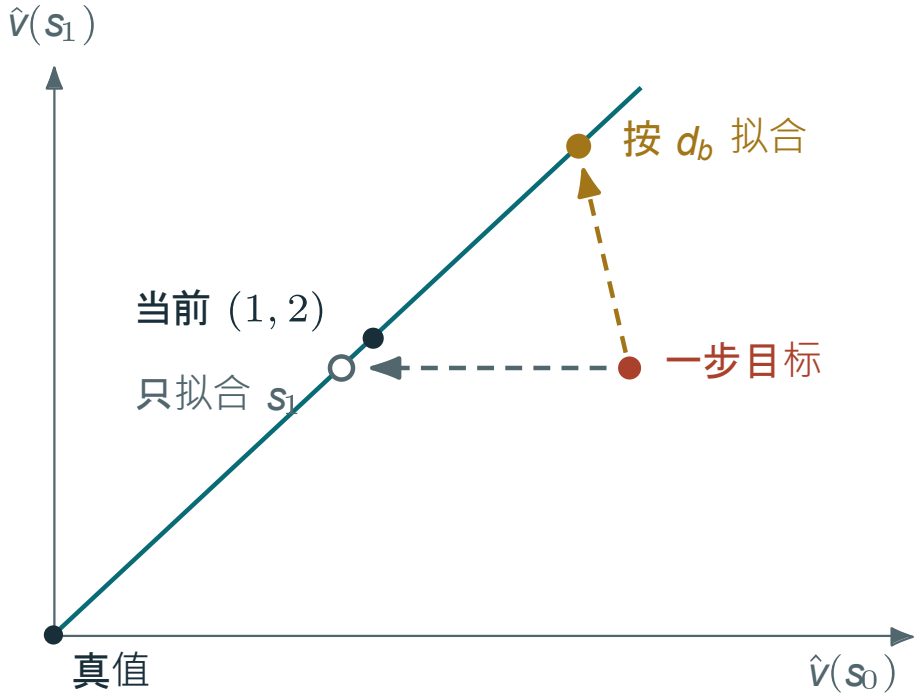
图中两条箭头是 π 的状态转移。奖励恒为零，真值为零。若 $w = 1$、$\gamma = .9$，两处自举目标都是 $.9(2w) = 1.8$。**同一个参数收到方向相反的修正。**

行为策略在两处都以 .05 的概率去 s_1。动作比率 $\pi(A \mid S)/b(A \mid S)$ 把每个起点的动作分布校正为 π，起点仍按 b 访问。两种修正各占多大权重，决定参数向零收缩还是远离零。

Sutton 与 Barto，§§11.1–11.4；Baird（1995）。图为本课两状态任务。

一个线性参数也会放大自举误差

两状态的真值均为零。横、纵轴分别是两个状态的预测。共享参数把一切可能的预测限制在直线 $(w, 2w)$ 上。目标策略总去 s_1，因此从 $w = 1$ 自举，两处目标都是 $.9 \times 2 = 1.8$。



按访问频率拟合同一个目标

只访问 s_1，可取 $w = .9$，使 $2w = 1.8$。若按行为访问 $d_b = (.95, .05)$ 拟合，所得 $w \approx 1.643$，更接近第一处的目标 1.8。

只走一步半梯度 TD，结论方向相同。对固定 w，以动作比率校正后，

$$\frac{\mathbb{E}_b[\Delta w]}{\alpha} = \underbrace{.95(+.8w)}_{s_0} + \underbrace{.05(-.2w)\,2}_{s_1} = +.74w.$$

行为决定了两个起点的权重。按上式反复做精确平均更新，$\alpha = .1$ 时 w 由 1 增至 $1.074,\ 1.153476, \ldots$；真值 0 本来就能表示。

Sutton 与 Barto，§§11.2–11.4。图为本课两状态预测任务；虚线表示不同权重下的一步目标投影。

价值更新中的采样、目标与参数共享

目标策略 π 定义要预测的回报，行为策略 b 产生经验。中图给出 $b = \pi$ 时的两种样本目标。半梯度更新保持 Y 不动，沿 $g_s = \nabla_w \hat{v}(s, w)$ 修正状态 s 的预测。

经验分布



访问状态的频率

同策略 $b = \pi$；离策略 $b \neq \pi$

学习目标 Y



自举把后继预测带回当前状态

一次更新的作用范围



表格只改 s；共享权重可影响 u

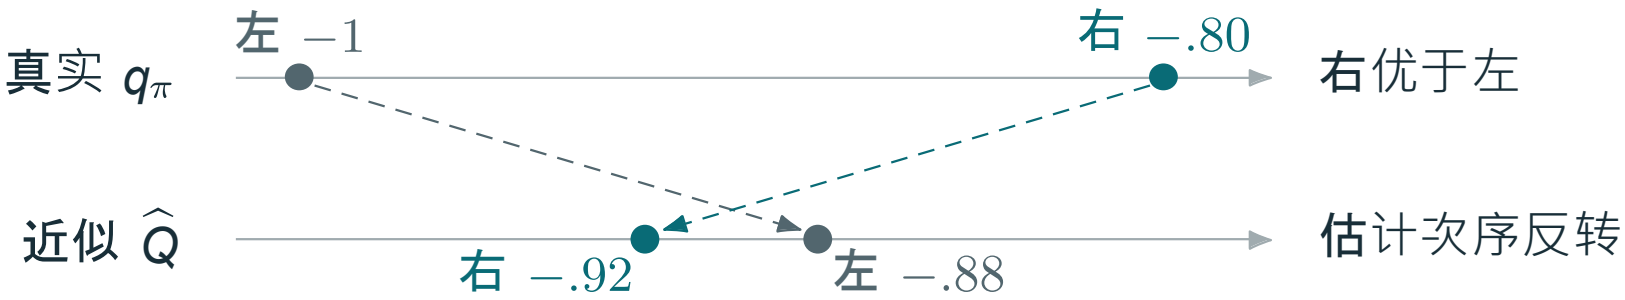
记 $\delta = Y - \hat{v}(s, w)$。一步 $\Delta w = \alpha \delta \, g_s$ 使 $\Delta \hat{v}(u) \approx \alpha \delta \, g_u^\top g_s$。固定线性特征时等号精确成立；网络中它给出一阶变化。若梯度内积为负，一次小的正误差更新会降低另一状态 u 的预测。

DQN 在第一处从回放池抽取旧转移，在第二处用暂时冻结的网络算 $\max_{a'} Q^-(s', a')$。第三处仍由同一在线网络给多个状态、动作估值。离策略、自举与参数共享可以同时存在。

Sutton 与 Barto，§§9.3–9.4、11.3；Mnih 等，2015；两状态单参数例；训练前后的梯度内积图；随机游走程序。

近似动作价值与策略改善条件

预测要估准给定策略的回报。用估值改善策略，还要分清动作的优劣。在随机游走第 1 格，**原策略** π **等概率向两**侧走，先左、先右的真实动作价值分别为 -1、$-.8$。



图中两项估计的平均仍准确。若按估计取贪心动作，第 1 **格会改**选左；同一改变按估计和真值计算，符**号相反**。

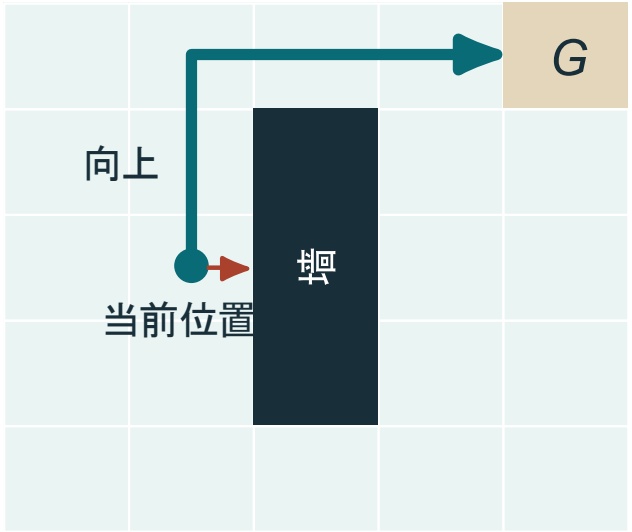
$$\widehat{\Delta}(1) = -.88 - (-.90) = +.02, \qquad \Delta(1) = -1 - (-.90) = -.10.$$

从第 1 **格出**发，改选左使回报由 $-.90$ **降到** -1。**控制**还有一层反馈：改选左马上终止，下一步就采不到**右**边的状态。DQN **用估**值选动作，选出的动作又决定随后能学到哪些转移。

Sutton 与 Barto，《强化学习》§§4.2、9.2；19 **格随机游走**：**原**书例 7.1。图中 $\widehat{Q}$ 为本课指定的估计。

第 9 章　深度价值学习

在动作有限、转移规律未知的任务中，DQN 与表格 Q-learning 都估计最优动作价值 $q_*(s, a)$。表格更新一个状态动作项；DQN 调整共享网络 Q_w，一次更新可以改变许多状态的动作排序。



青线：执行网络的贪心策略，五步到达终点。

非终止步得 $-.02$，到终点得 $+1$，折扣 $.97$。在图中位置，训练一万步后的上、右、下、左动作估计为

$$(\underbrace{.809}_{\text{上}},\ .765,\ .724,\ .727).$$

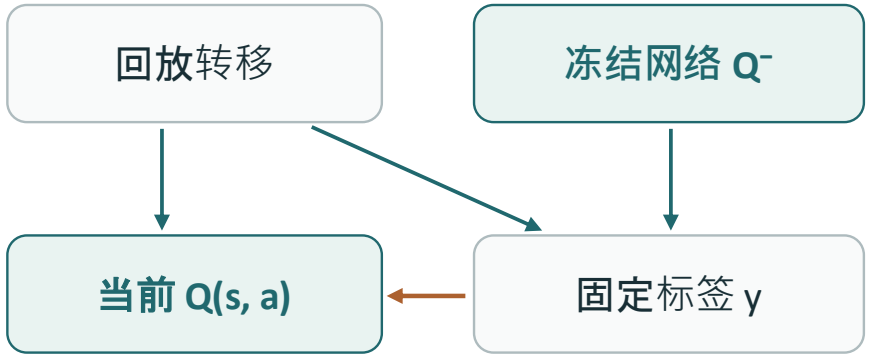
四项中向上最高。若只按这个排序行动，经验中只会出现该策略走过的路；探索会让其他动作也有机会得到更新。

表格中的一步目标沿用到网络：非终止时为 $R + \gamma \max_{a'} Q_{\bar{w}}(S', a')$，终止时为 R。回放池提供旧转移，副本 $\bar{w}$ 提供后继估计；策略按真实执行所得回报评价。

Mnih 等，Human-level Control through Deep Reinforcement Learning (2015)。 图据本课种子 0 的 grid-q-map.csv 和实际网格转移绘制。

DQN：一次完整的交互与训练更新

用在线网络 Q 估计有限动作的价值，初始化目标副本 $Q^{-} \leftarrow Q$ 和空回放池。



用标签修正在线 Q；每隔 C 次更新复制参数到目标网络。

交互并保存

按 Q 做 ε-贪心探索，将真实的 (s, a, r, s′, m) 存入池。真终止时 m = 0，否则为 1。

抽取旧经验

记录足够时均匀抽一小批转移，同一条记录可以多次参加训练。

计算固定标签

用 Q^{-} 读真实后继的最大动作估值。真终止样本只保留奖励。

更新并同步

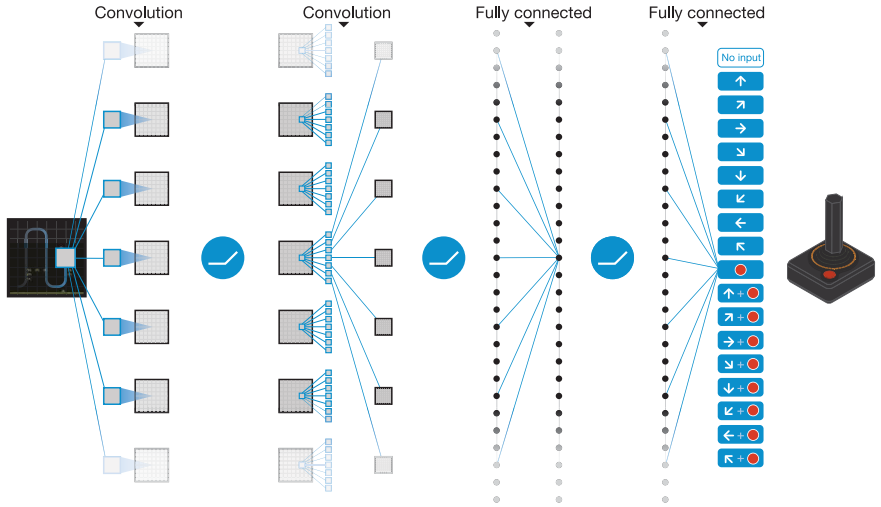
固定标签，用小批回归更新在线 Q 的已选动作输出。每隔 C 次训练更新复制一次 $Q^{-} \leftarrow Q$。

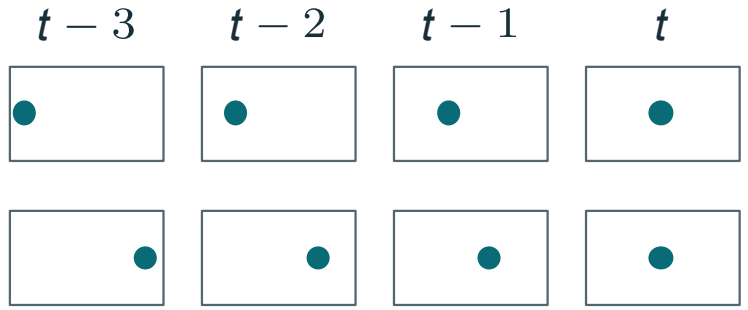
$$y = r + \gamma \max_{a'} Q(s', a'; \theta^{-})$$

行动来自在线网络，后继估值来自目标副本，回归只改变在线参数。

DQN 的图像输入与动作价值输出

网格任务把当前位置编码成输入。Atari DQN 把最近四幅预处理画面叠成 Z_t，用一次前向计算得到每个动作的价值 $Q_w(Z_t, a)$，再按 ϵ-greedy 选动作。





上行向右，下行向左，末帧相同

Mnih 等，原图 1。右端每个输出对应一个动作。

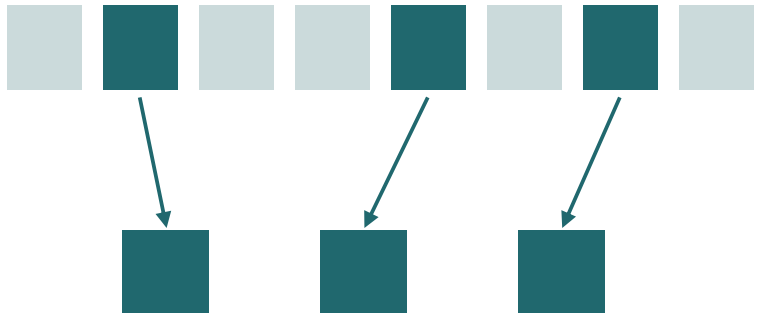
四帧可以分辨右图的运动方向若更早出现的线索仍影响奖励，同样的四帧就可能合并不同历史。换行为策略后，这些历史在同一 (Z_t, a) 下的比例可能改变，使一步 Q 目标的均值也随之改变。

Mnih 等，Nature 2015，图 1 及 Methods（Preprocessing、Model architecture）。右图为运动方向示意。

经验回放：复用转移与改变采样分布

连续收来的转移往往很相似，一次罕见的成功又很快会被新经验淹没。

按时间收集



均匀抽样组成一个小批量

打散采样次序

从池里均匀抽记录，使一个小批可以包含不同时间、不同局面的经验。

重复利用经验

一条真实转移可参与多次更新，每次重读都不增加环境交互数。

覆盖仍由行为决定

均匀抽记录会保留池中各类经验的相对频率。未尝试动作缺少自身**的真**实转移。

P(抽到记录 i) = 1 / 池中记录数

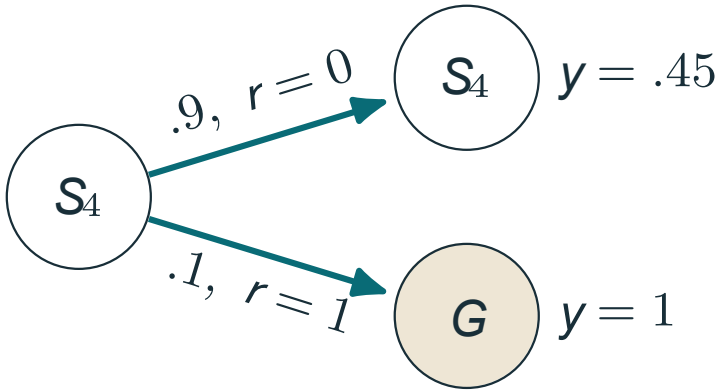
随机回放减弱样本的时间关联。哪些状态和动作有数据，仍取决于采集。

DQN 的回归标签

在给定的状态动作 (s, a) 上采一次真实转移：奖励和后继状态可变，目标网络 $Q_{\bar{w}}$ 固定。一步 Q-learning 以贪心动作的估计自举。环境转移律为 p，终止时 $m = 0$，其余 $m = 1$。

$$y = r + \gamma m \max_{b} Q_{\bar{w}}(s', b), \qquad \mathbb{E}_p[Y \mid s, a] = (T_* Q_{\bar{w}})(s, a).$$

在泥格 S_4 向上一步



取 $\gamma = .9$，留在泥格时后继最大估计为 $.5$。两种标签的条件均值为 $.9(.45) + .1(1) = .505$。若池中该动作只记录了两次原地停留，均匀回放的标签均值就是 $.45$，真实环境下才是 $.505$。有限样本与后继估值都会影响对 q_* 的逼近。

平方损失拟合条件均值

固定目标网络 $\bar{w}$，记 $u = Q_w(s, a)$、$\bar{y} = \mathbb{E}[Y \mid s, a]$。展开平方得

$$\mathbb{E}[(u - Y)^2 \mid s, a] = (u - \bar{y})^2 + \mathrm{Var}(Y \mid s, a).$$

方差项与在线参数 w 无关。只对 u 求导，得到

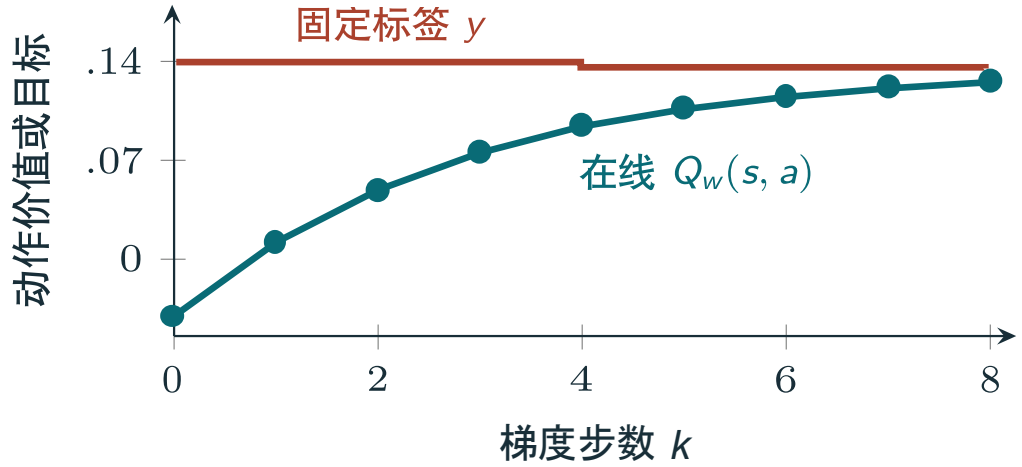
$$w \leftarrow w + \alpha(y - u)\,\nabla_w Q_w(s, a).$$

Mnih 等（2015），DQN；本文网格用平方损失，原 Atari 实验将 TD 误差限制在 $[-1, 1]$ 后用于回归更新。 Sutton 与 Barto，§§6.5、9.3。

目标网络与Double DQN 的动作选择

对非终止转移，自举标签等于即时奖励加上折扣后的后继动作估值。目标网络何时复制，与用哪个网络选出后继动作，是两个不同的决定。

延迟复制：数值何时改变



本例重复同一转移，DQN 每四步复制参数；在第 4 步，副本给出的标签由 .141 变为 .137。

分开选与评：读取哪项估值

同一后继	动作甲	动作乙
在线 Q_w	5	4
副本 $Q_{\bar{w}}$	2	6
	Double DQN 读 2	DQN 读 6

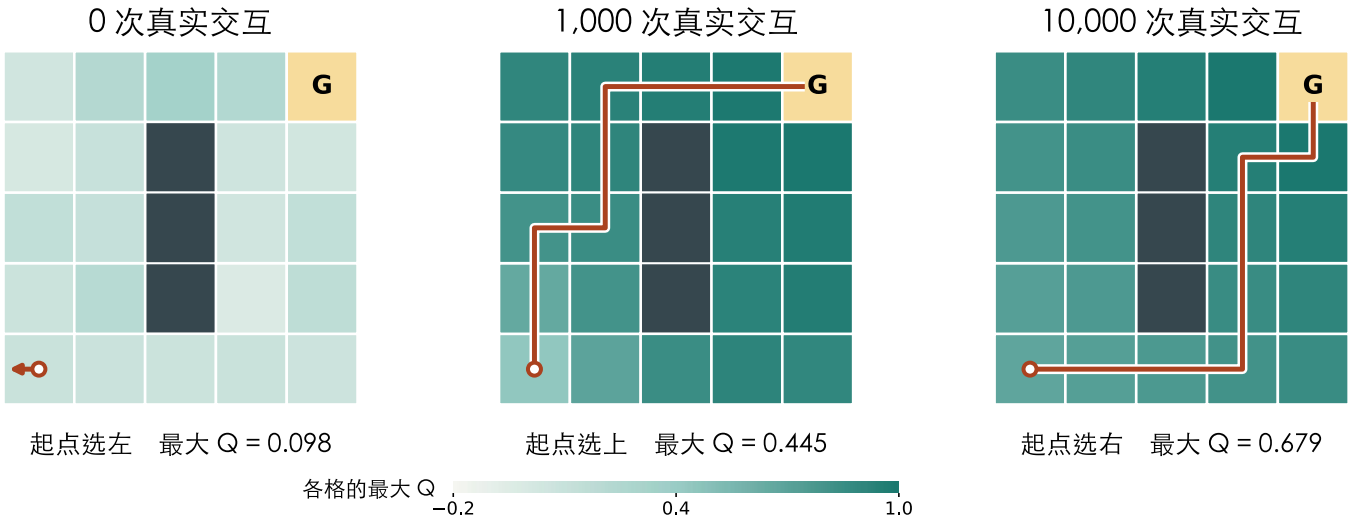
DQN 在副本中取最大值。Double DQN 由在线网络选甲，再到副本读取甲的估值。刚复制时两者相同。

取最大值可能导致高估 若两个动作真值均为 0，各自的误差独立且等概率为 ± 1，取最大值时，四种等概率组合中有三种读到 $+1$，期望为 $+.5$。分开选评可减轻高估；实际网络的误差仍可能相关。

Mnih 等，DQN；van Hasselt 等，Double DQN。左图为实算，右图为指定读数。枚举选评误差与回放权重。

同一个DQN，不同起点的贪心路线

三图都从 $(0,0)$ 出发。底色表示最大动作估值，橙线记录冻结策略逐步走过的路线。



第 750 到 1000 步，全网格动作价值平均绝对误差从 .239 降到 .083。在 64 步内到达终点的起点却从 $19/21$ 减至 $15/21$；图中的 $(0,0)$ 在第 1000 步已能八步到达。

同一网络，改从 $(3,3)$ 出发

向左撞墙后仍在原地。网络给左 .989、给上 .948，每一步都再选左，64 步的折扣回报为 $-.572$。

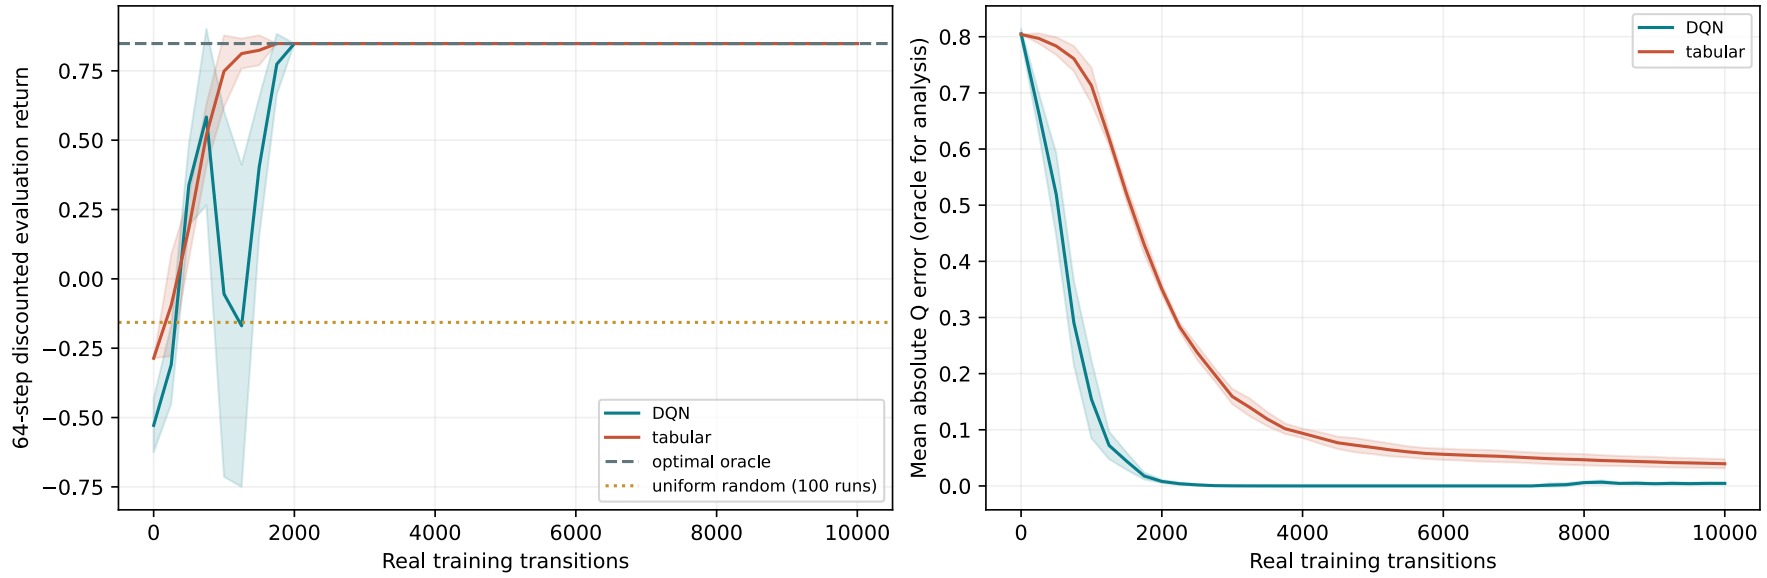
原地比较第3000 步的网络

向上 .9500，向左 .9016。贪心策略先上再右，两步到达终点，实际回报 $-.02 + .97 = .95$。

本课网格，种子 0；grid-q-map.csv 中的动作价值与 dqn_model_v11.py 中的转移。坐标自左下角 $(0,0)$ 起。

DQN 的价值误差与策略回报

在这个网格中，不同的 Q 数值误差对应同样好的动作选择。最终 DQN 与表格法的回报均为 .8484，达到最短路参照；Q 平均绝对误差却为 .00455 与 .03954。



5 个独立训练种子，阴影为 ±1 样本标准差。每次固定贪心策略，遍历 21 个非终点起点，累计最多 64 步的实际折扣奖励；不补预测尾值。

每次交互，表格法只更新一个表项。DQN 的一次梯度更新读取 32 条回放。两者的真实交互预算相同，数据读取和计算预算不同。

本课网格训练，dqn_model_v11.py；精确模型仅供评价。

动作排序与自举目标

DQN 用同一组动作估值做两件事。动作之间的相对误差可能改变下一次选择；最大估值的绝对误差会改变前一步的自举目标。

选动作取决于价值差

设 a_* 在 s 最优，$\max_a |Q(s,a) - q_*(s,a)| \le \varepsilon$。对任一次优动作 b，

$$Q(s,a_*) - Q(s,b) \;\ge\; \underbrace{q_*(s,a_*) - q_*(s,b)}_{\text{真实动作价值差}} - 2\varepsilon.$$

两项估计误差方向相反时，差值最多缩小 2ε。真实差超过这个数，b 就不能胜出。

回传取决于最大值

在一个已观测的非终止后继状态，把目标网络的所有动作估值都抬高 $.10$：

$$\arg\max_a (Q_{\bar{w}}(s',a) + .10) = \arg\max_a Q_{\bar{w}}(s',a),$$

$$y_{\text{new}} - y_{\text{old}} = \gamma \times .10.$$

当 $\gamma = .97$ 时，前一步的标签抬高 $.097$。在后继状态做对了选择，仍可能把错误的数值传回去。

网格 $(1,2)$ 的最优动作是向上，领先次优动作 $.0443$。第 1000 步时 $2\varepsilon = .1341$，网络已经选对；第 10000 步时 $2\varepsilon = .0106$，仅凭误差界也能判断排序正确。

DQN 通过动作排序改善行为，进而改变新收集的经验。下一章直接为策略引入参数，沿期望回报对这些参数的梯度改善策略。

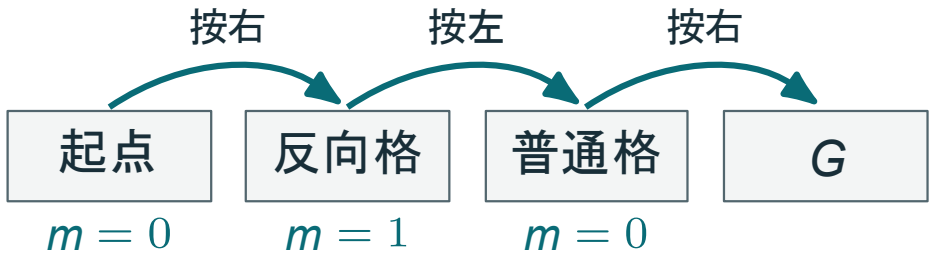
Sutton 与 Barto，§§6.5、9.2；Bellemare 等（2016），动作价值差；Mnih 等（2015），DQN。网格真值与种子 0 的冻结网络比较。

第 10 章　策略梯度与行动者—评论者

沿用固定起点分布 μ 与期望回报目标。直接用可微策略 π_θ 表示动作概率，在这个策略族内求

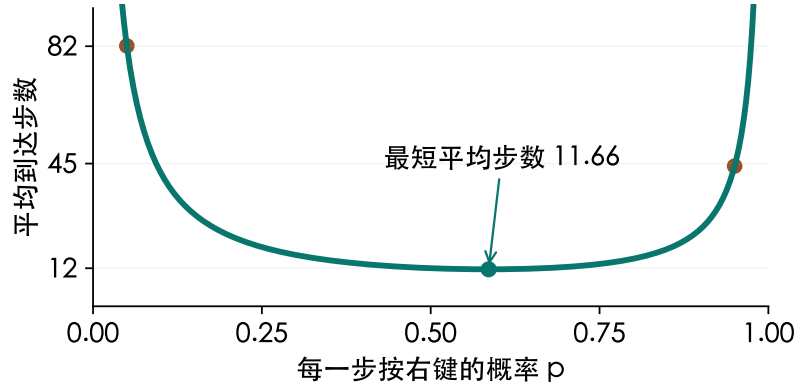
$$\max_\theta J(\theta), \qquad J(\theta) = \mathbb{E}_{\mu,\pi_\theta}\left[\sum_{t=0}^{T-1} \gamma^t R_{t+1}\right].$$

策略能使用上一动作



各格观测相同。已知从左端出发且转移确定，只记上次是否按右，便可依次按右、左、右，三步到达。

策略只能使用当前观测

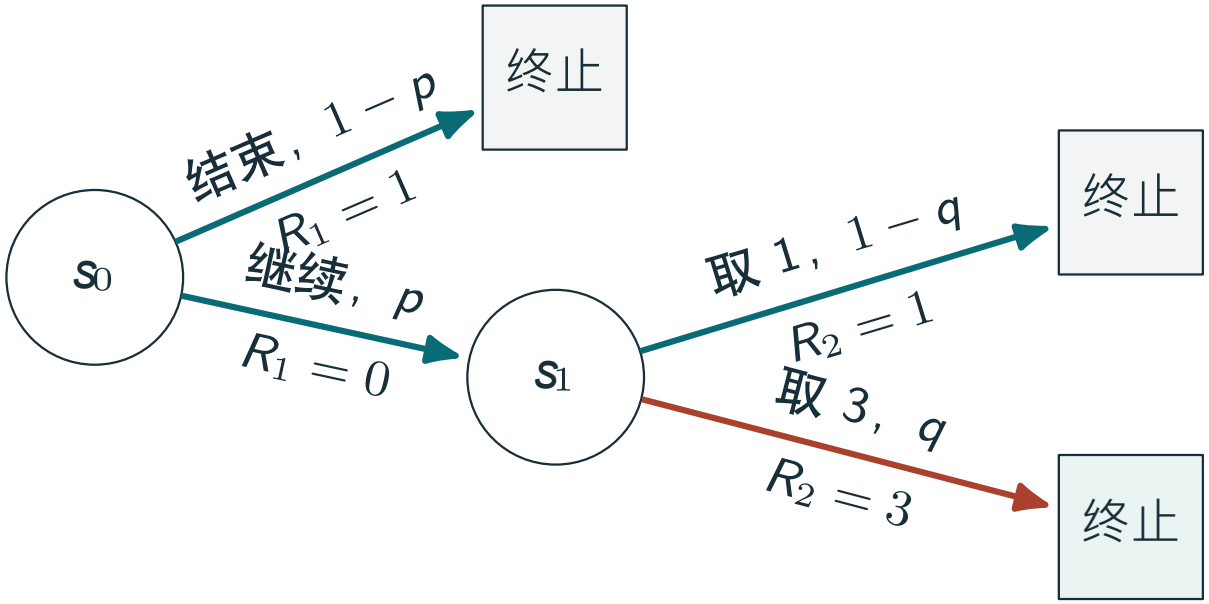


三个位置共用按右概率 p。即使选到最优 $p = 2 - \sqrt{2}$，平均仍需 11.66 步。

走廊每步奖励 -1，$\gamma = 1$，故 $J = -\mathbb{E}[T]$。策略的输入限制了可达到的回报。固定输入后，按当前策略采样轨迹，用回报或优势估计 ∇J。

Sutton 与 Barto，例 13.1（三格共用特征）；确定性的一位记忆规则为本课算例。两类策略的训练程序。

参数化随机策略



策略改变动作概率，环境规则固定。

$\pi_\theta(a \mid s)$ 是状态 s 下选动作 a 的概率；θ 是待学参数。本例有两个参数：

$$p = \sigma(\theta_0), \quad q = \sigma(\theta_1)$$

$$\sigma(z) = \frac{1}{1+e^{-z}}, \qquad \gamma = .9$$

每回合至多两步，始终从 s_0 开始。

$$J(\theta) = \mathbb{E}_\theta[G_0].$$

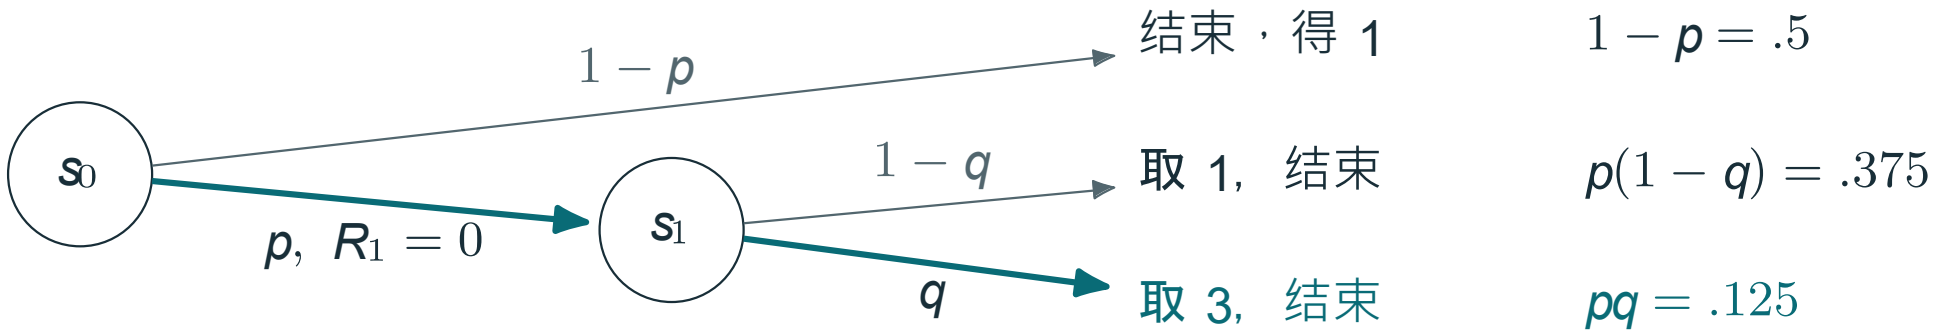
从实际路径与奖励估计改善方向。

两个概率的作用不同。提高 q 只改变已经到达 s_1 时的选择；提高 p 还会增加到达 s_1 的机会。

Sutton 与 Barto：《强化学习》第 13 章；本课两步任务与 sample14_pg.py。

轨迹概率与期望回报的导数

固定起点分布 μ **与环境核** $K(s', r \mid s, a)$**。改变策略会改变三条轨迹出现的概率。**



记 $g_t = \nabla_\theta \log \pi_\theta(A_t \mid S_t)$。对一条已指定的轨迹，其奖励序列也已指定：

$$P_\theta(\tau) = \mu(s_0) \prod_{t<T} \pi_\theta(a_t \mid s_t) K(s_{t+1}, r_{t+1} \mid s_t, a_t) \quad \Longrightarrow \quad \nabla_\theta \log P_\theta(\tau) = \sum_{t<T} g_t.$$

$$\nabla J = \sum_\tau G_0(\tau) \nabla P_\theta(\tau) \overset{\nabla P = P \nabla \log P}{=} \mathbb{E}_{\tau \sim P_\theta} \left[G_0 \sum_{t<T} g_t \right].$$

调整策略会改变各条轨迹出现的频率。用当前策略采样，就能估计右式中的期望。

Sutton 与 Barto，§§13.2–13.3；Williams（1992），REINFORCE。图中 $p = .5$，$q = .25$。

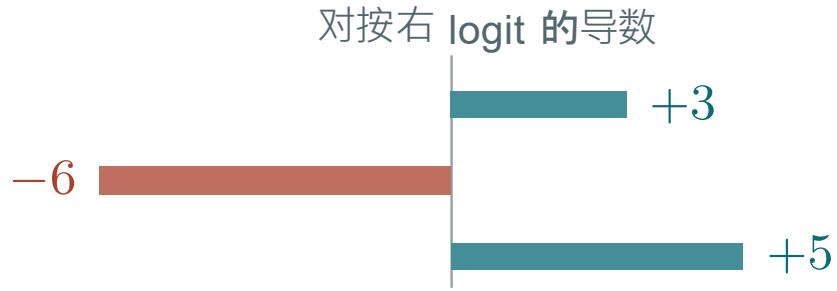
策略梯度定理：访问权重乘以局部改进

给定 (S_t, A_t)，回报 G_t 的条件均值是 $q_\pi(S_t, A_t)$。令 $g_t = \nabla_\theta \log \pi_\theta(A_t \mid S_t)$，按访问状态收集梯度贡献：

$$\nabla J = \mathbb{E}_\pi \sum_{t<T} \gamma^t g_t G_t = \sum_s \underbrace{\eta_\theta(s)}_{\text{折扣访问权重}} \underbrace{\sum_a \nabla_\theta \pi_\theta(a \mid s)\, q_\pi(s,a)}_{\text{改变此处动作概率的贡献}}.$$

$\eta_\theta(s) = \sum_{t\ge 0} \gamma^t \Pr_\pi(S_t = s, t < T)$。短走廊每步得 -1，$\gamma = 1$。三格共用按右概率 $p = \sigma(\theta) = .5$。每条横条长短与方向由 $\eta_\theta(s)\, p(1-p)\, \Delta q$ 给出，$\Delta q = q_\pi(s, \text{右}) - q_\pi(s, \text{左})$。

所在格	访问次数	Δq
起点	6	$+2$
反向格	4	-6
出口前	2	$+10$

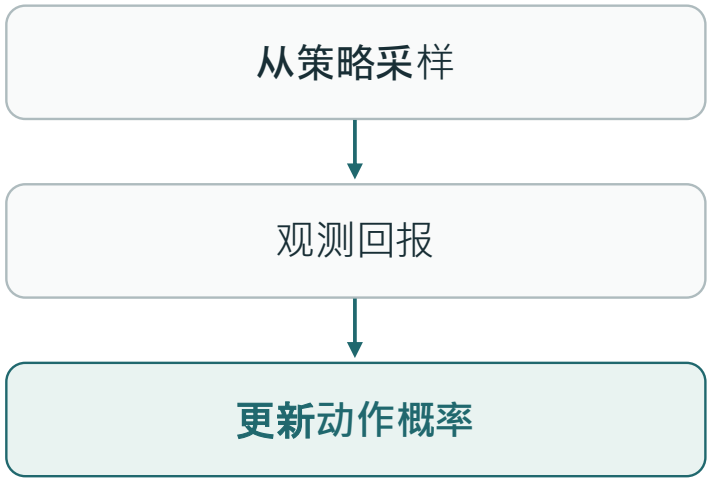


同一个参数接收三项，导数是 $3 - 6 + 5 = 2$。若行动时能辨认反向格，为它单设一个参数，则普通格与反向格的导数分别为 $+8$ 和 -6。只给训练基线看格号，行动者仍共用一个参数。

Sutton 与 Barto，例 13.1、§§13.2、13.4；短走廊数值由状态转移方程求得。

REINFORCE 的策略更新

从固定起点分布出发，希望提高折扣回报的期望 J(θ)。



采完整回合

固定当前参数 θ，按 πθ 采一批完整回合，保留每步的状态、动作与奖励。

回算后续回报

从每个终点往前递推 $G_t = R_{t+1} + \gamma G_{t+1}$，用它给当时所选动作加权。

沿平均梯度上升

回合内相加，回合间平均，更新一次 θ。下一批回合改用新策略采集。

$$\gamma^t \, G_t \, \nabla_\theta \log \pi_\theta(A_t|S_t)$$

G_t 折算动作之后的奖励，外层 γ^t 把时刻 t 的贡献折回起点。

基线与策略梯度的方差

只看已到达 s_1 的回合。取 1 的概率为 .75，对取 3 的 logit 而言，得分 $g = -.25$；取 3 时 $g = .75$。两种动作使用同一基线 b。



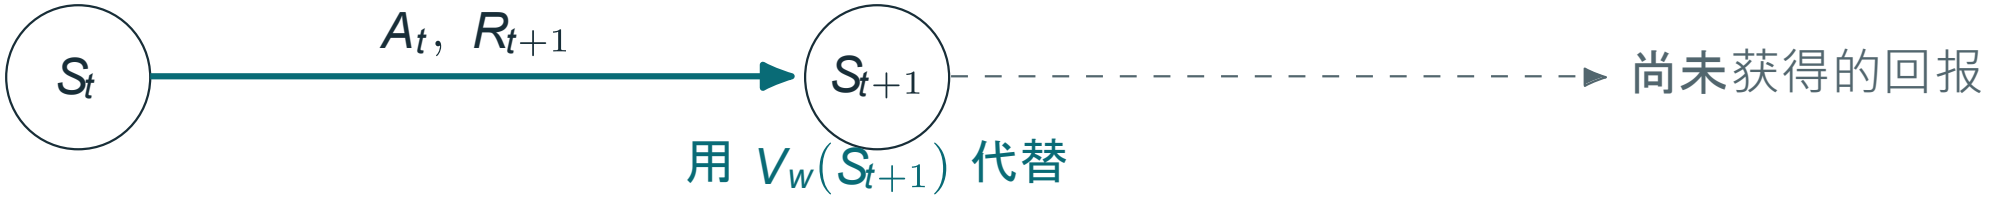
在选动作前固定 b，所减项的条件均值为 $b[.75(-.25) + .25(.75)] = 0$。准确的价值基线 $v_\pi(s_1) = 1.5$ 将条件方差从 1.172 降至 .188；在这一格，$b = 2.5$ 甚至使两种更新相同。

只有取 $b = v_\pi$ 时，$G - b$ 给定 (s, a) 的条件均值才是优势 $q_\pi(s, a) - v_\pi(s)$。其他固定基线仍能保持策略梯度的期望。

Sutton 与 Barto，§13.4；两步任务与基线的枚举。

行动者—评论者：用后继价值估计动作的优势

REINFORCE 要等到回合结束才知道 G_t。评论者 V_w 估计当前策略的价值，让行动者能够用一步转移估计优势。固定本步参数，记 $g_t = \nabla_\theta \log \pi_\theta(A_t \mid S_t)$。



$$\delta_t = R_{t+1} + \gamma V_w(S_{t+1}) - V_w(S_t), \qquad \mathbb{E}[\delta_t \mid s, a] = \underbrace{A_\pi(s,a)}_{\text{希望得到的优势}} + \underbrace{\gamma \mathbb{E}[e(S_{t+1}) \mid s, a] - e(s)}_{e(s) = V_w(s) - v_\pi(s)}.$$

$e(s)$ 与当前动作无关，作为基线不改变期望方向；**后继误差随动作改变** 可能改变梯度方向。

$$\left.\begin{aligned} \Delta w &= \eta_w \delta_t \nabla_w V_w(S_t), \\ \Delta \theta &= \eta_\theta \gamma^t \operatorname{sg}(\delta_t) g_t \end{aligned}\right\}$$

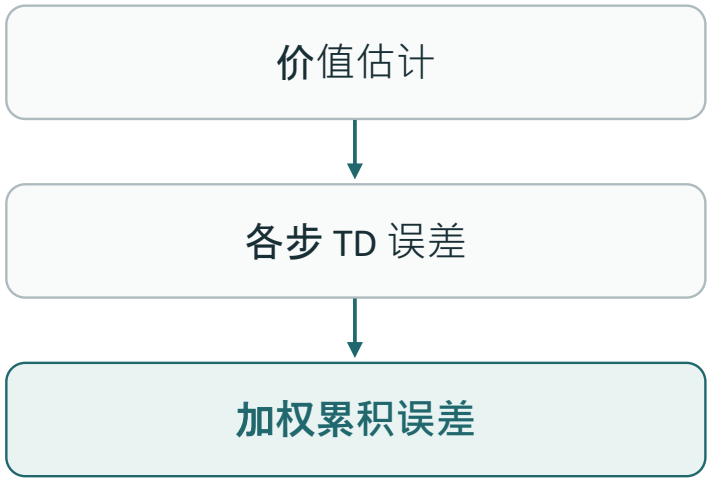
先用更新前的 (w, θ) 计算两项，再更新参数；终止状态价值为 0.

一步 TD 误差即可用于在线更新。若保留一段轨迹，也可用多步 TD 误差估计同一优势；这给出广义优势估计（GAE）。

Sutton 与 Barto：《强化学习》第 13 章；Machado：CMPUT628 Policy Gradient。

广义优势估计（GAE）

在同一段经验里，当前动作之后可能已经有好几条真实奖励。



先算一步误差

用采样时固定的评论者，算奖励加折扣续值减当前估值。真正终止时续值取零。

再从段尾递推

把下一步的优势估计乘 γλ **加回来**；**相隔 j 步的** TD 误差，权重是 (γλ) **的 j 次方。**

决定在哪里停

真终止或采样截断都停止跨段递推。外部截断时，末条误差仍在实际后继观测上自举。

$$\hat{A}_t = \delta_t + \gamma\lambda c_t \hat{A}_{t+1}$$

同段有下一步时 $c_t = 1$，**段末取** 0。**完整回合** $\lambda = 1$ 时得到 $G_t - V(S_t)$。

同一控制目标下的贪心改善与策略梯度

固定起点分布和折扣率。两条路径的共同目标是使 $J(\pi) = \mathbb{E}_\pi[G_0]$ 尽可能大。当前策略 π 的动作价值 $q_\pi(s, a)$ 描述先取 a、随后沿用 π 的期望回报。

逐状态改善

评价当前策略 $q_\pi(s, a)$ → 比较同一状态的动作 $\pi'(s) \in \arg\max_a q_\pi(s, a)$ → 精确评价、逐状态可选动作 → 策略改善定理给出 $J(\pi') \geq J(\pi)$

评论者估计 $A_\pi = q_\pi - v_\pi$

策略参数改善

对 π_θ 求导 → 折扣访问频率 × 动作优势 $\nabla J = \mathbb{E}_{\pi_\theta}\left[\sum_t \gamma^t A_{\pi_\theta}(S_t, A_t) \nabla_\theta \log \pi_\theta(A_t \mid S_t)\right]$ → $\theta' = \theta + \alpha \nabla J$

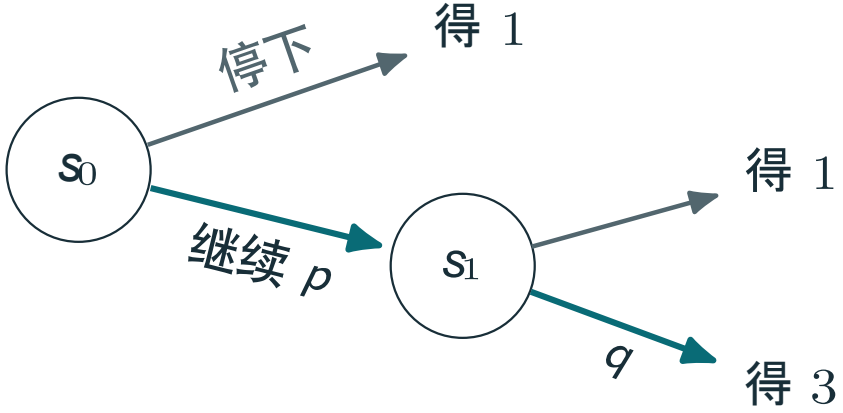
局部方向与有限步长 两步树沿一个候选方向取 $p_h = .5 + .4h$，$q_h = .25 - .15h$。按旧访问量计算，一阶改善为 $.005h$。计入到达第二个状态的概率变化，$\Delta J = .005h - .108h^2$。全步 $h = 1$ 使回报下降 $.103$。

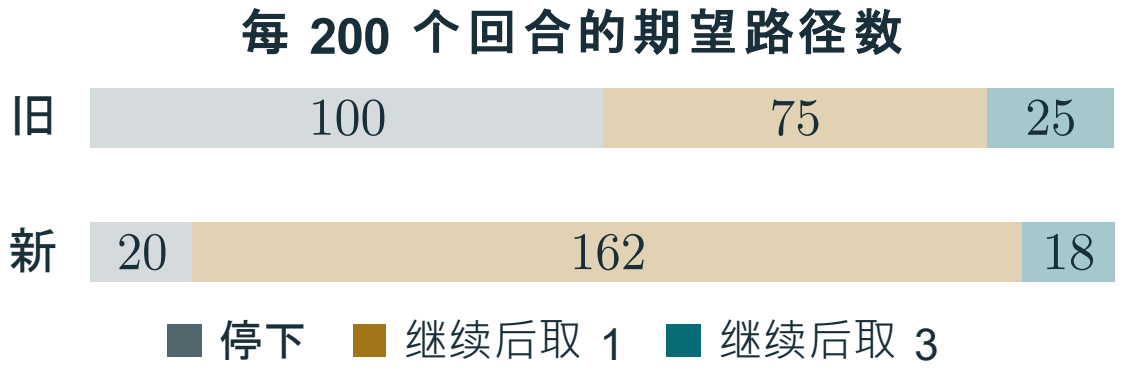
上式按当前策略 π_θ 取期望。改从行为策略 b 采样，还须处理动作概率与状态访问频率的差异。

Sutton 与 Barto，§§4.2、13.1–13.5；Schulman 等，TRPO；两步树精确计算。

第 11 章　信赖域策略优化与 PPO

策略改变时，**状态内的动作分布与状态的访问频率都可能改变**。旧轨迹保留原有的访问频率。





继续当步得 0，**第二步**奖励折扣 .9。

(p, q) **从** $(.50, .25)$ **改为** $(.90, .10)$。**按旧策略**计算，继续比停下多得 .35。**在** s_1，**新策略每次少得** .30。

$$\begin{aligned} &\textbf{按旧策略的到达概率估计} \quad .40(.35) - .9\,\underline{.50}(.30) = +.005, \\ &\textbf{按新策略的到达概率计算} \quad .40(.35) - .9\,\underline{.90}(.30) = -.103. \end{aligned}$$

旧访问代理略有提高，实际回报由 1.175 **降至** 1.072。**多出的到达次数放大了第二步的**损失。

Schulman 等，TRPO (2015)、PPO (2017)。**两步任**务的精确计算。

旧策略代理与有限步误差

折扣占用 $d_\pi(s) = (1-\gamma)\sum_{t\ge 0}\gamma^t \Pr_\pi(S_t = s)$。固定旧优势 A_{old}。动作概率比精确校正了每个已访问状态内的动作权重。代理还保留了旧状态占用；真实回报差则需要新状态占用。

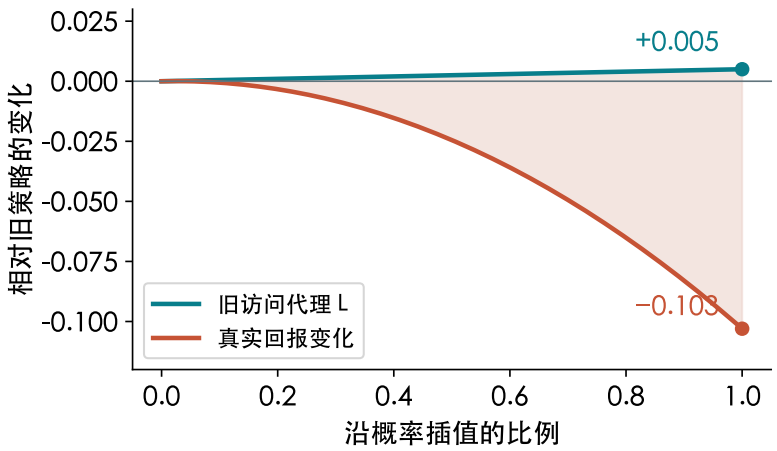
$$J(\pi_\theta) - J(\pi_{\text{old}}) = \frac{\mathbb{E}_{d_{\pi_\theta},\pi_\theta} A_{\text{old}}}{1-\gamma} \xrightarrow[\text{以旧访问代替新访问}]{} L_{\text{old}}(\theta) = \frac{1}{1-\gamma}\mathbb{E}_{d_{\text{old}},\pi_{\text{old}}}\left[\frac{\pi_\theta}{\pi_{\text{old}}} A_{\text{old}}\right].$$

在旧策略处，$\sum_a \pi_{\text{old}}(a \mid s) A_{\text{old}}(s,a) = 0$。访问分布导数所乘的项为零，故 $\nabla L_{\text{old}} = \nabla J$。

两步任务取 $\gamma = .9$。沿图中的方向，

$$p = .5 + .4u, \qquad q = .25 - .15u.$$

回报含乘积 $1.8pq$。同时改变两处动作概率，会多出 $1.8\,\Delta p\,\Delta q$。

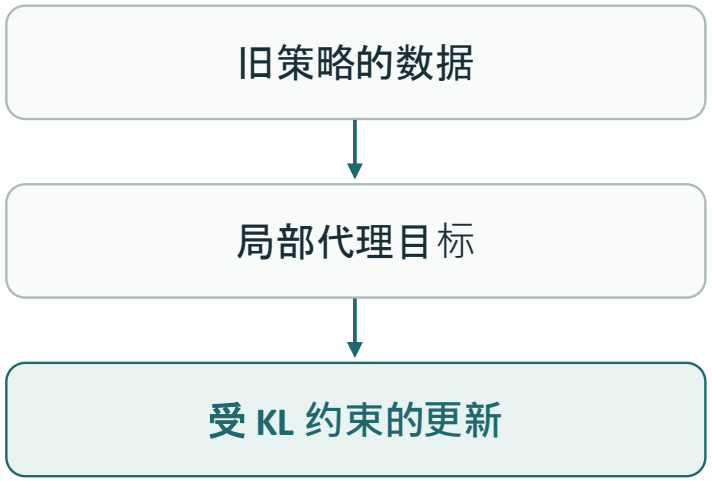


$$\underbrace{J - J_{\text{old}}}_{-.00332(\text{当}u=.2)} = \underbrace{.005u}_{\text{旧访问代理}+.001} \underbrace{-.108u^2}_{\text{到达概率与动作变化}-.00432}.$$

Schulman 等：Trust Region Policy Optimization；两步任务精确枚举：course22_policy_connections.py。

TRPO 的受约束策略更新

在同一批旧状态上评估候选策略，既看动作优势，也看整个动作分布改变了多少。



提出候选方向

旧策略采样并估优势，根据代理的梯度和局部 KL 曲率提出一步。

重算实际变化

在同一批旧状态上，用候选参数重新算代理和平均 KL；局部近似可能低估有限步的变化。

超限就回溯

接受提高代理且平均 KL 不超预算的候选；否则缩短步长，全部失败则保留旧策略。

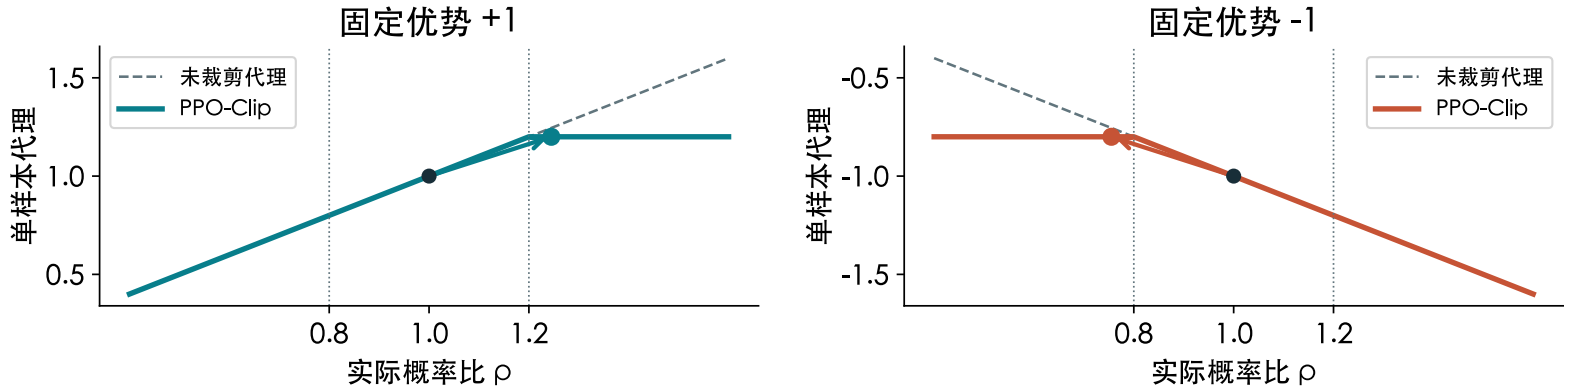
$$\mathbb{E}_{s\sim d_{\text{old}}}[D_{\text{KL}}(\pi_{\text{old}}(\cdot\,|s)\;\|\;\pi_\theta(\cdot\,|s))] \le \delta$$

实践中约束旧访问上的平均 KL。理论下界使用逐状态最大变化。

PPO-Clip 限制的是样本的代理收益

取旧轨迹中一条记录，固定其优势 $\widehat{A}$ 与采样概率，重算当前策略的比率 $\rho = \pi_\theta(a \mid s)/\pi_o(a \mid s)$。设 $\epsilon = .2$，这一项的得分为

$$\ell = \min\{\rho\widehat{A},\ \mathrm{clip}(\rho, .8, 1.2)\widehat{A}\} = \begin{cases} \widehat{A}\min(\rho, 1.2), & \widehat{A} \geq 0, \\ \widehat{A}\max(\rho, .8), & \widehat{A} < 0. \end{cases}$$



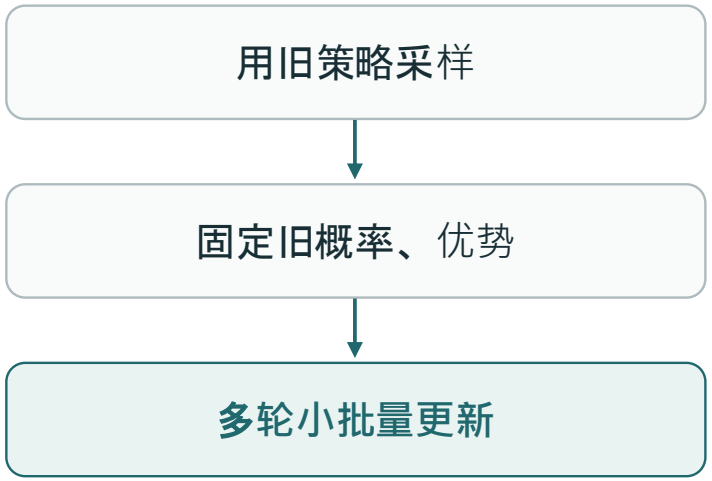
同样是 $\rho = 1.25$：正优势 $+1$ 的得分停在 1.20；负优势 -1 的得分降到 -1.25，仍有把概率拉回的梯度。同样越过上界，梯度仍随优势符号而异。

图中一次更新就使比率从 1 越到 1.245 与 $.755$。即使本项已在平台，其他样本仍可通过共享参数改变它的概率。

据Schulman 等，PPO（2017），§3 式 (7)、图 1重绘；箭头和圆点为本课两动作计算。Spinning Up，compute_loss_pi。

PPO-Clip 的一次策略迭代

旧策略采来的同一批数据可以复用多轮，概率比始终对照采样时的策略。



固定旧数据

保存动作的旧对数概率和旧价值。按同一套价值计算 GAE 与价值标签，在本批内固定。

用小批重复优化

每批重算当前动作概率，按裁剪代理更新行动者，同时让评论者回归固定标签。

重新采样

迭代结束，用更新后的策略与环境交互。新策略访问哪些状态，要到这时才观测到。

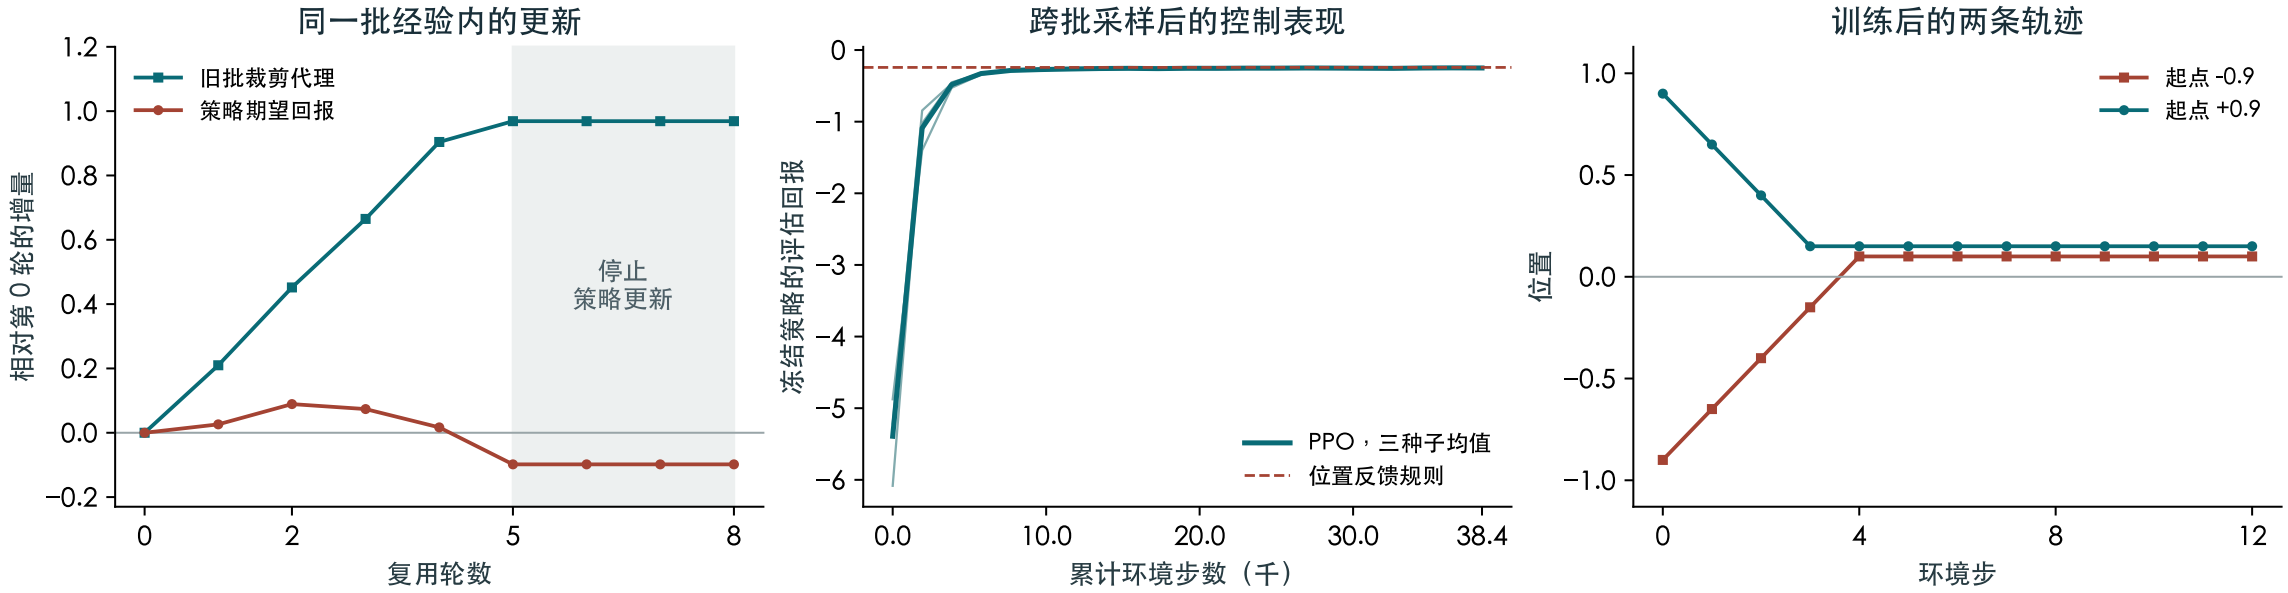
$$\rho_t = \pi_\theta(A_t|S_t) \,/\, \pi_{\text{old}}(A_t|S_t)$$

裁剪的是样本代理收益。可另监测平均 KL，决定何时结束本批更新。

参考文献

旧批次上的策略更新与实际控制表现

位置控制限定 12 步。每步向左或向右移动 .25，也可不动。新位置越靠近原点，奖励越高，移动另扣 .03。旧策略采集 32 个回合。



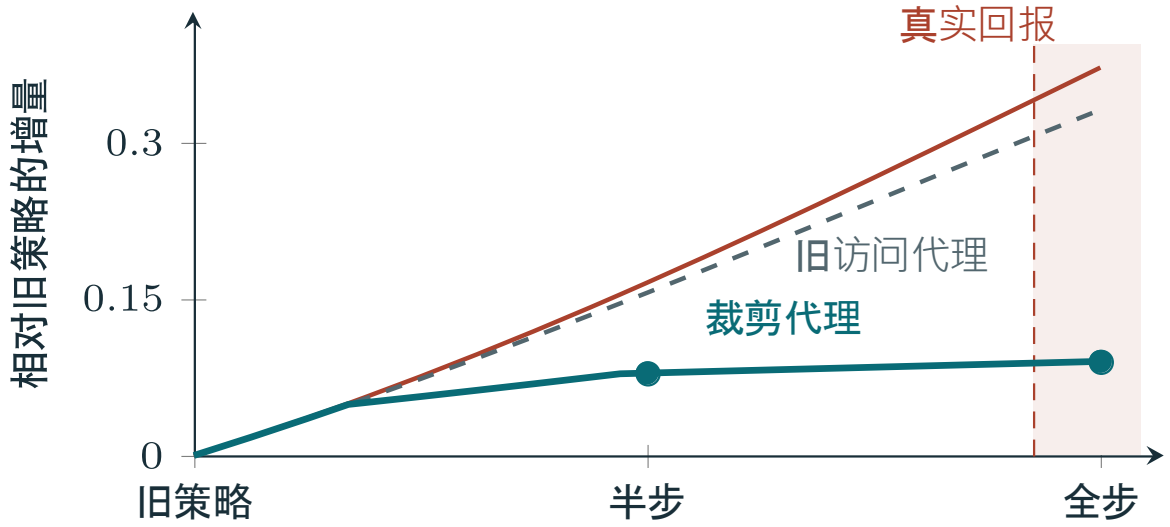
左图在同一批起点比较两项量。第 5 轮，按旧动作算出的裁剪代理升高 .969；候选策略重新行动的期望回报降低 .098。平均 KL 超过 .03，停止更新行动者。

训练 38,400 步后，三个种子的平均评估回报约为 −.25。右图是最终策略走出的两条轨迹。

本课位置控制实验。左图取种子 2 的第一批，期望回报由评价器计算。中图每次用独立随机流评估 128 回合；右图取种子 0。逐轮计算与绘图。

策略梯度、信赖域与裁剪代理

三种方法都以期望回报 J 衡量策略。当前策略的梯度只描述局部变化。要用同一批旧轨迹比较不同步长，还需近似新策略访问各状态的频率。



同一条候选策略路径；阴影处平均 KL **超**过 .01。

PG 给出旧策略处的斜率。图中三条曲线在**那里相切**；**走**远以后，真实回报与旧访问代**理分开**。

TRPO 用平均 KL 限制候选步。全步虽提高**代理，却超**过预算；回溯至半步后通过。

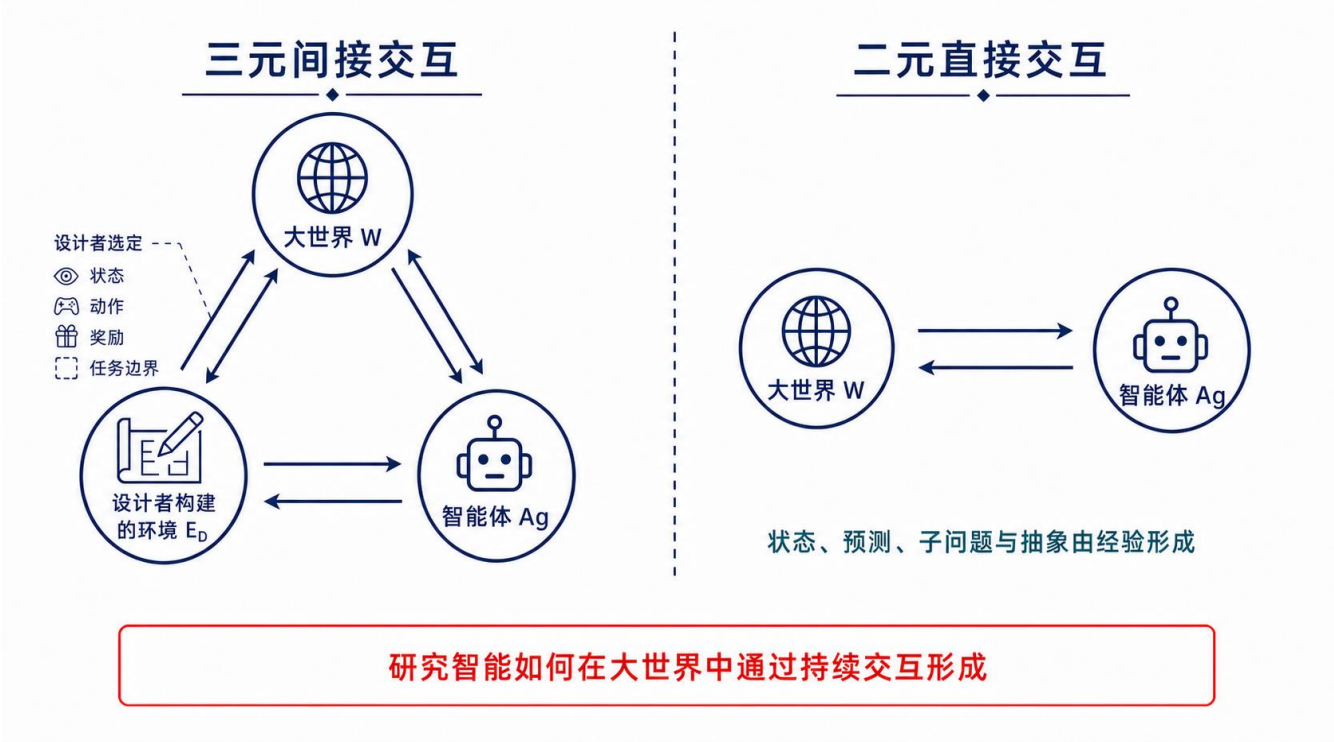
PPO-Clip 改变旧样本对代理的贡献。裁剪**代理仍**给全步更高的分数；逐样本裁剪没有规定平均 KL **上限**。

图中沿自然梯度方向改变两处动作概率。真实回报可在本例中枚举，用来检验近似；实际算法用轨迹估计改进方向。

Schulman 等，TRPO（2015）；Schulman 等，PPO（2017）。**两步**树与图中各点的精确计算。

第 12 章　大世界中的持续强化学习

DQN 从给定的画面、按键和得分学习动作价值。在本章的大世界设定中，**同一个有限智能体**沿**一条**经验**流行**动，没有任务编号和按需重置。



智能体能得到什么

智能体可以利用先验。每步执行 A_t，**其后果** O_{t+1}, R_{t+1} **成**为新的实际经验。

需要学什么

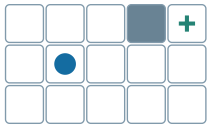
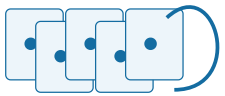
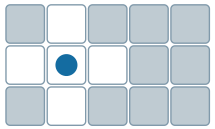
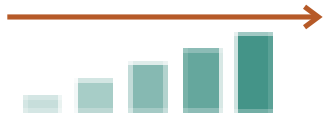
世界的细节超出记忆与计算容量。该记**住哪些区**别、预见哪些后果，要由它在**行**动中学会。

评价整个学习器 给定相同的步数 B，**比**较从首次行动起的期望总奖励 $\mathbb{E}[\sum_{t=0}^{B-1} R_{t+1}]$。**探索也**计入其中。

原图：温颖，《从现代深度强化学习到持续强化学习》，图 1；《大世界中持续强化学习》讲稿第 2–6 页；Sutton、Bowling、Pilarski，The Alberta Plan。

可以分别设定的交互条件

让两台机器人在同一个迷宫送货，还要给出它们可以获得哪些信息、怎样使用经验。图中每列比较一项**条件**，**各列可以分**别选择。

观测	外部重置	经验重放	计算期间	任务标签
				
完整状态	可回到起点	可重读旧样本	世界可暂停	给出任务编号
				
只见局部	从当前位置继续	只保留更新统计量	世界继续运行	只从后果推断

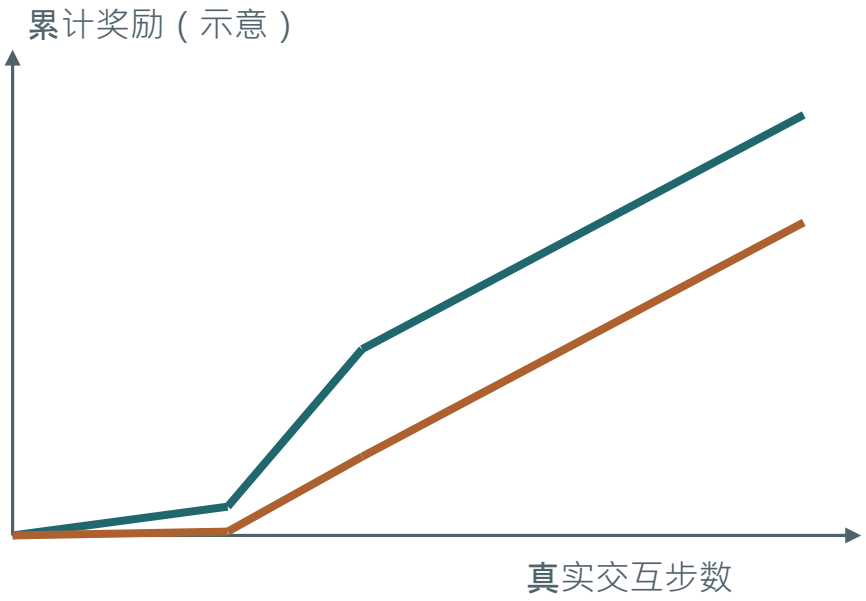
状态可观测性、重置权限和回放容量可以分别设定。任务标签标明当前任务；奖励和评价时域规定**策略或学**习过程的评价准则。

评价对象也要另定 冻结后测试，可以评价学成的策略。从出发起累计奖励，会把试错和恢复也计入。

温颖，《强化学习问题与大世界中的持续学习》, “从历史到 Markov 状态” ；**交互条件原**图。

从第一次行动起评价学习器

同一个最终策略，可以由代价很不相同的学习过程得到。



冻结策略

从共同起点另测，回答已经学会的行为表现如何。

运行学习器

从第一次行动计入奖励，探索、练习和恢复都有代价。

公平比较

规定初始信息、交互步数、存储和每步可用计算。

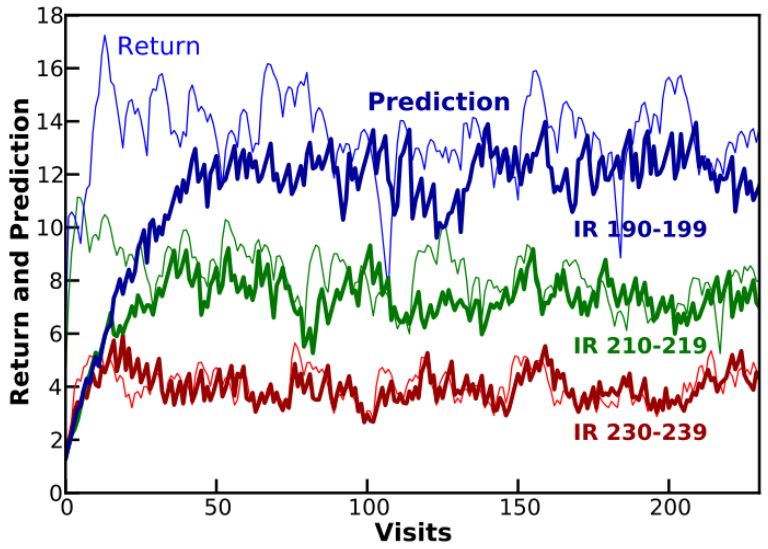
$$J_T(L) = \mathbb{E}_L[\sum_{t=0}^{T-1} R_{t+1}]$$

改变真实交互预算 T，**可以看到投入探索的代价何**时由后续收益补回。

参考文献

从智能体状态到可检验的预测

智能体状态保留与后续决策有关的历史信息。预测则说明，在给定行为下，未来哪一种信号会怎样累积。



状态

结合上一个状态、上一动作与新观测、奖励，更新历史摘要。

预测问题

GVF **指定行**为、逐步累积的信号，以及预测延续到什么时候。

实际检验

在相应行为得到覆盖时，用后来的信号检验预测。

Horde 图 2 测量持续前进到接近障碍的时间。粗线为预测，细线为实际步数。

持续控制中的平均奖励

交互没有自然终点时，可以比较固定策略带来的长期奖励率。

奖励率

把累计奖励除以经历的真实步数，**包括一个技能内部走**过的每一**步**。

差分价值

在平均奖励条件下，描述从某状态开始相对长期基准的额外收益。

学习表现

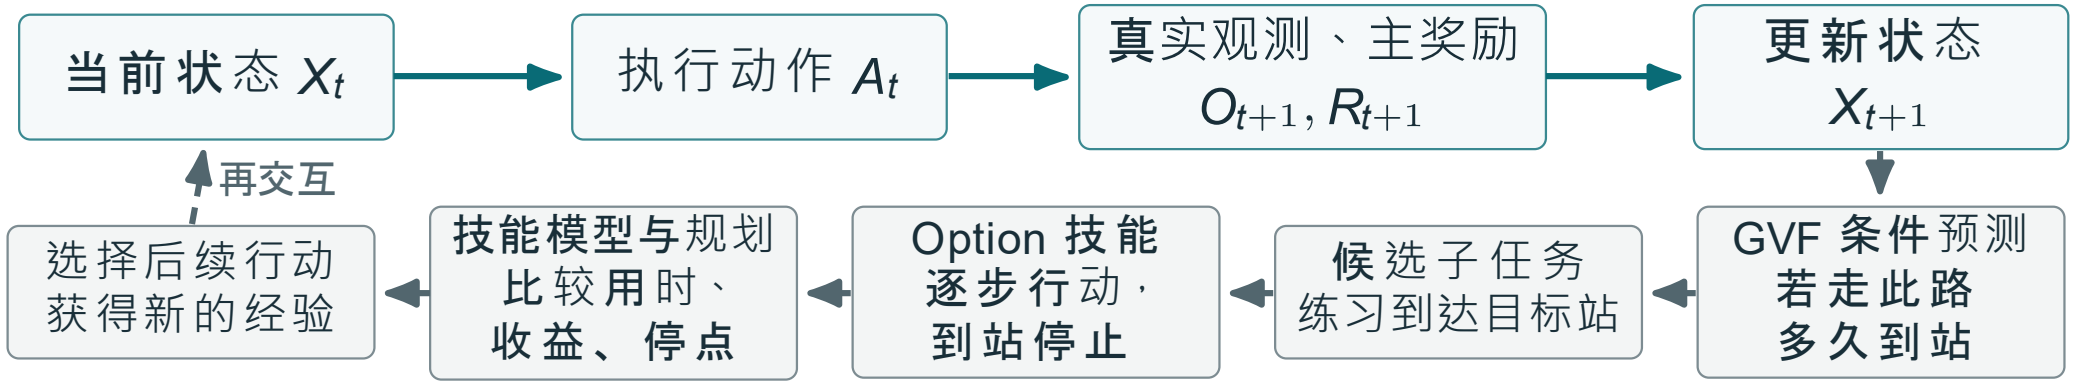
早期探索和恢复的差距，也要用有限期的累计奖励来观察。

$$\rho(\pi) = \lim_{T\to\infty} \frac{1}{T}\, \mathbb{E}_\pi[\sum_{t=0}^{T-1} R_{t+1}]$$

有限单链模型中，各起点共享长期奖励率。比较策略时统一按真实行动步计时。

从多步技能到模型与规划

上层怎样把一段能随中途观察调整的行动，当作一次选择？



形成技能

指定可启动的状态、执行时采用的内部策略、**交回控制的条件**。

学习技能模型

用实际经过预测整段累计奖励、持续时间**和**终止状态。

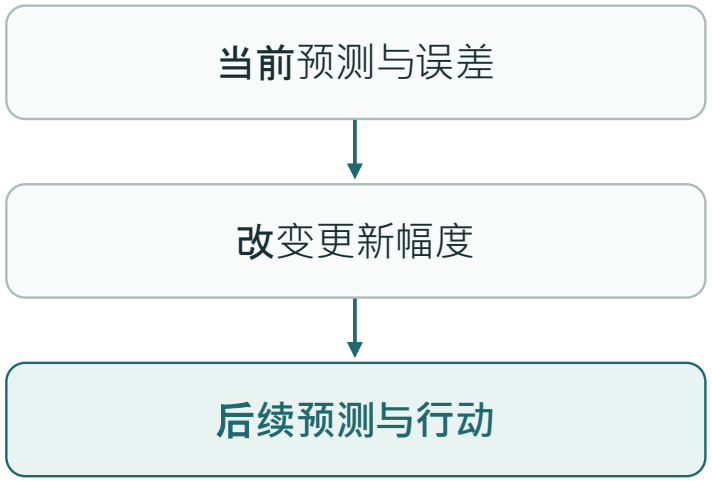
用于规划

在当前状态比较候选技能的后果，用价值评估后续选择。

上排是实际行动；下排的技能形成和模型学习可以跨越许多次交互。

让学习器调节自己的更新

同一条新经验既可用来修正预测，也可在以后检验这次修正得是否合适。



当前一步

观测到新信号，更新预测、策略或模型。

后来几步

后续预测误差为调节更新幅度提供依据，例如在线学习每个参数的步长。

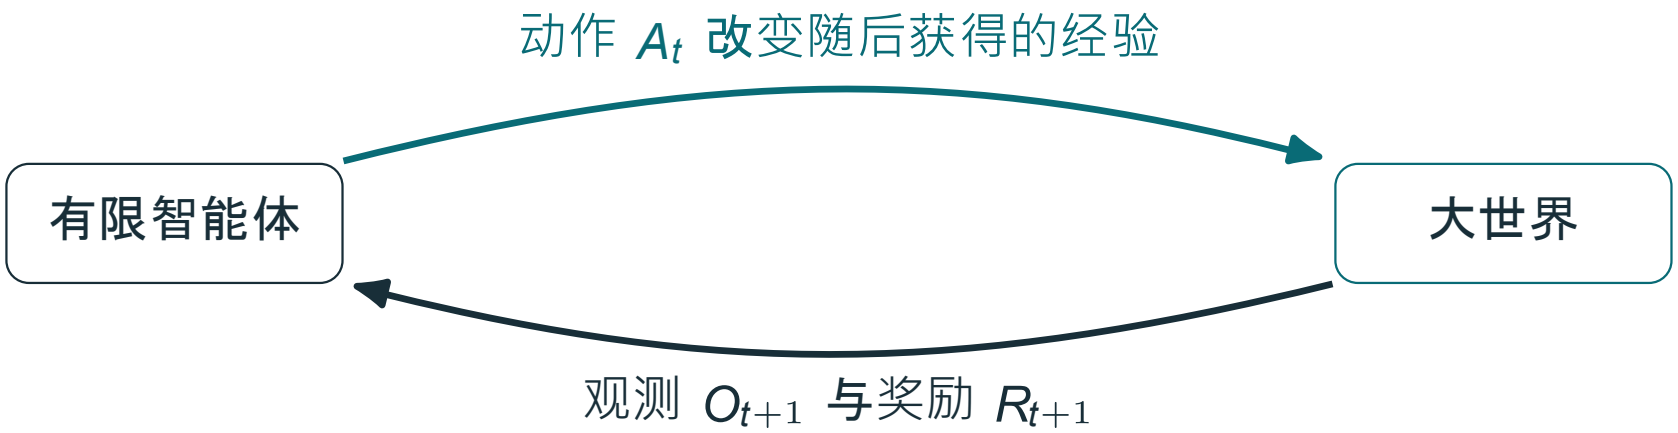
更长时间

检验对新变化的适应速度，以及仍有用的知识保留了多少。

第一层学的是预测或行为，元学习调节的是产生这些变化的学习过程。

持续强化学习的愿景

大世界中的智能体无法记住遇到的一切，却要凭有限的经验和计算，长期作出**有利的**选择。

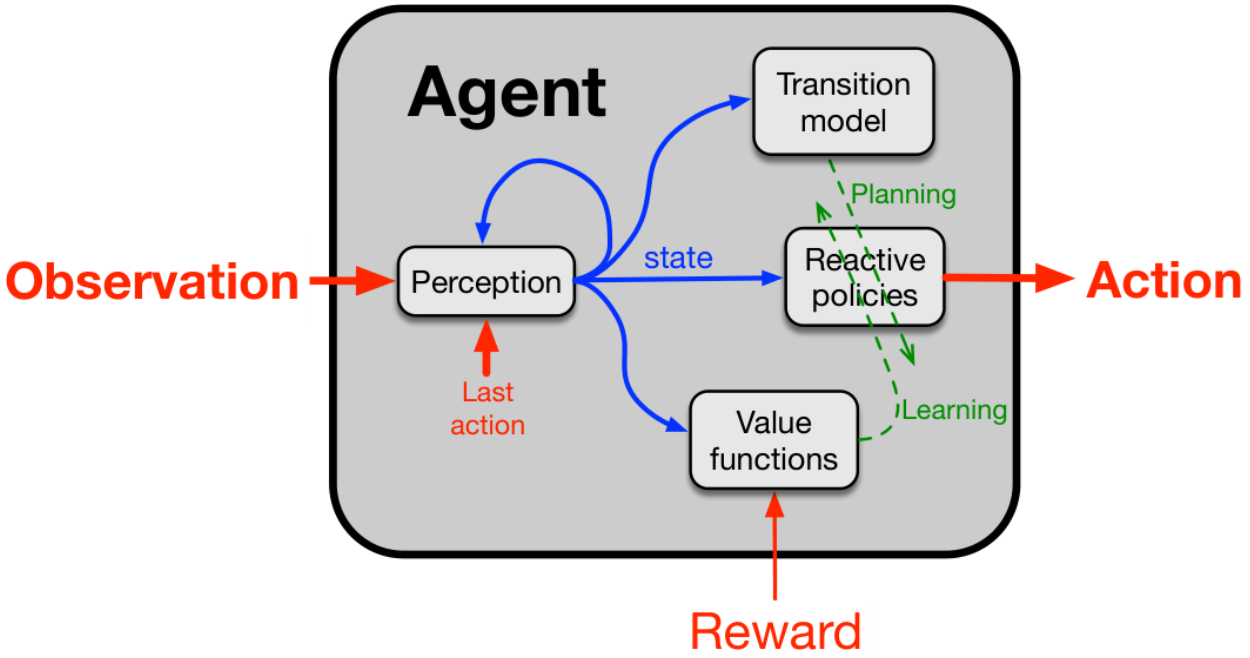


Atari **的**动作、得分和重置方式由设计者规定。在大世界设定中，智能体沿一条经验流持续行动。环境给**出**观测与奖励，运行时无人划分任务或重置世界。

主奖励给出评价行为的依据。智能体在行动中学会记住哪些区别、预测哪些后果、练习哪些技能。在相**同初始信息与**资源下，从第一次行动起比较累积奖励，探索的代价也计入其中。

Sutton、Bowling 与 Pilarski，The Alberta Plan for AI Research；温颖，**从**现代深度强化学习到持续强化学习。

持续学习智能体的整体架构



Alberta Plan 的基本智能体（原文图 2）

当下的行动 感知过程结合上一状态、动作与新观测形成智能体状态。反应式策略据此选择动作。

经验中的预测与控制 GVF 估计给定策略下累积信号的期望。策略可按平均奖励改进。新经验检验先前的预测，也用于学习转移模型。

行动之间的规划 模型推演动作或技能的后果，价值估计评价这些后果。规划可以分多步进行，逐渐改善策略。

哪些抽象值得学习？ 在 STOMP 中，选定的状态特征定义子任务；求解子任务得到 option，再学习它的模型供规划使用。Oak 进一步研究何时替换低效用的抽象。元学习可用后续误差调节更新步长。

Sutton、Bowling 与 Pilarski，The Alberta Plan for AI Research，图 2–3、步骤 10–11；温颖，从现代深度强化学习到持续强化学习。

强化学习：从交互中学习

问题 **交互接口**规定智能体能够观测什么、选择哪些动作。奖励与回报准则给出比较行为的依据。

方法 样本与模型都能用于估计价值，也都能自举。估计可以指导动作选择，也可以用来改善参数化策略。

愿景 **智能体的行**动决定它将获得哪些经验。这些经验又改变它的预测和下**一次**选择。我们希望它在这个循环中逐渐学会表示世界、积累知识和**形成技能**。

谢谢聆听 Thanks for listening!